

Universitat Politècnica de Catalunya
ETSETB / FIB

Aprendizaje no supervisado y detección de anomalías

Documento de descripción de los problemas de la exposición

Computació d'Altes Prestacions i Intel · ligència Artificial (CPIA)

Equipo:
Matías, Martí, Uriel y Arnau Montull
Grado en Ingeniería Física



27 de octubre de 2026

Índice

1. Equipo y reparto de problemas **2**

2. Fundamentos comunes **2**

3. Problema de Arnau Montull: detección de explosiones nucleares con DBSCAN **3**
3.1. Planteamiento y originalidad . . . 3
3.2. Datos . . . 3
3.3. Fundamentación teórica . . . 4
3.4. Método: cómo se detecta . . . 5
3.5. Elección de parámetros . . . 6
3.6. Validación de ε y estabilidad (`nukeval.py`) . . . 7
3.7. Resultados . . . 8
3.8. Conclusiones . . . 9
3.9. Cómo reproducirlo . . . 10

4. Problema de Matías: agrupación de sismos y detección de anomalías **10**

5. Problema de Martí: expresión génica y clustering jerárquico (leucemia ALL/AML) **11**
5.1. Plantejament del problema . . . 11
5.2. Fonament teòric . . . 12
5.3. Metodologia . . . 12
5.4. Resultats i anàlisi . . . 13
5.5. Limitacions . . . 15
5.6. Conclusions . . . 16
5.7. Fórmules complementàries . . . 16

6. Problema de Uriel **16**

7. Problema de Uriel **16**

8. Conclusiones del equipo **16**

Anexo: código completo del problema de Arnau **18**

1. Equipo y reparto de problemas

Exposición del tema «Aprendizaje no supervisado y detección de anomalías». El objetivo es entender cómo encontrar estructura y patrones en datos sin etiquetar con clustering (K-Means, DBSCAN, jerárquico), mezclas gaussianas e Isolation Forest, y cómo evaluar un clustering sin etiquetas (silhouette y método del codo).

Integrante	Problema	Algoritmo principal	Fichero
Arnau Montull	Detección de explosiones nucleares entre sismos (catálogo USGS)	DBSCAN (haversine)	`nukeDBSCAN_arnau.py`
Matías	Agrupación de sismos del último mes y detección de anomalías	K-Means ($K = 3$) y k-vecinos más próximos	`presentation_matias.py`, `validacio.py`
Martí	Expresión génica (leucemia ALL/AML): agrupar pacientes y módulos de genes sin etiquetas	Clustering jerárquico (single, complete, average) y K-Means	`clustering_marti.py`
Uriel	Clasificación de materiales (conductores, semiconductores, aislantes)	DBSCAN	`materiales_uriel.py`

Tabla 1: Reparto de problemas. Cada fichero se llama `<nemotécnico>_<estudiante>.py`.

2. Fundamentos comunes

Resumen de los conceptos que usan los problemas. La explicación completa de K-Means (en catalán) está en `docs/teoria/fonaments_de_clustering_i_kmeans.tex`.

Aprendizaje no supervisado y clustering. Se busca estructura en datos sin etiquetas. Cada algoritmo necesita una medida de similitud (distancia euclídea, haversine, correlación…) y la elección condiciona el resultado.

K-Means. Divide los datos en K grupos minimizando la suma de distancias cuadráticas de cada punto al centroide de su grupo, $J = \sum_{k=1}^{K} \sum_{x \in C_k} \|x - \mu_k\|^2$. Se resuelve con el algoritmo de Lloyd (asignar cada punto al centroide más cercano y recalcular centroides, hasta converger), inicializado con K-means++. Es un clustering *duro*, supone grupos compactos y de tamaño parecido, y hay que fijar K.

Cómo elegir K sin etiquetas. Método del codo (la inercia deja de bajar de forma apreciable), coeficiente de silueta, $s = (b - a)/\max(a, b)$, con a la distancia media a los puntos de su grupo y b la distancia media al grupo vecino más próximo, e índice de Davies–Bouldin.

DBSCAN. Agrupa por densidad: un punto es *central* si tiene al menos $v_{\text{mín}}$ puntos (él incluido) a distancia $\leq \varepsilon$; los grupos son las componentes conexas de puntos centrales y los puntos que no alcanza ninguno quedan como ruido (-1). No necesita fijar el número de grupos y encuentra formas arbitrarias.

Clustering jerárquico, mezclas gaussianas e Isolation Forest. El jerárquico construye un dendrograma según el tipo de enlace (simple, medio, Ward) y se corta a una altura. Las mezclas gaussianas (`GaussianMixture`) dan una asignación blanda por probabilidad. Isolation Forest puntúa como anómalos los puntos que se aíslan con pocos cortes aleatorios. **[PENDIENTE: el equipo revisa y amplía este resumen con lo que se exponga.]**

3. Problema de Arnau Montull: detección de explosiones nucleares con DBSCAN

3.1. Planteamiento y originalidad

Los sismógrafos registran por igual terremotos y explosiones nucleares. Preguntamos si un clustering que no mira la etiqueta puede señalar las explosiones solo con la posición y la profundidad del evento. El agrupamiento (DBSCAN) es no supervisado y la ventana de profundidad se fija con un criterio físico, sin optimizarla contra la etiqueta; esta solo se usa para evaluar (ver las limitaciones). La idea física es doble: las pruebas nucleares se repiten en los mismos polígonos de ensayo (Nevada, Semipalátinsk, Novaya Zemlya, Lop Nor, Mururoa…), por lo que forman agrupaciones espaciales muy compactas, y ocurren casi en la superficie, mientras que los terremotos tectónicos tienen profundidad mediana de unos 22 km.

Es un problema de aplicación física que no figura entre las sugerencias del enunciado. Los datos son públicos y el trabajo es de detección y verificación, no una guía para ocultar pruebas.

3.2. Datos

Catálogo del USGS (*ComCat*) con todos los eventos de magnitud $M \geq 4{,}5$ entre 1951 y 2025 (`datos/sismos_usgs_M45_1951_2025.csv`), descargado con `nukedatos.py`. No se filtra por tipo de evento. Tras quitar los eventos sin latitud, longitud, profundidad o magnitud quedan 298 127: 614 etiquetados por el USGS como `nuclear explosion`, 297 413 `earthquake` y 100 de otros tipos (71 erupciones volcánicas, 16 `explosion`, 6 colapsos de mina, 3 estallidos de roca, 2 deslizamientos, 1 voladura de cantera y 1 `other event`). La columna `tipo` *solo se usa para evaluar*, nunca para entrenar.

`nukedatos.py` pide a la API del USGS un año cada vez (cada consulta devuelve como máximo 20 000 eventos), reintenta si falla la red y guarda el resultado cambiando el nombre de la columna `type` por `tipo`. El código completo está en el Anexo.

```
13 def descargar_year(year):
14     # La API limita cada consulta a 20 000 eventos, asi que se pide un año cada
       vez
15     consulta = f'{URL}&starttime={year}-01-01&endtime={year␣+␣1}-01-01'
16
17     for intento in range(4):
18         try:
19             return pd.read_csv(consulta)
20         except Exception:
21             print(f'␣␣{year}:␣reintento')
22
23     raise RuntimeError(f'No␣se␣pudo␣descargar␣{year}')
```

Listing 1: `nukedatos.py`: descarga de un año del catálogo, con reintentos.

`nukeDBSCAN_arnau.py` carga el CSV y se queda con los eventos que tienen posición, profundidad y magnitud.

```
# --- Datos ---
df = pd.read_csv(ARCHIVO)
df = df.dropna(subset=['latitude', 'longitude', 'depth', 'mag'])
df = df[df['mag'] >= 4.5]
df = df.reset_index(drop=True)
```

Listing 2: `nukeDBSCAN_arnau.py`: carga y limpieza de los datos.

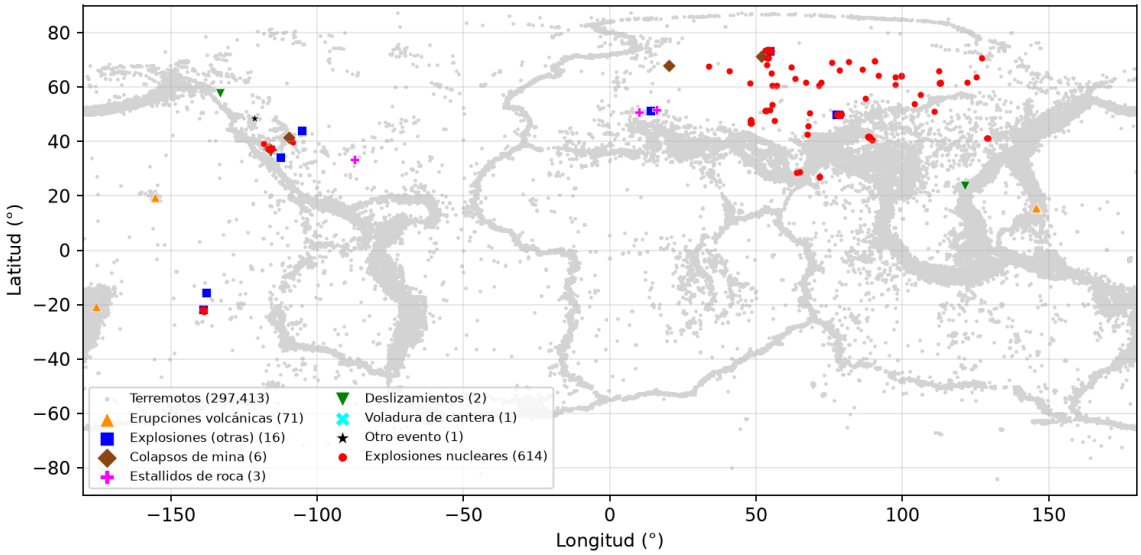


Figura 1: Catálogo completo: las explosiones nucleares (rojo) se concentran en unos pocos polígonos de ensayo. Los 100 eventos de otros tipos del USGS (erupciones volcánicas, otras explosiones, colapsos de mina, estallidos de roca, deslizamientos, voladura de cantera y otro evento) llevan cada uno su color y marcador.

3.3. Fundamentación teórica

DBSCAN [1] define los grupos por densidad. Dado ε y $v_{\text{mín}}$, un punto es central si su vecindad de radio ε contiene al menos $v_{\text{mín}}$ puntos; dos puntos centrales a distancia $\leq \varepsilon$ pertenecen al mismo grupo (alcanzabilidad por densidad) y los puntos sin vecindad suficiente que no alcanza ningún punto central son ruido. Con $v_{\text{mín}} = 1$ todo punto es central y los grupos son las componentes conexas del grafo que une los sismos a menos de ε; es equivalente al clustering jerárquico de enlace simple cortado a la altura ε.

Los epicentros están sobre la esfera, así que la distancia correcta es la ortodrómica. La fórmula de *haversine* [3],

$$d = 2R \arcsin \sqrt{\sin^2 \tfrac{\Delta\varphi}{2} + \cos\varphi_1 \cos\varphi_2 \sin^2 \tfrac{\Delta\lambda}{2}}, \qquad R = 6371 \text{ km},$$

es numéricamente estable para distancias pequeñas y está implementada en `sklearn.cluster.DBSCAN` [2] (`metric='haversine'`, con ε expresado en radianes, $\varepsilon_{\text{rad}} = \varepsilon_{\text{km}}/R$). Aquí el clustering solo agrupa por posición; el criterio físico (profundidad) es el que etiqueta cada grupo.

Como las clases están muy desbalanceadas (614 explosiones frente a casi 300 000 terremotos), la exactitud no sirve: un detector que nunca marcase nada tendría un 99,8 % de aciertos. Se usan la precisión $P = \text{TP}/(\text{TP}+\text{FP})$, el recall $R = \text{TP}/(\text{TP}+\text{FN})$ y su media armónica, $F_1 = 2PR/(P+R) = 2\,\text{TP}/(2\,\text{TP} + \text{FP} + \text{FN})$.

3.4. Método: cómo se detecta

1. **Agrupar por posición.** DBSCAN con distancia *haversine* (distancia sobre la esfera; las coordenadas se pasan a radianes y el radio ε se divide por el radio terrestre, 6371 km). Dos sismos pertenecen al mismo cluster si hay una cadena de sismos a menos de ε km uno del siguiente.
2. **Mirar la profundidad de cada cluster.** Se calcula la *mediana* de profundidad de cada cluster (la mediana no se deja engañar por unos pocos valores atípicos).
3. **Marcar como sospechosos** los clusters cuya mediana está en $[d_{\text{mín}}, d_{\text{máx}})$: casi en la superficie. Todos los sismos de un cluster sospechoso se marcan como *detectados*.
4. **Evaluar contra la etiqueta.** Acierto: detectado y explosión. Falso positivo (FP): detectado pero no explosión. Falso negativo (FN): explosión no detectada.

El paso 1 es la función `agrupar`: pasa las coordenadas a radianes, divide ε entre el radio terrestre y llama a DBSCAN con la métrica *haversine*.

```
# --- Agrupar los sismos cercanos con DBSCAN ---
def agrupar(df, eps_km, vmin):
    radio_tierra_km = 6371
    coordenadas = np.radians(df[['latitude', 'longitude']])
    eps_rad = eps_km / radio_tierra_km

    dbscan = DBSCAN(eps=eps_rad, min_samples=vmin, metric='haversine')
    cluster = dbscan.fit_predict(coordenadas)
    return pd.Series(cluster, index=df.index)
```

Listing 3: `agrupar`: DBSCAN con distancia haversine.

Los pasos 2 y 3 son `nukeDBSCAN`: la mediana de profundidad de cada cluster y la selección de los que caen en la ventana.

```
# --- Marcar los sismos sospechosos de ser explosiones ---
def nukeDBSCAN(df, eps_km, vmin, dmin, dmax):
    cluster = agrupar(df, eps_km, vmin)

    # Profundidad mediana de cada cluster (el ruido, -1, no cuenta)
    sin_ruido = cluster != -1
    mediana = df['depth'].groupby(cluster[sin_ruido]).median()

    # Sospechoso: cluster casi en la superficie, con la mediana entre dmin y dmax
    es_superficial = (mediana >= dmin) & (mediana < dmax)
    clusters_sospechosos = mediana[es_superficial].index

    return cluster.isin(clusters_sospechosos)
```

Listing 4: `nukeDBSCAN`: clusters sospechosos por la mediana de profundidad.

El paso 4 es `errores`, que cuenta FP y FN con la etiqueta `tipo`.

```
# --- Falsos positivos y falsos negativos ---
def errores(df, detectado):
    es_explosion = df['tipo'] == 'nuclear␣explosion'

    # Falso positivo: detectado, pero no es una explosion
    falsos_positivos = (detectado & ~es_explosion).sum()
    # Falso negativo: es una explosion, pero no se detecta
    falsos_negativos = (~detectado & es_explosion).sum()
    return falsos_positivos, falsos_negativos
```

Listing 5: `errores`: falsos positivos y falsos negativos.

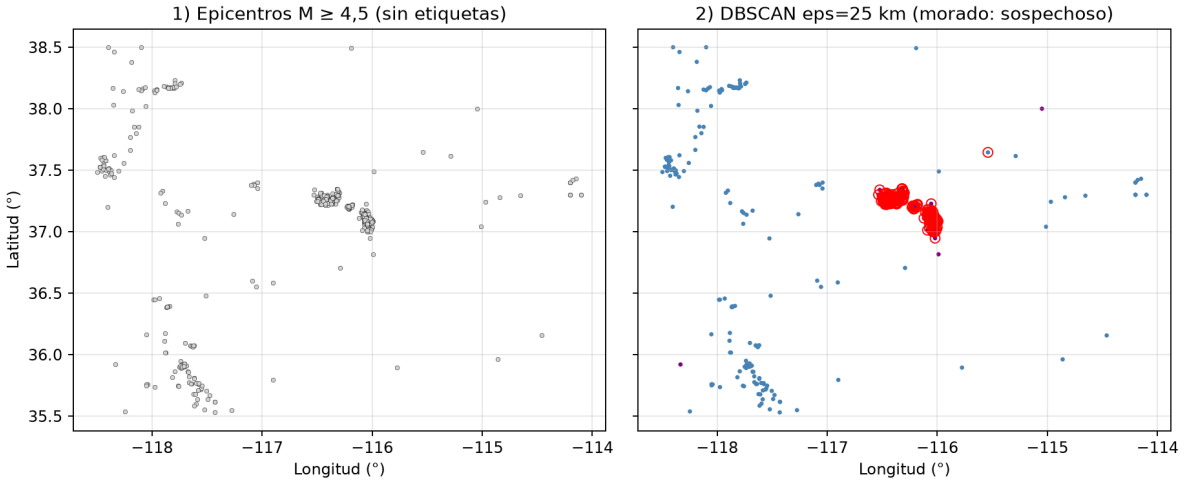


Figura 2: Zoom en el polígono de Nevada. Izquierda: epicentros sin etiquetar. Derecha: clusters de DBSCAN; en morado, los clusters sospechosos por profundidad; círculos rojos: explosiones reales (etiqueta USGS).

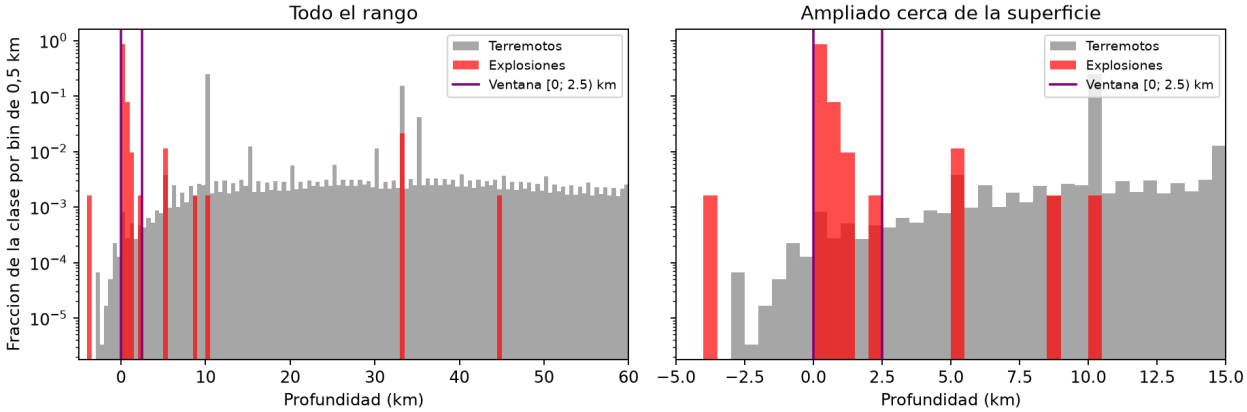


Figura 3: Distribución de profundidades: fracción de cada clase en bins de 0,5 km (escala logarítmica y mismo eje vertical), completa y ampliada cerca de la superficie. Las líneas moradas delimitan la ventana $[d_{\text{mín}}, d_{\text{máx}})$, que se aplica a la *mediana* de cada cluster y no a cada sismo.

3.5. Elección de parámetros

Parámetros fijos: $\varepsilon = 25$ km, $v_{\text{mín}} = 1$, $d_{\text{mín}} = 0$ y $d_{\text{máx}} = 2{,}5$ km. Están en un único diccionario al principio de `nukeDBSCAN_arnau.py`, que `nukeval.py` importa.

```
# Parametros fijos
#   eps_km: radio de DBSCAN. vmin: sismos minimos por cluster.
#   dmin, dmax: una explosion es casi superficial, asi que un cluster es sospechoso
#   si la mediana de su profundidad esta entre 0 y 2.5 km.
parametros = dict(eps_km=25, vmin=1, dmin=0, dmax=2.5)
```

Listing 6: `nukeDBSCAN_arnau.py`: parámetros fijos.

- **Ventana de profundidad** [0; 2,5) **km:** criterio físico. Una explosión nuclear enterrada está a menos de unos pocos km de la superficie; los terremotos tectónicos están, en su mayoría, mucho más profundos.
- $\varepsilon = 25$ **km:** del orden del tamaño de un polígono de ensayo. Es el valor con menos falsos positivos de los probados (5 a 100 km, ver la validación): con menos radio los terremotos superficiales

quedan en grupos sueltos y con más radio los grupos de explosiones se funden con terremotos más profundos. Aquí sí se mira la etiqueta.

- $v_{\text{mín}} = 1$**:** con $v_{\text{mín}} = 3$ empeora (ver las limitaciones).

El script `nuke_optimizar.py` (búsqueda de la ventana y de ε por F_1) se probó, pero no se usa para los parámetros finales: su óptimo, [0; 0,1) km, queda en el borde de su rejilla y aprovecha que el USGS registra con profundidad exactamente 0,0 km el 85 % de las explosiones (521 de 614) y solo 154 de 297 513 eventos que no son explosiones nucleares. Eso mide cómo cataloga el USGS y no la física. La tabla compara ventanas con $\varepsilon = 25$ km.

Ventana (km)	TP	FP	FN	F_1
[0; 0,1) (la que elegía el optimizador)	585	58	29	0,931
[0; 2,5) (usada)	586	115	28	0,891
[0; 5)	587	363	27	0,751
[0; 10)	588	2 897	26	0,287

Tabla 2: Efecto de la ventana de profundidad ($\varepsilon = 25$ km, $v_{\text{mín}} = 1$).

3.6. Validación de ε y estabilidad (`nukeval.py`)

Siguiendo el esquema de validación del temario (silueta, codo y estabilidad), `nukeval.py` evalúa ε con $v_{\text{mín}} = 1$ y la ventana [0; 2,5) km. Para cada ε cuenta los clusters, calcula la silueta con distancia haversine sobre una muestra de 2 000 sismos (sin etiquetas) y los FP y FN (con etiquetas).

```
# --- Silueta de unos clusters (sobre una muestra de 2000 sismos) ---
def silueta(df, cluster):
    coordenadas = np.radians(df[['latitude', 'longitude']])
    try:
        return silhouette_score(coordenadas, cluster, metric='haversine',
                                sample_size=2000, random_state=42)
    except ValueError:
        # La muestra no tiene al menos 2 clusters
        return np.nan


# --- Para cada eps: numero de clusters, silueta, FP y FN ---
def evaluar_eps(df, vmin, dmin, dmax):
    print('\n--- ELECCION DE EPS ---')
    print(f"{'eps (km)':<10}{'clusters':<10}{'silueta':<10}{'FP':<8}{'FN':<8}")
    print('-' * 46)

    n_clusters = []
    siluetas = []
    for eps in EPS_PROBADOS:
        cluster = agrupar(df, eps, vmin)
        detectado = nukeDBSCAN(df, eps, vmin, dmin, dmax)
        fp, fn = errores(df, detectado)

        n_clusters.append(cluster.nunique())
        siluetas.append(silueta(df, cluster))
        print(f'{eps:<10}{n_clusters[-1]:<10}{siluetas[-1]:<10.3f}{fp:<8}{fn:<8}'
    )

    return n_clusters, siluetas
```

Listing 7: `nukeval.py`: silueta de unos clusters y tabla para cada ε probado.

La estabilidad compara los clusters del catálogo completo con los de cinco muestras aleatorias del 50 % mediante el ARI.

```python
# --- Estabilidad: ARI entre los clusters del catalogo y los de una muestra del 50% ---
def evaluar_estabilidad(df, eps_km, vmin):
    print(f'\n--- ESTABILIDAD (eps={eps_km} km, muestra del 50%) ---')
    cluster_completo = agrupar(df, eps_km, vmin)

    for semilla in [1, 2, 3, 4, 5]:
        muestra = df.sample(frac=0.5, random_state=semilla)
        cluster_muestra = agrupar(muestra, eps_km, vmin)

        ari = adjusted_rand_score(cluster_completo[muestra.index], cluster_muestra)
        print(f'Semilla {semilla}: clusters={cluster_muestra.nunique()}, ARI={ari:.4f}')
```

Listing 8: `nukeval.py`: estabilidad con el Adjusted Rand Index.

ε (km)	Clusters	Silueta	FP	FN
5	111 117	0,01	500	15
10	44 804	−0,18	251	13
25	11 049	−0,45	115	28
40	5 691	−0,43	123	30
50	4 214	−0,50	483	28
100	1 786	−0,51	151	269

Tabla 3: Validación de ε (extracto; `nukeval.py` imprime 10 valores).

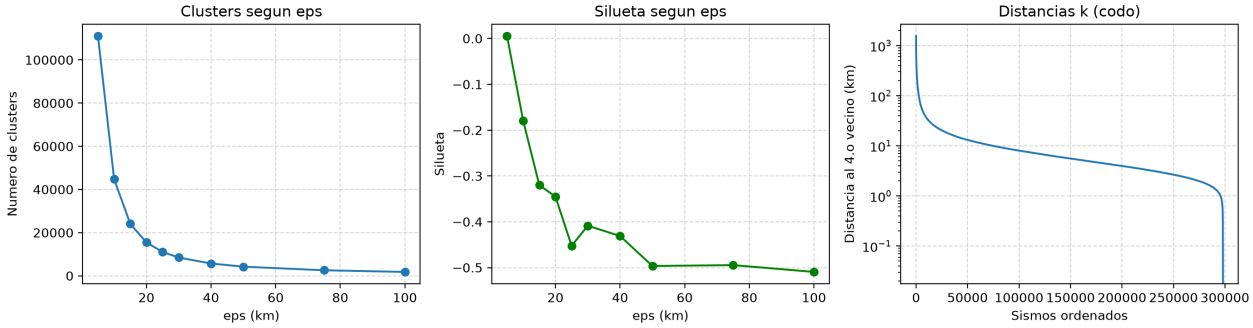


Figura 4: Clusters, silueta y distancia al 4.º vecino (codo clásico de DBSCAN) frente a ε.

- **La silueta no elige ε:** es negativa y decrece al aumentar ε. Con distancia por densidad, DBSCAN une cadenas alargadas de sismos y la silueta (que premia grupos compactos) lo penaliza. Tampoco el gráfico de distancias al 4.º vecino muestra un codo claro entre 20 y 30 km.
- **Lo que sí limita ε es la profundidad:** los FP bajan al crecer ε hasta un mínimo de 115 en 25 km (con ε pequeño muchos terremotos superficiales quedan en grupos sueltos); a partir de 40–50 km los grupos de explosiones se funden con terremotos más profundos: los FP suben a 483 con 50 km y los FN pasan de 28 a 261 con 75 km, porque la mediana deja de ser superficial.
- **Estabilidad:** el ARI entre el clustering de todo el catálogo y el de una muestra aleatoria del 50 % (5 semillas, $\varepsilon = 25$ km) vale entre 0,54 y 0,65: moderado, porque al quitar sismos se rompen cadenas de DBSCAN.

3.7. Resultados

Con los parámetros fijos: 586 aciertos, 115 FP y 28 FN, es decir, precisión 83,6 %, recall 95,4 % y $F_1 = 0{,}891$.

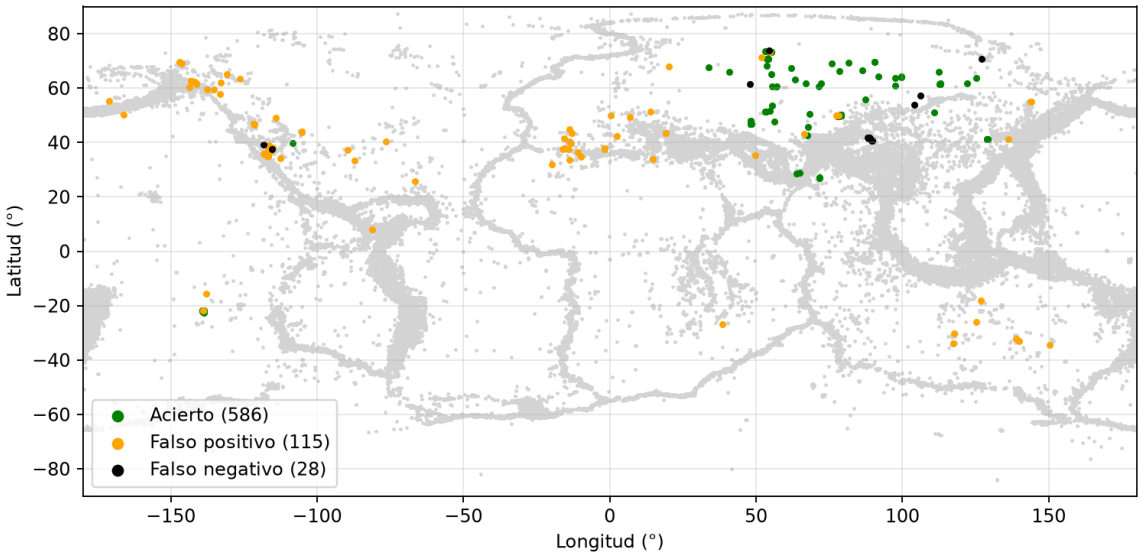


Figura 5: Resultado final: aciertos (verde), falsos positivos (naranja) y falsos negativos (negro).

Limitaciones y honestidad del resultado.

- **Con $v_{\text{mín}} = 1$ no hay ruido:** cada sismo aislado forma su propio cluster. DBSCAN actúa aquí como un agrupador por proximidad encadenada, y la selección real la hace el filtro de profundidad. Con $v_{\text{mín}} = 3$ el resultado empeora ($F_1 = 0{,}899$; FN = 69), porque muchas pruebas aisladas se perderían como «ruido».
- **Enfoque híbrido, no puramente no supervisado:** DBSCAN agrupa sin etiquetas y la ventana de profundidad es un criterio físico previo, pero ε se ha escogido mirando el F_1 contra la etiqueta entre unos pocos valores, porque la silueta y el codo no lo determinan (ver la validación).
- **Generalización:** no hay un subconjunto de prueba separado: se ajusta y se evalúa en el mismo catálogo.
- **Convención del catálogo:** el 85 % de las explosiones figura con profundidad exactamente 0,0 km. Una ventana más estrecha, [0; 0,1), daría $F_1 = 0{,}931$ pero mediría esa convención del USGS y no la física.
- **Falsos positivos:** terremotos muy superficiales (años 80 en Washington, California, Alaska) y otros eventos no sísmicos. De los 115 FP, 24 son de otro tipo: 16 `explosion`, 5 colapsos de mina, 1 voladura de cantera, 1 estallido de roca y 1 deslizamiento; ninguna de las 71 erupciones volcánicas se marca. Si se descartasen los otros 100 eventos no sísmicos (solo terremotos y explosiones nucleares), serían 91 FP y $F_1 = 0{,}908$. Algunas pruebas oficiales de Nevada figuran en el USGS como `earthquake`; ese error es de la etiqueta, no del método.
- **Sesgo de época:** no se usan el año ni el número de estaciones como variable, porque delatan la época del catálogo y no la física.

3.8. Conclusiones

- Un clustering espacial sin etiquetas, combinado con la profundidad mediana de cada grupo, recupera el 95 % de las explosiones del catálogo ($F_1 = 0{,}891$) con 115 falsos positivos entre casi 300 000 eventos.
- La señal útil es doble y física: repetición en los mismos polígonos de ensayo y profundidad casi nula.

- Líneas de mejora: elegir ε en un subconjunto y evaluarlo en otro; añadir la magnitud y la forma de onda como variables; y usar la lista oficial DOE/NV-209 [5] en lugar de la etiqueta USGS para las pruebas de Nevada.

3.9. Cómo reproducirlo

1. Crear el entorno: `python -m venv .venv` e instalar `requirements.txt` (numpy, pandas, matplotlib, scikit-learn, plotly).
2. Opcional: `python problemas/2_Nuclear/nukedatos.py` descarga del USGS el catálogo (`sismos_usgs_M45_` a `datos/`; si el archivo ya existe, no hace nada.
3. `python problemas/2_Nuclear/nukeDBSCAN_arnau.py` (se puede lanzar desde cualquier carpeta). Imprime FP y FN del run con los parámetros fijos y escribe `globo.html` (globo interactivo con 4 vistas, funciona sin internet).
4. `python problemas/2_Nuclear/nuke_optimizar.py` reproduce la búsqueda por F_1 que se descartó (opcional; unos minutos).
5. `python problemas/2_Nuclear/nukeval.py` reproduce la validación de ε y la estabilidad (unos 4 min) y guarda `nukeval_eps.png` y `nukeval_mapa.png`.
6. Las figuras de este documento: `python docs/figuras_nuclear.py`.

4. Problema de Matías: agrupación de sismos y detección de anomalías

Material en `problemas/3_Sismes_Matias/` (README, código, datos e informe propio en catalán, `informe_sismes.tex`). Lo que sigue resume su `README.md` y su código; *no he ejecutado su código ni he comprobado sus resultados.*

Objetivo. Segmentar los sismos globales del último mes con K-Means ($K = 3$) según magnitud, profundidad, latitud y longitud, para identificar patrones de subducción y actividad en los bordes de placa, y detectar eventos excepcionales (alta magnitud o profundidad inusual) como anomalías.

Datos. `earthquakes.csv`: 10 174 eventos del catálogo USGS con cabecera estándar (`time, latitude, longitude, depth, mag, ...`); el primero es del 15/10/2026.

Método.

1. Carga, reordenación de columnas y filtrado de registros incompletos o inválidos.
2. Normalización z-score de las cuatro variables (media 0, desviación 1).
3. K-Means con $K = 3$.
4. Anomalías: distancia euclídea media a los $k = 5$ vecinos más próximos en el espacio normalizado; son anómalos los puntos más aislados.

Validación. Método del codo (WCSS), coeficiente de silueta y *Adjusted Rand Index* (ARI) entre inicializaciones distintas para medir la estabilidad; `validacio.py` también genera el mapa geográfico.

Reproducir. `pip install -r requirements.txt` (pandas, numpy, scikit-learn, matplotlib), después `python presentation_matias.py` y `python validacio.py`. Hay versiones `*_PANDAS.py` de ambos scripts. Nota: el README nombra `problema_matias.py`, que no existe en la carpeta, y los ficheros no siguen el formato `<nemotécnico>_<estudiante>.py` que pide el enunciado.

[PENDIENTE: Matías: resultados (valor de K elegido, silueta, ARI, anomalías encontradas) y su conclusión.]

5. Problema de Martí: expresión génica y clustering jerárquico (leucemia ALL/AML)

Material en `problemas/4_RNAseq_Marti/` (código `clustering_marti.py`, pruebas `test_clustering.py`, `README.txt`, figuras e informe propio `informe_curt.tex`). El texto que sigue es el informe de Martí, en catalán, tal como lo ha escrito él.

Resum. Aquesta implementació aplica l'aprenentatge no supervisat al conjunt de dades de leucèmia de Golub et al. (72 pacients, 7.129 gens) per comprovar, primer, si és possible recuperar sense etiquetes la distinció entre leucèmia limfoblàstica aguda (ALL) i mieloide aguda (AML) i, segon, quins grups de gens mostren patrons d'expressió semblants. Després d'un preprocessament logarítmic i d'una selecció dels 500 gens més variables, s'agrupen els pacients amb clustering jeràrquic (tres tipus d'enllaç) i K-Means, i els gens amb clustering jeràrquic de distància de correlació. Els diagnòstics clínics s'usen només per validar els models. K-Means assoleix un ARI de 0,89 i l'enllaç *complete* de 0,79, mentre que el coeficient de Silhouette indica $k = 2$ com a nombre òptim de grups.

5.1. Plantejament del problema

Les cèl · lules fabriquen proteïnes a partir de la informació dels gens, i ho fan a través de l'ARN missatger (mRNA): com més activitat té un gen, més mRNA se'n detecta. Aquesta quantitat s'anomena *nivell d'expressió*. Tècniques com el microarray d'oligonucleòtids (usat a [6]) o la seqüenciació d'ARN la mesuren per a milers de gens alhora, de manera que cada pacient queda descrit per un vector amb els nivells d'expressió de tots els gens mesurats. Les leucèmies agudes limfoblàstica (ALL) i mieloide (AML) deriven de línies cel · lulars diferents de la sang i requereixen tractaments diferents; per això distingir-les bé és clínicament rellevant.

El problema és naturalment no supervisat per dos motius. Primer, no sabem a priori quins gens funcionen junts: els gens que s'expressen amb patrons semblants entre pacients (gens co-expressats) sovint estan regulats conjuntament o participen en processos biològics comuns [7], però aquesta informació no ve etiquetada. Segon, volem comprovar si l'estructura de les dades, per si sola, reprodueix el diagnòstic clínic sense haver-lo vist durant el modelatge. A més, es treballa amb alta dimensionalitat (7.129 gens per només 72 pacients), una situació on les distàncies són poc intuïtives i cal escollir amb cura la mètrica i el preprocessament.

Els objectius de la implementació són els següents:

1. Identificar les leucèmies ALL/AML sense etiquetes, tallant l'arbre o K-Means a $k = 2$, amb un ARI superior a 0,7.
2. Comparar tres criteris d'enllaç (*single*, *complete*, *average*) i K-Means, amb una mètrica interna (Silhouette) i una d'externa (ARI).
3. Identificar mòduls de gens co-expressats i triar-ne el nombre amb el coeficient de Silhouette.
4. Visualitzar conjuntament gens i pacients amb un mapa de calor (via dendrogrames).

Pel que fa a l'abast i els supòsits, s'usa un únic conjunt de dades, es treballa amb els 500 gens més variables, la distància és de correlació (o euclidiana), les etiquetes ALL/AML només s'usen després del clustering per validar, no s'elimina cap pacient i no s'interpreten biològicament els mòduls de gens.

Com a aportacions pròpies, el treball agrupa tant pacients com gens i els mostra junts, compara el mapa de calor brut amb el reordenat pels dendrogrames per veure què aporta el clustering, i corregeix un problema de preprocessament detectat en una primera versió (apartat de Metodologia).

5.2. Fonament teòric

Per comparar perfils d'expressió interessa la *forma* del patró i no la seva magnitud: dos gens que pugen i baixen igual entre pacients han de ser veïns encara que un tingui el doble d'amplitud. Per això s'usa la distància de correlació de Pearson, $d_r(u, v) = 1 - r(u, v)$, que val 0 si els perfils estan perfectament correlacionats i 2 si estan perfectament anticorrelacionats; combinada amb l'enllaç *average*, és l'opció clàssica en expressió gènica [7]. K-Means, en canvi, usa la distància euclidiana.

El clustering jeràrquic aglomeratiu parteix de cada element com a clúster propi i fusiona a cada pas els dos clústers més propers; el resultat és un arbre (dendrograma) que es pot tallar a l'altura desitjada per obtenir k grups. Els criteris d'enllaç difereixen en com mesuren la distància entre clústers:

- **Single:** distància mínima entre parells d'elements (sensible a punts aïllats i a l'efecte cadena).
- **Complete:** distància màxima entre parells; afavoreix clústers compactes.
- **Average:** distància mitjana entre tots els parells; equilibri entre els dos anteriors.

K-Means divideix les dades en k grups minimitzant la *inèrcia*, és a dir, la suma de quadrats de les distàncies de cada punt al centre del seu grup. Cal fixar k per endavant i el resultat depèn de la inicialització, per això es repeteix diverses vegades i es guarda la millor. El *mètode del colze* representa la inèrcia en funció de k i busca el punt on la millora deixa de ser apreciable.

Per validar sense etiquetes s'usa el *coeficient de Silhouette* [8], que mesura com de bé encaixa cada element i en el seu grup, $s(i) = \frac{b(i)-a(i)}{\max\{a(i),b(i)\}} \in [-1, 1]$, on $a(i)$ és la distància mitjana als altres elements del seu grup i $b(i)$ la del grup veí més proper; se'n tria el k de silueta mitjana màxima. Com a validació externa s'usa l'*Adjusted Rand Index* (ARI) [9], que compara dues particions comptant els parells d'elements que coincideixen i corregeix l'acord esperat per atzar: val 1 si són idèntiques, aproximadament 0 si equivalen a una partició aleatòria i pot ser lleugerament negatiu. Les fórmules completes són a l'Annex 5.7.

Finalment, un *clustermap* mostra la matriu d'expressió com un mapa de calor amb files (gens) i columnes (pacients) reordenades segons els seus dendrogrames, de manera que els blocs de color revelen gens co-expressats en grups de pacients [7].

5.3. Metodologia

Dades. S'ha utilitzat el conjunt de Golub et al. [6], descarregat d'OpenML (ID 1104): l'expressió de 7.129 gens, mesurada amb microarrays Affymetrix, en 72 pacients (47 ALL i 25 AML), organitzada en una matriu $X \in \mathbb{R}^{7129\times72}$. Les etiquetes clíniques no intervenen en cap etapa del modelatge. La matriu en brut no té valors nuls, va de -28.400 a 71.369 i és molt asimètrica (mitjana 619,78, mediana 120,00); els valors negatius provenen de la correcció del fons i no tenen sentit com a expressió.

Preprocessament. S'inspira en el de Golub et al. [6]. Primer, un retall de rang a [100, 16.000] (`np.clip`), que elimina els valors negatius i les fluctuacions per sota del límit de detecció i limita la saturació dels detectors. Després, la transformació $x' = \log_2(x+1)$, que redueix l'asimetria, estabilitza la variància i fa que les diferències es llegeixin com a canvis relatius d'expressió (*fold-change*); com que $x \geq 100$, el $+1$ és innecessari però inofensiu. Una primera versió retallava només a 0: concentrava més de 10^5 valors en un sol punt i feia aparèixer gens amb variàncies artificialment altes, que haurien dominat la selecció posterior. Finalment, es conserven els $N = 500$ gens de variància més alta, perquè els gens gairebé constants no informen sobre diferències entre pacients (selecció sense etiquetes), i cada gen s'estandarditza amb el z-score, $z = (x - \mu)/\sigma$ entre pacients. El resultat és una matriu $X_{\text{clean}} \in \mathbb{R}^{500\times72}$.

Clustering dels pacients. S'agrupen els 72 pacients, cadascun descrit pels seus 500 gens, amb distància de correlació i tres criteris d'enllaç (*single*, *complete* i *average*). Per a cada enllaç es talla l'arbre a $k = 2$ i es calcula l'ARI contra el diagnòstic. El dendrograma i el clustermap es fan amb *average*, que s'ha fixat des del principi (no pas mirant l'ARI) perquè és l'opció estàndard amb distància

de correlació en expressió gènica [7]. Amb K-Means es fa servir $k = 2, \ldots, 8$, amb 10 inicialitzacions i llavor fixa; per a cada k es guarden la inèrcia i la silueta mitjana, i per a $k = 2$ l'ARI.

Mòduls de gens i mapes de calor. S'agrupen els 500 gens, cadascun descrit pels seus valors en els 72 pacients, amb distància de correlació i enllaç *average*. Per a $k = 2, \ldots, 10$ es talla l'arbre, es calcula la silueta amb la matriu de distàncies precalculada i es tria el k de silueta màxima, que defineix el mòdul de cada gen. Després es representa X_{clean} en dues versions: sense reordenar (ordre original dels pacients i ordre de selecció dels gens) i reordenada pels dos dendrogrames (clustermap), amb barres de color pel diagnòstic i pel mòdul. Comparar-les mostra què aporta el clustering.

Implementació. El codi és en Python: NumPy i pandas per a les dades, SciPy per al clustering jeràrquic, scikit-learn [10] per a K-Means, la silueta i l'ARI, i Matplotlib i seaborn per als gràfics. Cada pas és una funció amb *docstring*, totes les llavors són fixes i el repositori inclou un `README` i un `requirements.txt`; totes les figures i xifres d'aquest informe s'obtenen d'una única execució del programa.

5.4. Resultats i anàlisi

La Figura 6 mostra l'efecte del retall i del logaritme: la distribució original, molt asimètrica i amb valors negatius, queda acotada entre $\log_2(101) \approx 6{,}66$ i $\log_2(16001) \approx 13{,}97$. Els dos pics extrems corresponen als valors retallats (47,0 % al terra i 0,8 % al sostre), una limitació del retall perquè tots els gens poc expressats queden al mateix valor. El filtre per variància conserva els 500 gens amb variància $\geq 1{,}30$.

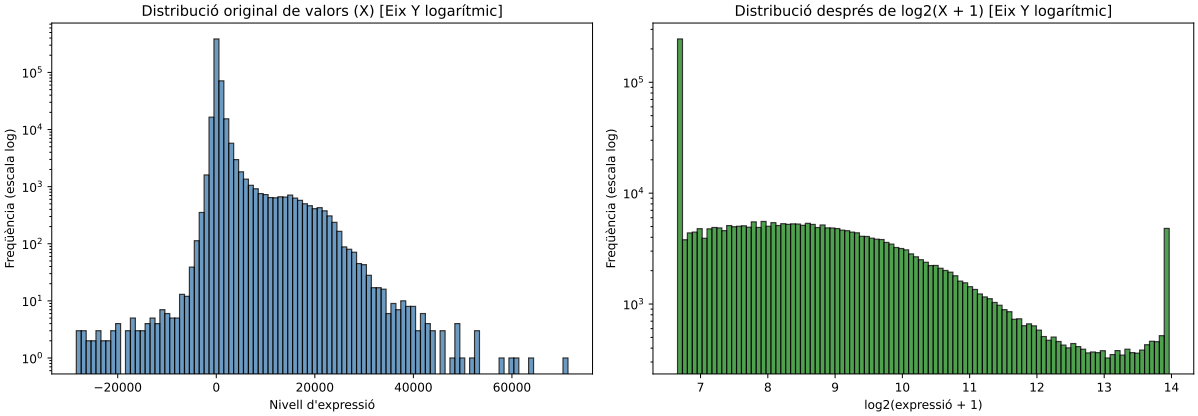


Figura 6: Distribució de les intensitats d'expressió abans (esquerra) i després (dreta) del retall a $[100, 16000]$ i de la transformació $\log_2(x + 1)$. L'eix vertical és logarítmic.

La Taula 4 resumeix els quatre mètodes sobre els 72 pacients i la Figura 7 mostra el dendrograma de l'enllaç *average*.

Mètode	Distància	Mides dels 2 grups	ARI
Single	correlació	[71, 1]	−0,013
Complete	correlació	[29, 43]	0,787
Average	correlació	[31, 41]	0,690
K-Means	euclidiana	–	**0,890**

Tabla 4: Comparació de mètodes per a $k = 2$ (mides reals: 47 ALL i 25 AML). En negreta, l'ARI màxim (K-Means).

- **Single** falla: separa un únic pacient i deixa la resta junta (ARI ≈ 0) per l'efecte cadena.
- **Complete** té el millor ARI entre els jeràrquics (0,787), per sobre de 0,7.

- **Average**, l'enllaç triat per al dendrograma i el clustermap, queda just per sota (0,690): l'enllaç condiciona el resultat.

Cap partició té mides 47/25, així que cap recupera exactament el diagnòstic; tanmateix, **K-Means** és la que s'hi acosta més (ARI 0,890).

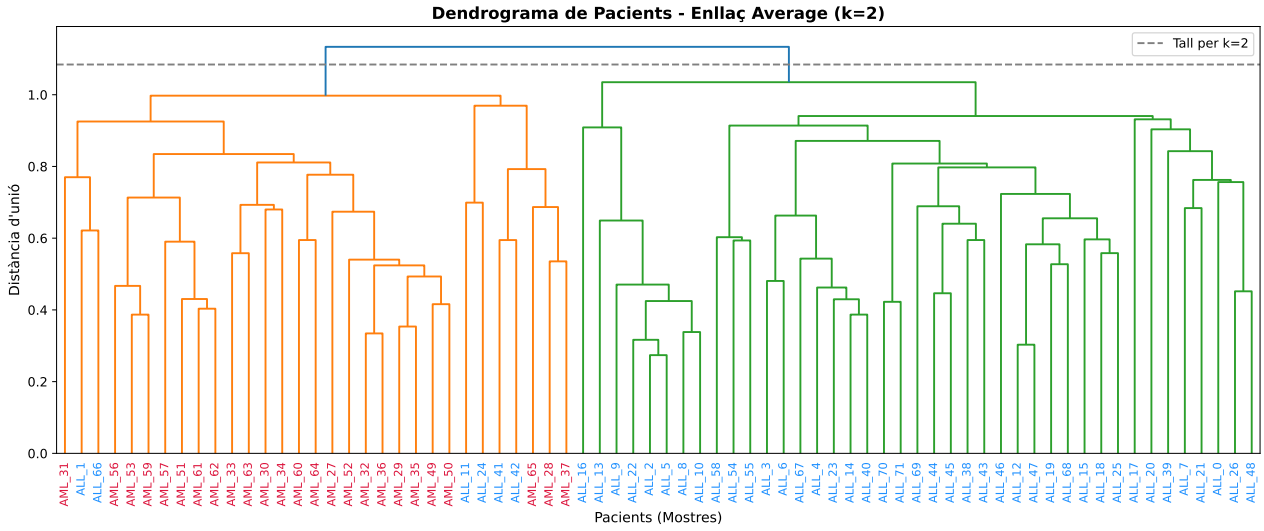


Figura 7: Dendrograma dels 72 pacients (enllaç *average*, distància de correlació). Les etiquetes són blaves per a ALL i vermelles per a AML; la línia grisa discontínua és el tall a $k = 2$.

Pel que fa a K-Means (Figura 8), la inèrcia baixa de manera contínua (de 30.821 a $k = 2$ fins a 22.841 a $k = 8$) i no mostra un colze clar, de manera que el mètode del colze no ajuda a triar k. La silueta, en canvi, és màxima a $k = 2$ (0,1352) i decreix fins a 0,0683 a $k = 8$, la qual cosa coincideix amb els dos diagnòstics reals. Els valors són baixos (inferiors a 0,14): els grups són reconeixibles però no estan gaire separats en un espai de 500 dimensions.

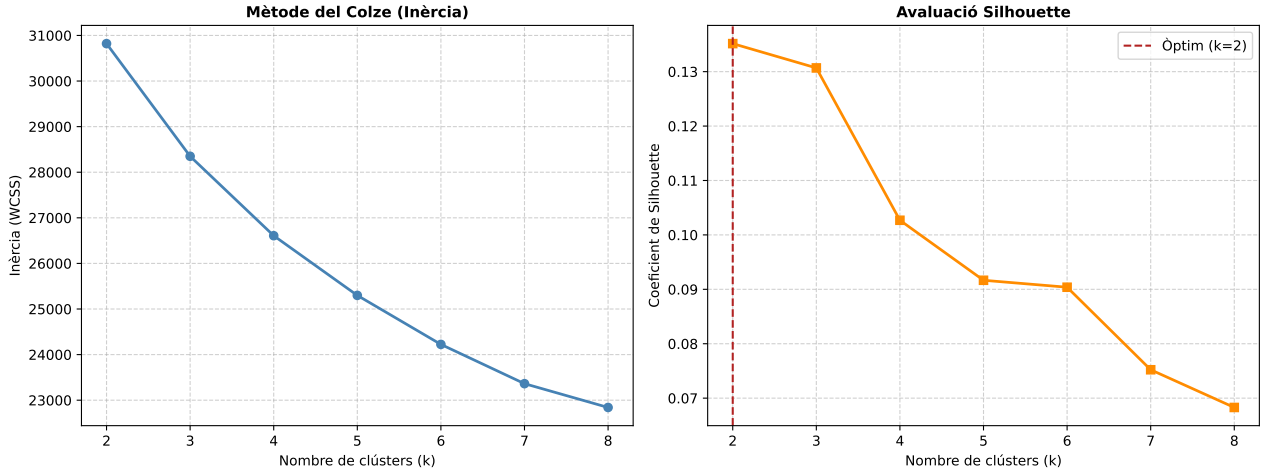


Figura 8: Mètode del colze (esquerra) i coeficient de Silhouette (dreta) per a K-Means.

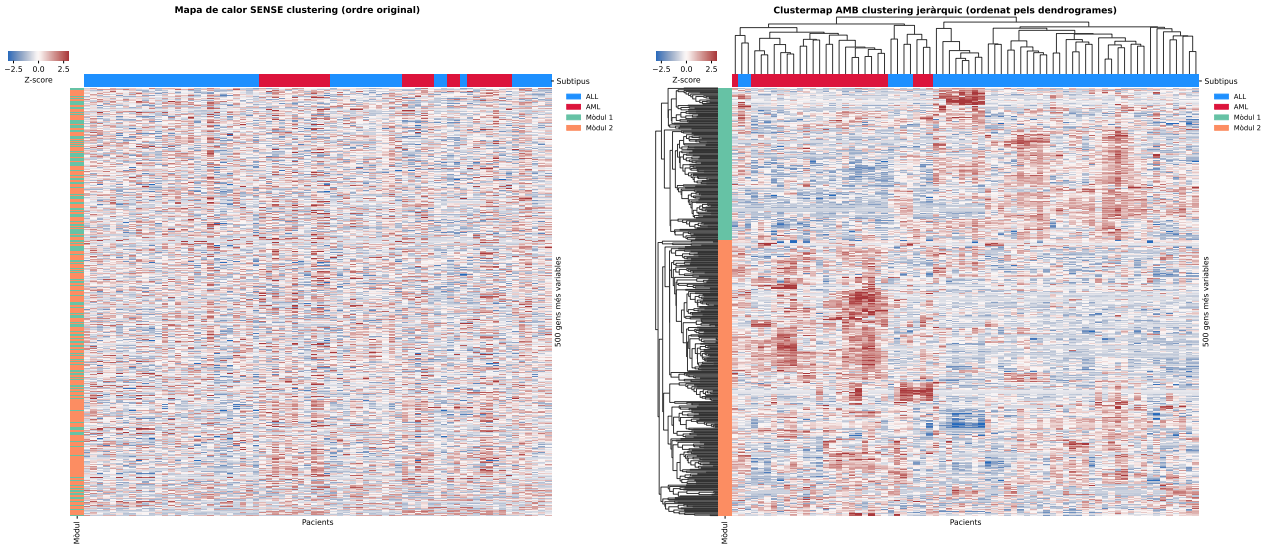
Per als mòduls de gens (Taula 5), la silueta és màxima per a $k = 2$ (0,1812), amb dos mòduls de 178 i 322 gens. Per a k més gran apareixen mòduls molt petits (de 3, 4 o 7 gens) i la silueta empitjora, tot i que té un màxim local a $k = 10$ (0,1394), que donaria una partició més fina. Es manté $k = 2$ per criteri de silueta; és una divisió gruixuda que informa de dos grans patrons d'expressió i no de mòduls funcionals concrets.

Per entendre què aporta el clustering, la Figura 9a mostra la matriu X_{clean} sense reordenar: columnes en l'ordre original dels pacients i files en l'ordre de selecció dels gens (de variància creixent). Cada cel · la és el z-score d'un gen en un pacient (vermell: expressió per sobre de la mitjana d'aquell gen;

k	Silueta	Mides dels mòduls
2	**0,1812**	178, 322
3	0,1302	178, 7, 315
4	0,1188	178, 7, 278, 37
5	0,1088	178, 7, 278, 15, 22
6	0,1125	49, 129, 7, 278, 15, 22
7	0,0929	49, 129, 3, 4, 278, 15, 22
8	0,1297	49, 129, 3, 4, 159, 119, 15, 22
9	0,1276	49, 129, 3, 4, 159, 119, 15, 4, 18
10	0,1394	49, 129, 3, 4, 159, 27, 92, 15, 4, 18

Tabla 5: Silueta i mida dels mòduls de gens per a cada k (enllaç *average*, distància de correlació).

blau: per sota). En aquest ordre no hi ha cap criteri que agrupi gens o pacients semblants i els patrons no es poden llegir. La Figura 9b mostra la mateixa matriu reordenada pels dos dendrogrames: els valors no canvien, només l'ordre, i els gens i pacients amb perfils semblants queden adjacents. Així apareixen blocs de color i les barres de diagnòstic i de mòdul s'agrupen en trams contigus. Es veu que els pacients AML estan gairebé ben separats, ja que la majoria formen un bloc contigu, i a simple vista el mòdul 2 sembla més expressat en els AML i el mòdul 1 en molts dels ALL.



(a) Sense clustering.

(b) Amb clustering jeràrquic.

Figura 9: Z-score dels 500 gens més variables en els 72 pacients, sense reordenar (a) i reordenat pels dendrogrames de gens i pacients, enllaç *average* (b). Barres de color: diagnòstic (ALL blau, AML vermell) i mòdul de gens.

5.5. Limitacions

Primer, l'alta dimensionalitat: amb 500 característiques i només 72 pacients, les distàncies tendeixen a concentrar-se i la silueta és baixa (0,14–0,18) encara que els grups coincideixin amb el diagnòstic. Segon, la sensibilitat al preprocessament: el retall, la selecció de 500 gens i el logaritme afecten els resultats i no s'ha fet una anàlisi de sensibilitat sistemàtica (per exemple, amb 100, 500 i 1.000 gens). Tercer, el tall a $k = 2$: l'ARI es calcula amb el nombre de diagnòstics coneguts i, per als jeràrquics, aquest valor és una decisió prèvia (la silueta de K-Means també indica $k = 2$). Quart, per als mòduls de gens s'ha usat directament *average*, sense comparar-lo amb la resta d'enllaços.

A més, es treballa amb un sol conjunt de dades petit, amb mostres de diversos hospitals, de manera que el clustering podria no distingir els efectes de laboratori del senyal biològic. Els mòduls no s'han anotat biològicament i, per tant, no es pot afirmar que tinguin significat funcional. Tampoc s'ha fet

cap detecció d'anomalies, així que el pacient aïllat per *single* no s'ha analitzat; queda pendent per a una possible continuació del projecte.

5.6. Conclusions

Els resultats permeten respondre els quatre objectius. Sense usar etiquetes, K-Means (ARI 0,890) i l'enllaç *complete* (0,787) superen l'ARI de 0,7 plantejat i recuperen en gran part la distinció ALL/AML, mentre que *average* (0,690) hi queda just per sota; cap partició, però, reprodueix exactament els grups 47/25. La comparació de mètodes mostra que l'enllaç condiciona el resultat: *single* falla per l'efecte cadena i *complete* i *average* donen ARI diferents, de manera que convé validar amb una mètrica externa quan n'hi ha. Pel que fa als gens, la silueta en tria dos mòduls (178 i 322), una divisió gruixuda i de silueta baixa que no equival a mòduls funcionals, de manera que aquest objectiu s'assoleix només en part. Finalment, el clustermap integra gens i pacients amb els diagnòstics i els mòduls, i mostra què aporta el clustering respecte del mapa de calor brut. En conjunt, l'aprenentatge no supervisat, amb un preprocessament acurat i una distància adequada, recupera bona part de l'estructura biològica sense usar les etiquetes. Com a línies de millora es plantegen una anàlisi de sensibilitat al nombre de gens i al preprocessament, la detecció d'anomalies (Isolation Forest), la comparació amb DBSCAN i models de mescla gaussiana, l'anotació biològica dels mòduls i la repetició de l'estudi amb dades de seqüenciació d'ARN, que requereixen un preprocessament diferent.

5.7. Fórmules complementàries

K-Means. Minimitza la inèrcia $J = \sum_{j=1}^{k} \sum_{x \in C_j} \|x - \mu_j\|^2$ alternant dos passos fins que res canvia: assignar cada punt al centre més proper i recalcular cada centre com la mitjana dels seus punts.

Adjusted Rand Index. Sigui n_{ij} el nombre de pacients que són al grup i de la partició trobada i a la classe j del diagnòstic, amb sumes per files a_i i per columnes b_j, i n el total. Llavors

$$\mathrm{ARI} = \frac{\sum_{ij} \binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}\right] \Big/ \binom{n}{2}}{\frac{1}{2}\left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}\right] - \left[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}\right] \Big/ \binom{n}{2}}.$$

6. Problema de Uriel

[PENDIENTE: Uriel: título, datos, método, parámetros, resultados y código.]

7. Problema de Uriel

[PENDIENTE: descripción detallada para reproducir el experimento: datos, método, parámetros, resultados, código.]

8. Conclusiones del equipo

[PENDIENTE: comparativa de los cuatro problemas, qué algoritmo funcionó mejor y por qué.]

Anexo

Anexo: código completo del problema de Arnau

Los tres programas del problema de las explosiones nucleares, tal como se ejecutaron. Cada sección del informe cita solo las líneas que explican en ese punto.

```
"""
Descarga el catalogo del USGS (todos los eventos M>=4.5 de 1951 a 2025, de
    cualquier tipo)
y lo guarda en datos/sismos_usgs_M45_1951_2025.csv.
"""
from pathlib import Path
import pandas as pd

DATOS = Path(__file__).resolve().parent.parent.parent / 'datos'
DESTINO = DATOS / 'sismos_usgs_M45_1951_2025.csv'
URL = 'https://earthquake.usgs.gov/fdsnws/event/1/query?format=csv&orderby=time-
    asc&minmagnitude=4.5'


def descargar_year(year):
    # La API limita cada consulta a 20 000 eventos, asi que se pide un año cada
    vez
    consulta = f'{URL}&starttime={year}-01-01&endtime={year + 1}-01-01'

    for intento in range(4):
        try:
            return pd.read_csv(consulta)
        except Exception:
            print(f'  {year}: reintento')

    raise RuntimeError(f'No se pudo descargar {year}')


if __name__ == '__main__':
    if DESTINO.exists():
        print(f'{DESTINO.name}: ya esta')
    else:
        DATOS.mkdir(exist_ok=True)

        years = []
        for year in range(1951, 2026):
            eventos = descargar_year(year)
            years.append(eventos)
            print(f'{year}: {len(eventos)} eventos')

        df = pd.concat(years, ignore_index=True)
        df = df.rename(columns={'type': 'tipo'})
        df.to_csv(DESTINO, index=False)

        explosiones = (df['tipo'] == 'nuclear explosion').sum()
        print(f'{DESTINO.name}: {len(df)} eventos, {explosiones} explosiones')
```

Listing 9: `problemas/2_Nuclear/nukedatos.py`: descarga del catálogo.

```
from pathlib import Path
import numpy as np
import pandas as pd
import plotly.graph_objects as go
from sklearn.cluster import DBSCAN

# --- Catalogo y parametros ---
# Catalogo USGS 1951-2025, M>=4.5, todos los eventos (se descarga con nukedatos.
    py)
CARPETA = Path(__file__).resolve().parent
ARCHIVO = CARPETA.parent.parent / 'datos' / 'sismos_usgs_M45_1951_2025.csv'
```

```

# Parametros fijos
#   eps_km: radio de DBSCAN. vmin: sismos minimos por cluster.
#   dmin, dmax: una explosion es casi superficial, asi que un cluster es sospechoso
#   si la mediana de su profundidad esta entre 0 y 2.5 km.
parametros = dict(eps_km=25, vmin=1, dmin=0, dmax=2.5)

# --- Datos ---
df = pd.read_csv(ARCHIVO)
df = df.dropna(subset=['latitude', 'longitude', 'depth', 'mag'])
df = df[df['mag'] >= 4.5]
df = df.reset_index(drop=True)


# --- Agrupar los sismos cercanos con DBSCAN ---
def agrupar(df, eps_km, vmin):
    radio_tierra_km = 6371
    coordenadas = np.radians(df[['latitude', 'longitude']])
    eps_rad = eps_km / radio_tierra_km

    dbscan = DBSCAN(eps=eps_rad, min_samples=vmin, metric='haversine')
    cluster = dbscan.fit_predict(coordenadas)
    return pd.Series(cluster, index=df.index)


# --- Marcar los sismos sospechosos de ser explosiones ---
def nukeDBSCAN(df, eps_km, vmin, dmin, dmax):
    cluster = agrupar(df, eps_km, vmin)

    # Profundidad mediana de cada cluster (el ruido, -1, no cuenta)
    sin_ruido = cluster != -1
    mediana = df['depth'].groupby(cluster[sin_ruido]).median()

    # Sospechoso: cluster casi en la superficie, con la mediana entre dmin y dmax
    es_superficial = (mediana >= dmin) & (mediana < dmax)
    clusters_sospechosos = mediana[es_superficial].index

    return cluster.isin(clusters_sospechosos)


# --- Falsos positivos y falsos negativos ---
def errores(df, detectado):
    es_explosion = df['tipo'] == 'nuclear explosion'

    # Falso positivo: detectado, pero no es una explosion
    falsos_positivos = (detectado & ~es_explosion).sum()
    # Falso negativo: es una explosion, pero no se detecta
    falsos_negativos = (~detectado & es_explosion).sum()
    return falsos_positivos, falsos_negativos


if __name__ == '__main__':
    # --- Run con los parametros fijos ---
    detectado = nukeDBSCAN(df, **parametros)
    fp, fn = errores(df, detectado)
    print(f'{parametros}: FP={fp}, FN={fn}')

    # --- Grupos de sismos para el globo ---
    es_explosion = df['tipo'] == 'nuclear explosion'
    terremotos_muestra = df[~es_explosion].sample(4000, random_state=0)
    explosiones = df[es_explosion]
    sospechosos = df[detectado]
    aciertos = df[detectado & es_explosion]
    falsos_positivos = df[detectado & ~es_explosion]
```

```
    falsos_negativos = df[~detectado & es_explosion]

    # Cada vista del globo es una lista de (sismos, nombre, color)
    vistas = {
        'Todos los eventos': [(terremotos_muestra, 'Terremotos (muestra)', 'lightgray'),
                              (explosiones, 'Explosiones nucleares', 'red')],
        'Sospechosos': [(sospechosos, 'Sospechosos', 'purple')],
        'Reales': [(explosiones, 'Explosiones nucleares', 'red')],
        'Aciertos y errores': [(aciertos, 'Acierto', 'green'),
                               (falsos_positivos, 'Falso positivo', 'orange'),
                               (falsos_negativos, 'Falso negativo', 'gray')],
    }

    # --- Globo (globo.html) ---
    fig = go.Figure()
    for vista, capas in vistas.items():
        for sismos, nombre, color in capas:
            fig.add_trace(go.Scattergeo(
                lat=sismos['latitude'],
                lon=sismos['longitude'],
                mode='markers',
                marker=dict(color=color, size=5),
                name=f'{nombre} ({len(sismos)})',
                hoverinfo='skip',
                meta=vista,
                visible=(vista == 'Todos los eventos'),
            ))

    # Un boton por vista: muestra las capas de esa vista y oculta las demas
    botones = []
    for vista in vistas:
        visibles = [capa.meta == vista for capa in fig.data]
        botones.append(dict(label=vista, method='update', args=[{'visible': visibles}]))

    fig.update_layout(updatemenus=[dict(buttons=botones, x=0.01, y=0.99)],
                      legend=dict(x=0.01, y=0.1),
                      margin=dict(l=0, r=0, t=0, b=0))
    fig.update_geos(projection_type='natural earth',
                    showland=True, landcolor='whitesmoke', showcountries=True)

    # Plotly va incluido en el HTML: funciona sin internet
    fig.write_html(CARPETA / 'globo.html', include_plotlyjs=True)
    fig.show()
```

Listing 10: `problemas/2_Nuclear/nukeDBSCAN_arnau.py`: detección y globo interactivo.

```
"""
Validacion de nukeDBSCAN_arnau.py: silueta y distancias k para mirar eps,
estabilidad con el Adjusted Rand Index (ARI) y mapa de aciertos y errores.
"""
from pathlib import Path
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import silhouette_score, adjusted_rand_score
from sklearn.neighbors import NearestNeighbors

from nukeDBSCAN_arnau import parametros, df, agrupar, nukeDBSCAN, errores

CARPETA = Path(__file__).resolve().parent
RADIO_TIERRA_KM = 6371
EPS_PROBADOS = [5, 10, 15, 20, 25, 30, 40, 50, 75, 100]


```

```
# --- Silueta de unos clusters (sobre una muestra de 2000 sismos) ---
def silueta(df, cluster):
    coordenadas = np.radians(df[['latitude', 'longitude']])
    try:
        return silhouette_score(coordenadas, cluster, metric='haversine',
                                sample_size=2000, random_state=42)
    except ValueError:
        # La muestra no tiene al menos 2 clusters
        return np.nan


# --- Para cada eps: numero de clusters, silueta, FP y FN ---
def evaluar_eps(df, vmin, dmin, dmax):
    print('\n--- ELECCION DE EPS ---')
    print(f"{'eps (km)':<10}{'clusters':<10}{'silueta':<10}{'FP':<8}{'FN':<8}")
    print('-' * 46)

    n_clusters = []
    siluetas = []
    for eps in EPS_PROBADOS:
        cluster = agrupar(df, eps, vmin)
        detectado = nukeDBSCAN(df, eps, vmin, dmin, dmax)
        fp, fn = errores(df, detectado)

        n_clusters.append(cluster.nunique())
        siluetas.append(silueta(df, cluster))
        print(f'{eps:<10}{n_clusters[-1]:<10}{siluetas[-1]:<10.3f}{fp:<8}{fn:<8}'
    )

    return n_clusters, siluetas


# --- Distancia de cada sismo a su 4.o vecino, de mayor a menor (el "codo" de
    DBSCAN) ---
def distancias_k(df, k=4):
    coordenadas = np.radians(df[['latitude', 'longitude']])
    vecinos = NearestNeighbors(n_neighbors=k, metric='haversine').fit(coordenadas
    )
    distancias, _ = vecinos.kneighbors(coordenadas)

    distancia_k = distancias[:, -1] * RADIO_TIERRA_KM
    return np.sort(distancia_k)[::-1]


# --- Estabilidad: ARI entre los clusters del catalogo y los de una muestra del
    50% ---
def evaluar_estabilidad(df, eps_km, vmin):
    print(f'\n--- ESTABILIDAD (eps={eps_km} km, muestra del 50%) ---')
    cluster_completo = agrupar(df, eps_km, vmin)

    for semilla in [1, 2, 3, 4, 5]:
        muestra = df.sample(frac=0.5, random_state=semilla)
        cluster_muestra = agrupar(muestra, eps_km, vmin)

        ari = adjusted_rand_score(cluster_completo[muestra.index],
    cluster_muestra)
        print(f'Semilla {semilla}: clusters={cluster_muestra.nunique()}, ARI={ari
    :.4f}')


# --- Figura 1: clusters, silueta y distancias k ---
def figura_eps(n_clusters, siluetas, distancia_k):
    fig, ejes = plt.subplots(1, 3, figsize=(14, 3.8))

    ejes[0].plot(EPS_PROBADOS, n_clusters, 'o-')
```

```
    ejes[0].set(xlabel='eps (km)', ylabel='Numero de clusters', title='Clusters segun eps')

    ejes[1].plot(EPS_PROBADOS, siluetas, 'o-', color='green')
    ejes[1].set(xlabel='eps (km)', ylabel='Silueta', title='Silueta segun eps')

    ejes[2].plot(distancia_k)
    ejes[2].set(xlabel='Sismos ordenados', ylabel='Distancia al 4.o vecino (km)',
                yscale='log', title='Distancias k (codo)')

    for eje in ejes:
        eje.grid(True, linestyle='--', alpha=0.5)

    fig.tight_layout()
    fig.savefig(CARPETA / 'nukeval_eps.png', dpi=200)


# --- Figura 2: mapa de aciertos y errores ---
def figura_mapa(df, detectado):
    es_explosion = df['tipo'] == 'nuclear explosion'
    otros = df[~detectado & ~es_explosion]

    fig, eje = plt.subplots(figsize=(10, 5))
    eje.scatter(otros['longitude'], otros['latitude'], s=1, c='lightgray')

    grupos = [(detectado & es_explosion, 'green', 'Acierto'),
              (detectado & ~es_explosion, 'orange', 'Falso positivo'),
              (~detectado & es_explosion, 'black', 'Falso negativo')]
    for mascara, color, nombre in grupos:
        sismos = df[mascara]
        eje.scatter(sismos['longitude'], sismos['latitude'], s=8, c=color,
                    label=f'{nombre} ({len(sismos)})')

    eje.set(xlabel='Longitud (°)', ylabel='Latitud (°)',
            title='Aciertos y errores con los parametros fijos')
    eje.legend(loc='lower left', markerscale=2)
    eje.grid(True, linestyle='--', alpha=0.5)

    fig.tight_layout()
    fig.savefig(CARPETA / 'nukeval_mapa.png', dpi=200)


if __name__ == '__main__':
    print(f'Catalogo: {len(df)} eventos, parametros {parametros}')

    n_clusters, siluetas = evaluar_eps(df, parametros['vmin'], parametros['dmin'], parametros['dmax'])
    evaluar_estabilidad(df, parametros['eps_km'], parametros['vmin'])

    detectado = nukeDBSCAN(df, **parametros)
    fp, fn = errores(df, detectado)
    print(f'\nRun con los parametros fijos: FP={fp}, FN={fn}')

    figura_eps(n_clusters, siluetas, distancias_k(df))
    figura_mapa(df, detectado)
    print(f'Figuras guardadas en: {CARPETA}')
```

Listing 11: `problemas/2_Nuclear/nukeval.py`: validación de ε y estabilidad.

Referencias

[1] Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proc. 2nd Int. Conf. on Knowledge Discovery and*

Data Mining (KDD-96), 226–231.

[2] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[3] Sinnott, R. W. (1984). Virtues of the haversine. *Sky & Telescope*, 68(2), 159.

[4] U.S. Geological Survey. *ANSS Comprehensive Earthquake Catalog (ComCat)*. https://earthquake.usgs.gov/data/comcat/

[5] U.S. Department of Energy, Nevada Operations Office (2015). *United States Nuclear Tests, July 1945 through September 1992*, DOE/NV-209 Rev. 16. https://www.osti.gov/biblio/1351809

[6] Golub, T. R. et al. (1999). Molecular classification of cancer: class discovery and class prediction by gene expression monitoring. *Science*, 286(5439), 531–537.

[7] Eisen, M. B., Spellman, P. T., Brown, P. O., Botstein, D. (1998). Cluster analysis and display of genome-wide expression patterns. *PNAS*, 95(25), 14863–14868.

[8] Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.

[9] Hubert, L., Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2, 193–218.

[10] Pedregosa, F. et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.