

Universitat Politècnica de Catalunya
ETSETB

Aprenentatge no supervisat i detecció d'anomalies

Document de descripció dels problemes de l'exposició

Computer Programming and Its Applications / Programación de Computadores y Sus Aplicaciones (CPIA)

Equip:
Martí Canut Sumarroca
Uriel Martínez Rosa
Arnau Montull Bainad
Matías Stein Niell

Grau en Enginyeria Física



27 d'octubre de 2026

Índex

1 Equip i plantejament dels problemes **3**
1.1 Plantejament integrat dels problemes . . . 3

2 Fonaments comuns de l'aprenentatge no supervisat i el clustering **4**
2.1 La mesura de proximitat i el pretractament de les dades . . . 4
2.2 Clustering particional: L'enfocament de K-Means . . . 5
2.3 Clustering basat en densitat: La filosofia de DBSCAN . . . 5
2.4 Clustering jeràrquic aglomeratiu i Clustermaps . . . 6
2.5 Mètodes de detecció d'anomalies i models probabilístics . . . 7
2.6 Com avaluem un clustering sense disposar d'etiquetes? . . . 7
2.7 Comparativa visual i taula resum dels mètodes de clustering . . . 8

3 Problema d'Arnau Montull: detecció d'explosions nuclears amb DBSCAN **10**
3.1 Interès del problema . . . 10
3.2 Plantejament de la solució . . . 10
3.3 Dades . . . 11
3.4 Fonamentació teòrica . . . 11
3.5 Mètode: com es detecta . . . 12
3.6 Elecció dels paràmetres . . . 13
3.7 Validació de ε i estabilitat . . . 14
3.8 Resultats . . . 15
3.9 Què hi ha darrere de cada clúster . . . 15
3.10 Conclusions . . . 18

4 Problema de Matías: terratrèmols, patrons i anomalies amb K-Means **19**
4.1 Plantejament del problema . . . 19
4.1.1 Context i interès . . . 19
4.1.2 Objectius mesurables . . . 19
4.1.3 Abast i supòsits . . . 19
4.2 Fonamentació teòrica . . . 19
4.2.1 Les dades sísmiques . . . 19
4.2.2 Normalització z-score . . . 19
4.2.3 K-Means (algorisme de Lloyd) . . . 20
4.2.4 Detecció d'anomalies per distància als k veïns . . . 20
4.2.5 Mètriques de validació . . . 20
4.3 Metodologia i solució proposada . . . 20
4.3.1 Visió general i estructura del codi . . . 20
4.3.2 Parts del codi, funcions i justificació . . . 21
4.3.3 Decisions de disseny justificades . . . 21
4.3.4 Proves automàtiques . . . 21
4.4 Resultats i anàlisi . . . 21
4.4.1 Neteja i descripció de les dades . . . 21
4.4.2 Clústers trobats . . . 22
4.4.3 Validació: elecció de K i qualitat . . . 22
4.4.4 Anomalies . . . 23
4.4.5 Eficiència . . . 24
4.5 Conclusions, limitacions i millores . . . 25
4.6 Reproducibilitat . . . 25

5 Problema de Martí: expressió gènica i clustering jeràrquic (leucèmia ALL/AML) **26**
5.1 Plantejament del problema . . . 26

5.2 Fonament teòric . . . 26
5.3 Metodologia . . . 27
5.4 Resultats i anàlisi . . . 28
5.5 Limitacions . . . 30
5.6 Conclusions . . . 30
5.7 Fórmules complementàries . . . 31

6 Problema d'Uriel: classificació de materials elèctrics mitjançant DBSCAN 32
6.1 Introducció i Plantejament del Problema . . . 32
6.1.1 Resistivitat tèrmica . . . 32
6.1.2 Coeficient tèrmic de resistivitat α . . . 32
6.2 Fonament teoric de les Tres Fases . . . 32
6.2.1 Conductors (Metalls) . . . 33
6.2.2 Semiconductors . . . 33
6.2.3 Aïllants (Dielèctrics) . . . 33
6.3 Dataset Experimental: Recopilació i Propietats . . . 34
6.4 Fonamentació de DBSCAN enfront de K-Means . . . 34
6.4.1 Inadequació estructural de K-Means en aquest domini . . . 34
6.4.2 Avantatges determinants de DBSCAN . . . 35
6.5 Metodologia i Preprocessament . . . 35
6.5.1 Estandardització Manual Z-Score amb NumPy . . . 35
6.5.2 Determinació Objectiva dels Hiperparàmetres de DBSCAN . . . 36
6.6 Resultats Experimentals i Visualització . . . 36
6.7 Validació Quantitativa i Discussió Crítica . . . 37
6.7.1 Matriu de Contingència (Patró d'Or) . . . 37

1 Equip i plantejament dels problemes

El present treball conjunt s'emmarca en l'assignatura **Computer Programming and Its Applications / Programación de Computadores y Sus Aplicaciones (CPIA)** del Grau en Enginyeria Física de la Universitat Politècnica de Catalunya (ETSETB). L'objectiu global de l'equip és explorar, avaluar i contrastar les capacitats de l'**aprenentatge no supervisat** (*unsupervised learning*) i la **detecció d'anomalies** per descobrir estructures intrínseques en quatre dominis físics i experimentals completament diferenciats, sense utilitzar cap etiqueta de classe durant el modelatge.

L'equip de treball està format per quatre estudiants, cadascun responsable d'un domini físic, un conjunt de dades real i una estratègia algorítmica específica:

Membre de l'equip	**Problema Físic / Aplicació**	**Domini i Dades**	**Algorisme**
Arnau Montull	Detecció d'explosions nuclears	Catàleg sísmic global (USGS / ComCat)	DBSCAN (Haversine)
Matías Stein	Patrons sísmics i anomalies	Catàleg sísmic global (USGS ComCat)	K-Means + kNN
Martí Canut	Expressió gènica i leucèmia	Microarrays RNA (Golub et al.)	Jeràrquic (HAC)
Uriel Martínez	Classificació de materials elèctrics	Transport d'estat sòlid (CRC / Kittel)	DBSCAN (Z-score)

Taula 1: Repartiment de problemes, dominis físics i algorismes entre els membres de l'equip.

1.1 Plantejament integrat dels problemes

Cada integrant ha abordat un repte científic que posa a prova les propietats geomètriques i topològiques dels algorismes de clustering:

1. **Problema d'Arnau Montull (Secció 3):** Detecció d'assaigs nuclears històrics en el catàleg sísmic global mitjançant DBSCAN amb distància esfèrica de Haversine. Demostra la capacitat de DBSCAN per agrupar detonacions repetides en polígons d'assaig compactes i discriminar-les per profunditat superficial enfront de terratrèmols tectònics naturals.
2. **Problema de Matías Stein (Secció 4):** Descobriment de patrons globals i detecció d'esdeveniments atípics mitjançant K-Means combinat amb la distància als k veïns més propers (kNN). Analitza críticament com la cobertura instrumental de les xarxes sísmiques regionals enfront de les globals condiciona la partició, i identifica terratrèmols de subducció ultraprofunds (> 300 km).
3. **Problema de Martí Canut (Secció 5):** Estratificació no supervisada de pacients de leucèmia aguda (ALL vs. AML) a partir de perfils d'expressió de 7 129 gens mitjançant clustering jeràrquic aglomeratiu i *clustermaps*. Avalua com la distància de correlació i l'enllaç mitjà permeten descobrir subtipus biomèdics sense biaix supervisat.
4. **Problema d'Uriel Martínez (Secció 6):** Classificació autònoma de les tres grans fases de conducció de la matèria condensada (conductors metàl · lics, semiconductors i aïllants) a l'espai bidimensional $(\log_{10}\rho_{300\mathrm{K}}, \alpha)$. Demostra la superioritat de DBSCAN sobre K-Means davant de variàncies que abasten més de 30 ordres de magnitud i densitats espacials heterogènies.

2 Fonaments comuns de l'aprenentatge no supervisat i el clustering

L'**aprenentatge no supervisat** (*unsupervised learning*) aborda un dels reptes més importants de la ciència de dades i la física computacional: descobrir estructura, patrons geomètrics o relacions latents en conjunts d'observacions on no disposem d'etiquetes prèvies de classe durant el modelatge. En lloc de comptar amb un conjunt de dades d'entrenament amb respostes correctes conegudes, l'objectiu consisteix a deixar que les pròpies dades parlin a través de la seva distribució espacial i la seva densitat, revelant taxonomies naturals que sovint reflecteixen mecanismes físics fonamentals.

Dins d'aquest paradigma, el **clustering** o agrupament cerca particionar les dades de manera que les observacions d'un mateix grup presentin una màxima semblança entre si (*alta cohesió intraclúster*) i una diferenciació clara respecte de les d'altres grups (*bona separació interclúster*). Al llarg dels quatre problemes desenvolupats per l'equip, aquest enfocament permet abordar preguntes científiques de gran rellevància: descobrir assaigs nuclears clandestins enmig de la sismicitat global, identificar terratrèmols ultraprofunds de subducció, estratificar pacients de leucèmia per la seva expressió gènica o classificar autònomament les fases conductores, semiconductores i aïllants de la matèria.

2.1 La mesura de proximitat i el pretractament de les dades

Com decidim si dos esdeveniments o materials són «semblants»? Tot algorisme d'agrupament depèn directament de la noció de proximitat entre punts. Tanmateix, mesurar distàncies en dades físiques reals exigeix considerar dues decisions crítiques:

Per què és imprescindible estandarditzar? Si combinem variables que es mesuren en unitats diferents o amb ordres de magnitud dispars, qualsevol mètrica de distància quedarà completament dominada per la variable amb valors numèrics més grans, fent invisible la resta. Per exemple, en física de materials la resistivitat elèctrica varia en més de 30 ordres de magnitud mentre que el coeficient tèrmic varia en fraccions de centèsima; en sismologia, la profunditat abasta centenars de quilòmetres mentre que la magnitud sol estar entre 1 i 8. La transformació canònica z-score escala cada dimensió per tenir mitjana nul · la ($\mu = 0$) i desviació estàndard unitària ($\sigma = 1$):

$$z = \frac{x - \mu}{\sigma}. \tag{1}$$

Això garanteix que totes les propietats físiques ponderin de manera equitativa i que la distància reflecteixi la variabilitat real de cada fenomen.

Mètriques espacials adaptades a la física del problema.

- **Distància Euclidiana (L_2):** És la distància geomètrica en línia recta habitual en espais continus plans. És adequada quan les coordenades representen variables físiques independents estandarditzades (com el pla logaritme de resistivitat vs. coeficient tèrmic).
- **Distància de Haversine (geometria sobre l'esfera):** Quan treballem amb dades geogràfiques (latitud φ i longitud λ), tractar els graus amb la distància euclidiana euclidiana plana genera greus distorsions cap als pols i ignora la continuïtat als antimeridians ($\pm 180°$). La mètrica de Haversine [4] calcula la distància ortodròmica exacta sobre la superfície esfèrica de la Terra (de radi $R \approx 6\,371$ km):

  $$d_H = 2R \arcsin \sqrt{\sin^2\left(\frac{\Delta\varphi}{2}\right) + \cos\varphi_1 \cos\varphi_2 \sin^2\left(\frac{\Delta\lambda}{2}\right)}. \tag{2}$$

  Aquesta mètrica és la que permet a l'equip agrupar detonacions nuclears i terratrèmols sense artefactes de vora a l'oceà Pacífic.
- **Distància de Correlació (Pearson):** En problemes d'alta dimensionalitat com la genòmica (milers de gens per pacient), la intensitat d'expressió absoluta pot estar esbiaixada per motius

tècnics del laboratori. El que interessa és si el perfil de gens puja i baixa de manera coordinada; la distància de correlació mesura precisament la similitud de patrons de variació relativa.

2.2 Clustering particional: L'enfocament de K-Means

La intuïció darrere de K-Means [17, 18] és molt visual: busca resumir un conjunt complex de dades en K punts representatius o «centroides». Podem imaginar-ho com la ubicació òptima de K centres de distribució per tal de minimitzar el desplaçament total de tots els usuaris fins al centre més proper.

Com funciona l'algorisme de Lloyd. Formalment, K-Means cerca la partició que minimitza la inèrcia o suma de quadrats de les distàncies de cada punt al centroide del seu grup assignat:

$$J = \sum_{k=1}^{K} \sum_{\mathbf{x} \in C_k} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2. \tag{3}$$

L'algorisme resol aquesta optimització alternant dos passos senzills fins a la convergència:

1. **Assignació:** Cada punt s'adscriu al centroide que té més a prop, dividint l'espai en cel · les geomètriques de Voronoi.
2. **Actualització:** Es recalcula la posició de cada centroide movent-lo a la mitjana aritmètica (baricentre) dels punts que té assignats.

Aquest cicle garanteix que la inèrcia J disminueix a cada pas i s'atura sempre en un mínim local.

La millora de K-means++. La principal feblesa de l'algorisme clàssic és que depèn de la tria inicial dels centroides: si dos centroides comencen massa a prop per pur atzar, competiran pel mateix grup i deixaran altres zones desateses. Per solucionar-ho, l'esquema K-means++ [19] escull el primer centroide a l'atzar i tria els següents de forma probabilística donant més oportunitat als punts que estan allunyats dels centroides ja existents. Això assegura que els centres inicials quedin ben repartits per l'espai i evita convergir a solucions pobres.

Quan és idoni i quines limitacions té? K-Means és ràpid, escalable i molt eficaç quan els grups naturals són compactes, arrodonits i de densitats similars (com en el problema de sismes de Matías). No obstant això, té limitacions estructurals evidents:

- Imposa una forma convexa i esferoïdal als clústers; falla davant de formes allargades, anells o meandres.
- És molt sensible a densitats desiguals: si un grup és hiperdens i un altre molt dispers (com passa entre metalls i aïllants elèctrics), K-Means tendeix a fragmentar el grup dispers per reduir la inèrcia.
- Força que absolutament totes les dades pertanyin a algun clúster, de manera que els valors anòmals o soroll distorsionen la posició dels centroides.

2.3 Clustering basat en densitat: La filosofia de DBSCAN

L'algorisme DBSCAN [1, 20] aborda el problema des d'una perspectiva totalment diferent: en lloc de buscar punts centrals, imita la manera com l'ull humà reconeix els cúmuls naturals, és a dir, com a **regions de l'espai amb una alta concentració de punts, separades entre si per zones buides o de baixa densitat**.

La intuïció dels punts nucli, frontera i soroll. DBSCAN només demana dos paràmetres geomètrics: un radi d'inspecció local ε i un nombre mínim de veïns $v_{\min}$ que exigeix trobar dins d'aquest radi per considerar que una zona és prou densa:

- **Punts Nucli (*Core points*):** Són aquells que estan envoltats d'almenys $v_{\min}$ punts veïns dins del radi ε. Representen el cor dens d'un clúster.
- **Punts Frontera (*Border points*):** Són punts que no arriben a la densitat mínima per ser nucli, però que cauen dins del radi ε d'un punt nucli. Formen la perifèria del clúster.
- **Punts de Soroll (*Noise*):** Totes les observacions que no tenen prou veïns ni cauen a la vora de cap nucli. DBSCAN les aïlla de manera natural assignant-los l'etiqueta -1.

Connectivitat per densitat. Un clúster en DBSCAN es forma com una cadena continua: si un punt nucli toca un altre nucli, tots dos pertanyen al mateix grup i arrosseguen amb ells tots els seus veïns. Aquesta propietat és la que permet a DBSCAN descobrir estructures de forma absolutament arbitrària (línies de falla, cadenes d'illes volcàniques, corbes de materials) sense que la forma hagi de ser convexa ni arrodonida.

Per què és determinant en física?

1. **No cal fixar el nombre de grups a priori:** DBSCAN troba de forma autònoma quants clústers hi ha en les dades (com els 3 grups purs de conductors, semiconductors i aïllants trobats per Uriel).
2. **Aïllament natiu del soroll:** En problemes com la detecció d'explosions nuclears d'Arnau, milers de terratrèmols ordinaris dispersos es descarten automàticament com a soroll, permetent que l'algorisme es focalitzi únicament en les agrupacions denses corresponents a polígons de proves militars repetides.
3. **Tolera densitats variables** sempre que cadascuna superi el llindar mínim local fixat per ε.

2.4 Clustering jeràrquic aglomeratiu i Clustermaps

En molts fenòmens de la natura no hi ha un únic nombre «correcte» de clústers, sinó una organització a diferents escales (des de branques principals fins a subfamílies). El **clustering jeràrquic aglomeratiu** [8] reflecteix aquesta realitat construint un arbre complet de relacions.

Com es construeix l'arbre (aglomeratiu)? S'inicia amb cada dada formant un clúster individual. En cada iteració, l'algorisme localitza els dos clústers més propers entre si i els fusiona en un de nou, repetint el procés de manera ascendent fins que totes les dades queden unides en una única arrel.

Criteris d'unió (*Linkage*): La manera de definir la distància entre dos grups condiciona el tipus d'arbre que s'obté:

- **Enllaç Simple (*Single*):** Mesura la distància entre els dos elements més propers dels dos grups. Tendeix a crear cadenes allargades i pot connectar dos grups diferents a través d'un sol punt intermedi (*efecte de cadena*).
- **Enllaç Complet (*Complete*):** Mesura la distància entre els dos elements més allunyats. Força que els clústers resultants tinguin un diàmetre màxim fitat i siguin molt compactes.
- **Enllaç Mitjà (*Average*):** Fa la mitjana de totes les parelles de distàncies possibles entre ambdós grups. És un mètode molt robust que equilibra cohesió i separació, com empra Martí en la seva anàlisi genòmica.
- **Mètode de Ward [38]:** Minimitza l'increment de la variància interna que es produiria en fusionar dos grups, afavorint clústers amb mides similars i molt homogenis.

Dendrogrames i Clustermaps. L'arbre es representa mitjançant un **dendrograma**: l'eix vertical indica el nivell de discrepància al qual s'han unit els grups. Si tallem el dendrograma a una alçada determinada amb una línia horitzontal, obtenim una partició concreta sense haver de reexecutar l'algorisme. Quan combinem dos dendrogrames simultanis (un per a les files i un altre per a les columnes d'una matriu) sobre un mapa de calor (*clustermap*), sorgeix una eina visual extraordinària per descobrir mòduls funcionals co-regulats (com grups de gens que s'activen específicament en pacients amb leucèmia mielode enfront de limfoblàstica).

2.5 Mètodes de detecció d'anomalies i models probabilístics

A més d'agrupar dades similars, una branca cabdal de l'aprenentatge no supervisat és identificar instàncies extraordinàries que discrepen del comportament habitual:

- **Puntuació d'anomalia per k-veïns més propers (kNN):** La intuïció és directa: si un esdeveniment és típic, tindrà molts altres esdeveniments semblants a poca distància; si és atípic o anòmal, els seus veïns més propers estaran molt llunyans. Es calcula la distància mitjana als seus k veïns més propers; els punts amb una distància mitjana més gran encapçalen la llista d'anomalies. En el problema de Matías, això permet aïllar de forma objectiva terratrèmols ultraprofunds de zones de subducció que la resta del catàleg no reflecteix.
- **Local Outlier Factor (LOF) [30]:** Avalua la raresa comparant la densitat d'un punt amb la densitat dels seus propis veïns. Això permet descobrir anomalies que potser no estan molt lluny en termes absoluts, però que estan aïllades en comparació amb el seu entorn immediat.
- **Isolation Forest [21, 31]:** Es basa en un principi molt enginyós: aïllar les anomalies mitjançant talls binaris a l'atzar. Com que els punts ordinaris estan concentrats en masses denses, calen molts talls per aïllar-ne un; en canvi, un punt atípic està sol i s'aïlla amb molt pocs talls (profunditat baixa a l'arbre).
- **Mescles Gaussianes (GMM):** A diferència del clustering dur on cada dada pertany estrictament a un sol grup, els models de mescles gaussianes assignen a cada punt una probabilitat de pertànyer a cadascun dels grups (*soft clustering*). Permeten clústers en forma d'el · lipse orientats en qualsevol direcció de l'espai mitjançant matrius de covariància lliures.

2.6 Com avaluem un clustering sense disposar d'etiquetes?

Sense una «veritat de referència» que ens digui si l'assignació és correcta, com sabem si un clustering té sentit físic o quin és el nombre òptim de grups K? L'equip utilitza quatre indicadors de diagnòstic complementaris:

1. **El Mètode del Colze (*Elbow method*):** Representem la inèrcia J en funció de K. A mesura que afegim més centroides la inèrcia sempre decreix, però busquem el punt d'inflexió o «colze» a partir del qual afegir més grups amb prou feines aporta una millora apreciable en la compactació.
2. **El Coeficient de Silueta (*Silhouette Score*) [9]:** Avalua la qualitat de pertinença de cada punt individual combinant cohesió i separació:

$$s = \frac{b - a}{\max(a, b)}, \tag{4}$$

   on a és la distància mitjana del punt als altres membres del seu mateix clúster (cohesió) i b és la distància mitjana als membres del clúster veí més proper (separació). Varia entre -1 (mal assignat) i $+1$ (excel · lentment separat). Un valor mitjà $\bar{s} > 0.5$ indica una estructura clara; $\bar{s} > 0.7$ denota una partició excel · lent i robusta.
3. **L'Índex de Davies–Bouldin (DB) [34]:** Compara la dispersió interna de cada parella de clústers amb la separació física entre els seus respectius centres. Valors més petits indiquen clústers més compactes i més allunyats entre si.

4. **L'Índex de Rand Ajustat (Adjusted Rand Index, ARI) [10]:** S'utilitza per mesurar l'**estabilitat** del model. Si reexecutem l'algorisme amb diferents llavors aleatòries o dividim les dades en dues submostres independents del 50 %, l'ARI mesura la concordança de les particions corregint per atzar: val 1 si les agrupacions són completament idèntiques i ≈ 0 si equivalen a una assignació aleatòria. Un ARI proper a 1 certifica que la partició és una propietat real de la física de les dades i no un artefacte numèric.

2.7 Comparativa visual i taula resum dels mètodes de clustering

A la Figura 1 es sintetitza gràficament la resposta dels quatre grans paradigmes davant de quatre tipologies geomètriques representatives de l'espai bidimensional: formes no convexes (anells concèntrics), varietats no lineals (mitges llunes), cúmuls amb densitats heterogènies i dades denses amb soroll de fons. La visualització fa palesa la incapacitat de K-Means i GMM per connectar topologies no lineals, enfront de l'adaptabilitat de DBSCAN i l'enllaç jeràrquic.

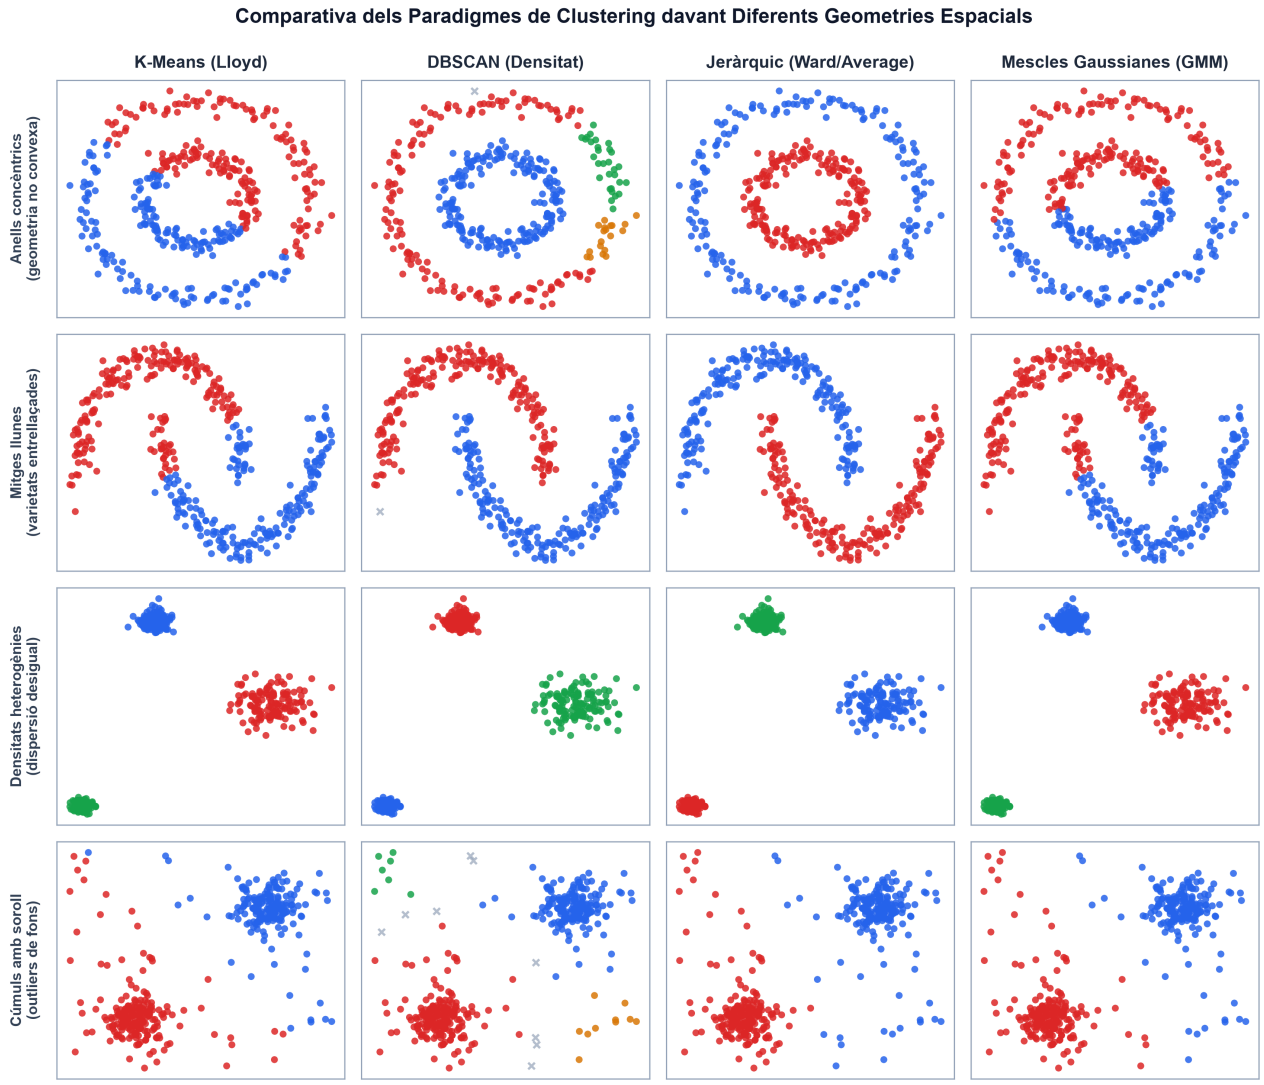


Figura 1: Comparativa del comportament de K-Means, DBSCAN, Jeràrquic aglomeratiu i Models de Mescles Gaussianes (GMM) davant de diferents geometries espacials. S'evidencia la incapacitat de K-Means i GMM per capturar geometries no convexes o densitats desiguals, enfront de la flexibilitat de DBSCAN (que aïlla a més el soroll de fons en gris) i l'enllaç jeràrquic.

A la Taula 2 es resumeixen les característiques operatives de cada mètode i el seu paper dins dels problemes de l'exposició.

Algorisme	**Paradigma**	**Hiperparàmetres**	**Geometria i Formes**	**Gestió Soroll**	**Problema**
K-Means	Particional basat en centroides	Nombre de grups K	Esferoïdal i convexa; isovariàncies	Nul · la (força assignació)	Matías / Martí
DBSCAN	Basat en connectivitat de densitat	Radi ε, mostres mínimes $v_{\min}$	Arbitrària (anells, corbes, meandres)	Nativa (etiqueta soroll -1)	Arnau / Uriel
Jeràrquic (HAC)	Aglomeratiu ascendent (arbre)	Criteri d'enllaç, mètrica de distància	Adaptable segons l'enllaç utilitzat	Nul · la (tot punt en arbre)	Martí
kNN Anomaly	Veïnatge geomètric de distàncies	Nombre de veïns k	Sense forma prèvia (densitat local)	Especialitzat en atípics	Matías
GMM	Model generatiu probabilístic	Components K, matriu $\boldsymbol{\Sigma}$	El · lipsoïdal (covariàncies lliures)	Assignació tova probabilística	Teòric

Taula 2: Resum comparatiu dels paradigmes de clustering i detecció d'anomalies de l'exposició.

3 Problema d'Arnau Montull: detecció d'explosions nuclears amb DBSCAN

3.1 Interès del problema

El desenvolupament de l'armament nuclear ha donat lloc a un període de pau sense precedents entre les grans potències. La possibilitat d'una destrucció mútua assegurada ha dissuadit qualsevol guerra a gran escala entre potències nuclears des de la Segona Guerra Mundial. Alhora, aquestes potències han procurat que el nombre d'estats amb accés a aquesta tecnologia sigui el més reduït possible, i ho han fet mitjançant tractats com el de No Proliferació (1968) i el Tractat de Prohibició Completa dels Assaigs Nuclears (CTBT, 1996), que encara no ha entrat en vigor.

Els fets recents mostren que aquest equilibri és fràgil. L'enriquiment d'urani per part de l'Iran, que s'acosta a l'ús militar, ha alarmat Occident i ha desencadenat un conflicte armat a l'Orient Mitjà entre l'Iran, d'una banda, i Israel i els Estats Units, de l'altra, amb implicació dels seus aliats del golf Pèrsic.

L'últim estat que ha entrat al club nuclear és Corea del Nord, que va fer el seu primer assaig el 2006, fa relativament poc. Amb l'arma, Pyongyang ha blindat el seu règim autoritari davant de qualsevol intent d'intervenció exterior. Corea del Nord va anunciar els seus assaigs, però les xarxes sísmiques globals els van registrar de manera independent i en van permetre la localització i l'estimació de la mida [14]. Aquesta capacitat de verificar a distància, només amb dades sísmiques, és la que dona sentit als tractats anteriors.

Per això en aquesta exposició em pregunto si amb algorismes de detecció d'anomalies i clusters puc identificar explosions de proves nuclears històriques utilitzant dades sísmiques puúbliques.

3.2 Plantejament de la solució

Els sismògrafs registren igual terratrèmols i explosions nuclears. Utilitzem el catàleg de l'USGS i només dues variables de cada esdeveniment: la posició i la profunditat. L'agrupament (DBSCAN) és no supervisat i la finestra de profunditat es fixa amb un criteri físic, sense optimitzar-la contra l'etiqueta; aquesta només s'utilitza per avaluar (vegeu les limitacions). La idea física és doble: les proves nuclears es repeteixen als mateixos polígons d'assaig (Nevada, Semipalatinsk, Nova Zembla, Lop Nur, Mururoa...), de manera que formen agrupacions espacials molt compactes, i passen gairebé a la superfície, mentre que els terratrèmols del catàleg tenen una profunditat mitjana de 33 km i només el 0,25 % és a menys de 2,5 km.

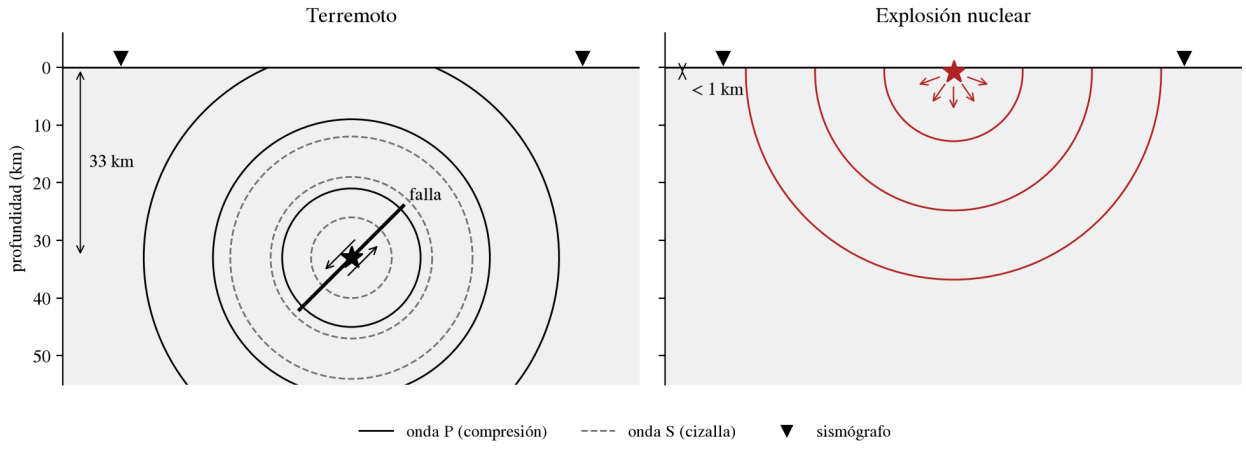


Figura 2: Tall vertical esquemàtic. Un terratrèmol s'origina quan una falla llisca en profunditat (mitjana del catàleg, 33 km) i emet ones P i S. Una explosió nuclear subterrània és un pols de pressió gairebé a la superfície i emet sobretot ones P. Els sismògrafs (triangles) registren tots dos esdeveniments; aquí només es fa servir la profunditat del focus que dona el catàleg.

És un problema d'aplicació física que no figura entre els suggeriments de l'enunciat. Les dades són públiques i el treball és de detecció i verificació, no una guia per amagar proves.

3.3 Dades

Catàleg de l'USGS (*ComCat: Comprehensive Earthquake Catalog*) amb tots els esdeveniments de magnitud $M \geq 4{,}5$ entre 1951 i 2025. Després de filtrar els esdeveniments sense latitud, longitud, profunditat o magnitud en queden 298 127: 614 etiquetats per l'USGS com a `nuclear explosion`, 297 413 `earthquake` i 100 d'altres tipus (71 erupcions volcàniques, 16 `explosion`, 6 esfondraments de mina, 3 esclats de roca, 2 esllavissades, 1 voladura de pedrera i 1 `other event`). La columna de tipologia *només s'utilitza per avaluar*, mai durant la fase de clustering no supervisat.

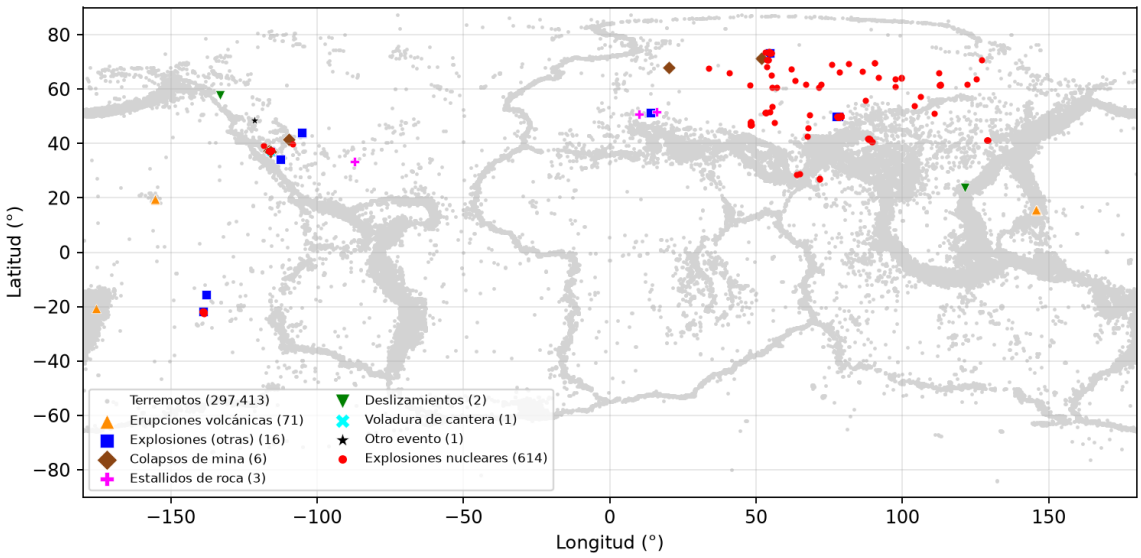


Figura 3: Catàleg complet: les explosions nuclears (vermell) es concentren en uns pocs polígons d'assaig. Els 100 esdeveniments d'altres tipus de l'USGS (erupcions volcàniques, altres explosions, esfondraments de mina, esclats de roca, esllavissades, voladura de pedrera i un altre esdeveniment) porten cadascun el seu color i marcador.

3.4 Fonamentació teòrica

DBSCAN [1] agrupa els punts que estan a prop els uns dels altres. Té dos paràmetres: un radi ε i un nombre mínim de punts $v_{\min}$. Un punt és *central* si té com a mínim $v_{\min}$ punts (ell inclòs) a una distància $\leq \varepsilon$. Dos punts centrals que són a menys de ε l'un de l'altre queden al mateix grup, i així el grup creix de punt en punt com una cadena. Els punts que no són centrals ni tenen cap punt central a prop es marquen com soroll.

Nosaltres fem servir $v_{\min} = 2$: un sisme és central si té almenys un altre sisme a menys de ε km. Així, els sismes que estan sols en un radi de ε km queden com a soroll i no formen cap grup, i els altres s'uneixen per cadenes de menys de ε km. Per això els assajos d'un mateix polígon, que estan molt a prop, acaben al mateix grup. Schubert et al. [20] expliquen com triar ε i $v_{\min}$; per a ε proposen mirar la distància de cada punt al seu veí més proper, com fem a la validació.

Els epicentres són sobre l'esfera, així que la distància correcta és l'ortodròmica. La fórmula de *haversine* [4],

$$d = 2R \arcsin \sqrt{\sin^2 \tfrac{\Delta\varphi}{2} + \cos\varphi_1 \cos\varphi_2 \sin^2 \tfrac{\Delta\lambda}{2}}, \qquad R = 6371 \text{ km},$$

és numèricament estable per a distàncies petites i està implementada a `sklearn.cluster.DBSCAN` [3] (`metric='haversine'`, amb ε en radiants, $\varepsilon_{\text{rad}} = \varepsilon_{\text{km}}/R$). Aquí el clustering només agrupa per posició; el criteri físic (la profunditat) és el que etiqueta cada grup.

Com que les classes estan molt desequilibrades (614 explosions davant de gairebé 300 000 terratrèmols), l'exactitud no serveix: un detector que no marqués mai res encertaria el 99,8 %. S'utilitzen la precisió $P = \mathrm{TP}/(\mathrm{TP}+\mathrm{FP})$, el recall $R = \mathrm{TP}/(\mathrm{TP}+\mathrm{FN})$ i la seva mitjana harmònica, $F_1 = 2PR/(P+R) = 2\,\mathrm{TP}/(2\,\mathrm{TP}+\mathrm{FP}+\mathrm{FN})$.

3.5 Mètode: com es detecta

1. **Agrupar per posició.** DBSCAN amb distància *haversine* (distància sobre l'esfera; les coordenades es passen a radiants i el radi ε es divideix pel radi terrestre, 6371 km). Dos sismes són del mateix clúster si hi ha una cadena de sismes a menys de ε km l'un del següent; els sismes aïllats són soroll i no s'assignen a cap clúster.
2. **Mirar la profunditat de cada clúster.** Es calcula la *mitjana* de la profunditat de cada clúster (la mitjana no es deixa enganyar per uns pocs valors atípics).
3. **Marcar com a sospitosos** els clústers amb la mitjana dins de $[d_{\min}, d_{\max})$: gairebé a la superfície. Tots els sismes d'un clúster sospitós es marquen com a *detectats*.
4. **Avaluar contra l'etiqueta.** Encert: detectat i explosió. Fals positiu (FP): detectat però no és una explosió. Fals negatiu (FN): explosió no detectada.

El pas 1 és la funció `agrupar`: passa les coordenades a radiants, divideix ε pel radi terrestre i crida DBSCAN amb la mètrica *haversine*.

Els passos 2 i 3 són `nukeDBSCAN`: la mitjana de la profunditat de cada clúster i la selecció dels que cauen dins de la finestra.

El pas 4 és `errores`, que compta els FP i els FN amb l'etiqueta `tipo`.

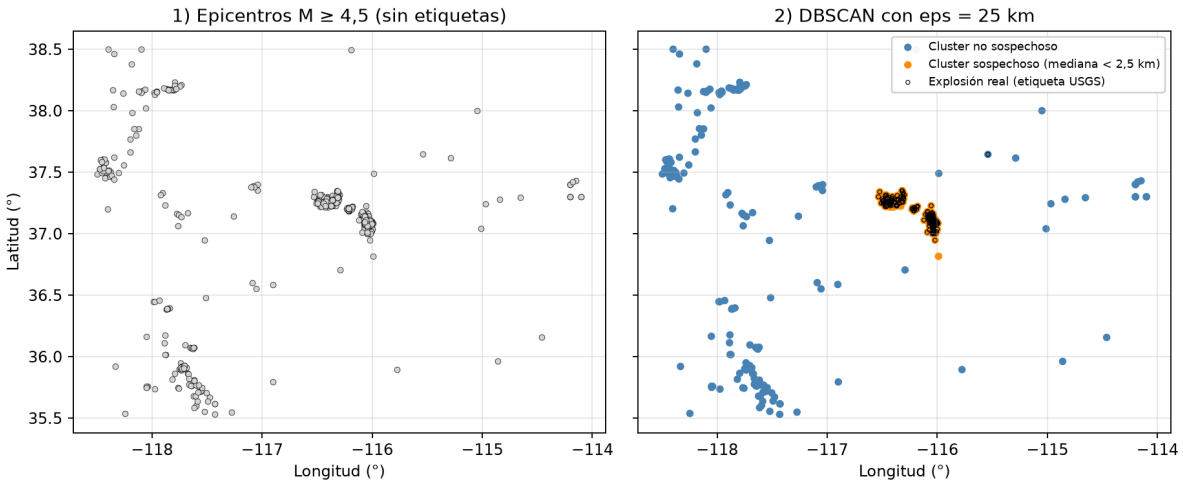


Figura 4: Zoom al polígon de Nevada. Esquerra: epicentres sense etiquetar. Dreta: clústers de DBSCAN; en taronja, els clústers sospitosos per profunditat; cercles negres petits: explosions reals (etiqueta de l'USGS).

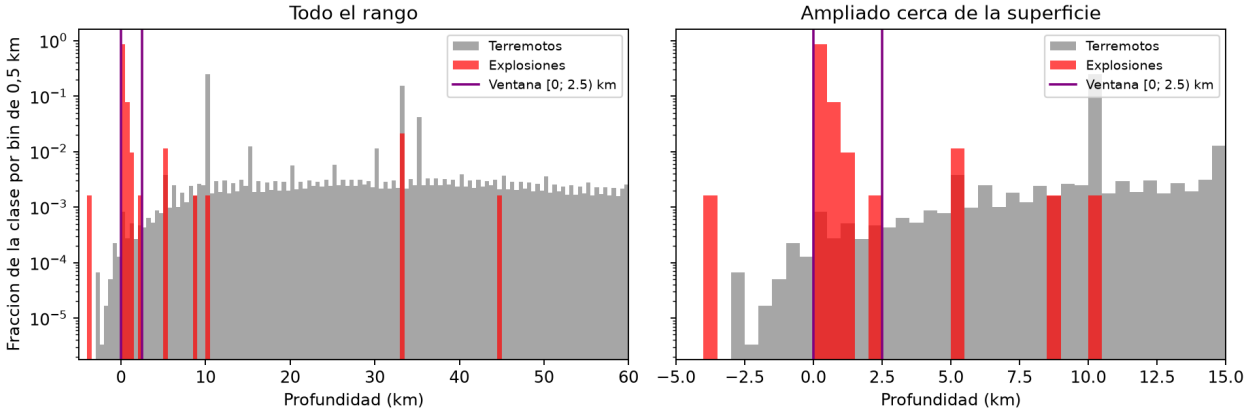


Figura 5: Distribució de profunditats: fracció de cada classe en intervals de 0,5 km (escala logarítmica i mateix eix vertical), completa i ampliada a prop de la superfície. Les línies morades delimiten la finestra $[d_{\min}, d_{\max})$, que s'aplica a la *mitjana* de cada clúster i no a cada sisme.

3.6 Elecció dels paràmetres

Paràmetres fixos de filtratge i densitat: $\varepsilon = 25$ km, $v_{\min} = 2$, $d_{\min} = 0$ km i $d_{\max} = 2{,}5$ km.

- **Finestra de profunditat** [0; 2,5) **km:** criteri físic. Una explosió nuclear soterrada és a menys d'uns pocs km de la superfície; els terratrèmols tectònics són, majoritàriament, molt més profunds. Triem un màxim de 2,5 km, i no una finestra estreta al voltant de 0 km, perquè volem que l'algorisme pugui detectar proves futures: el catàleg podria registrar-les a una profunditat que no sigui exactament 0 km, i no volem dependre que l'etiquetatge hi sigui perfecte.
- $\varepsilon = 25$ **km:** de l'ordre de la mida d'un polígon d'assaig. És el valor amb menys falsos positius dels provats (de 5 a 100 km, vegeu la validació): amb menys radi els terratrèmols superficials queden en grups solts i amb més radi els grups d'explosions es fonen amb terratrèmols més profunds. Aquí sí que es mira l'etiqueta.
- $v_{\min} = 2$**:** és el mínim perquè hi hagi soroll. Amb $v_{\min} = 1$ no hi ha soroll i es detecten més explosions (FN 28), però també molts més terratrèmols superficials aïllats (FP 115, $F_1 = 0{,}891$); amb $v_{\min} = 2$ els FP baixen a 57 i els FN pugen a 63 ($F_1 = 0{,}902$), perquè les explosions que estan soles en 25 km queden com a soroll (vegeu les limitacions).

Una exploració numèrica de la finestra i de ε maximitzant directament la mètrica F_1 es va avaluar, però no es fa servir per als paràmetres finals: el seu òptim, [0; 0,1) km, queda a la vora de la seva graella i aprofita que l'USGS registra amb profunditat exactament 0,0 km el 85 % de les explosions (521 de 614) i només 154 dels 297 513 esdeveniments que no són explosions nuclears. Això mesura com cataloga l'USGS i no la física. La taula compara finestres amb $\varepsilon = 25$ km. També hem provat de permetre profunditats negatives (per sobre de la superfície), amb la finestra $[-5; 2{,}5)$ km: no es guanya cap explosió, perquè l'única explosió amb profunditat negativa del catàleg és la Bomba Tsar, que està aïllada i és soroll, i els FP pugen de 57 a 150, perquè els clústers de terratrèmols i d'erupcions volcàniques d'altiplans i volcans tenen la mediana negativa.

Finestra (km)	TP	FP	FN	F_1
[0; 0,1) (la que triava l'optimitzador)	551	30	63	0,922
[0; 2,5) (la utilitzada)	551	57	63	0,902
[−5; 2,5) (amb profunditats negatives)	551	150	63	0,838
[0; 5)	552	259	62	0,775
[0; 10)	552	2 581	62	0,295

Taula 3: Efecte de la finestra de profunditat ($\varepsilon = 25$ km, $v_{\min} = 2$).

3.7 Validació de ε i estabilitat

Seguint l'esquema de validació del temari (silueta, colze i estabilitat), s'avalua ε amb $v_{\min} = 2$ i la finestra $[0;\, 2{,}5)$ km. Per a cada ε compta els clústers, calcula la silueta amb distància haversine sobre una mostra de 2 000 sismes (sense etiquetes) i els FP i FN (amb etiquetes).

L'estabilitat compara els clústers del catàleg complet amb els de cinc mostres aleatòries del 50 % mitjançant l'ARI.

ε (km)	Clústers	Silueta	FP	FN	ε (km)	Clústers	Silueta	FP	FN
5	29 451	−0,258	266	77	55	1 290	−0,541	130	289
10	14 166	−0,267	126	56	60	1 181	−0,517	129	289
15	7 938	−0,326	89	66	65	1 070	−0,389	136	288
20	5 140	−0,326	66	64	70	997	−0,352	137	288
25	3 759	−0,447	57	63	75	930	−0,411	137	288
30	2 824	−0,401	99	63	80	874	−0,415	137	288
35	2 282	−0,436	100	63	85	817	−0,466	139	286
40	1 941	−0,399	88	62	90	768	−0,461	136	292
45	1 680	−0,485	86	61	95	722	−0,461	139	291
50	1 464	−0,493	453	57	100	669	−0,408	136	293

Taula 4: Validació de ε de 5 en 5 km, de 5 a 100 km, amb $v_{\min} = 2$ i la finestra $[0;\, 2{,}5)$ km. Els clústers inclouen el soroll com un grup més.

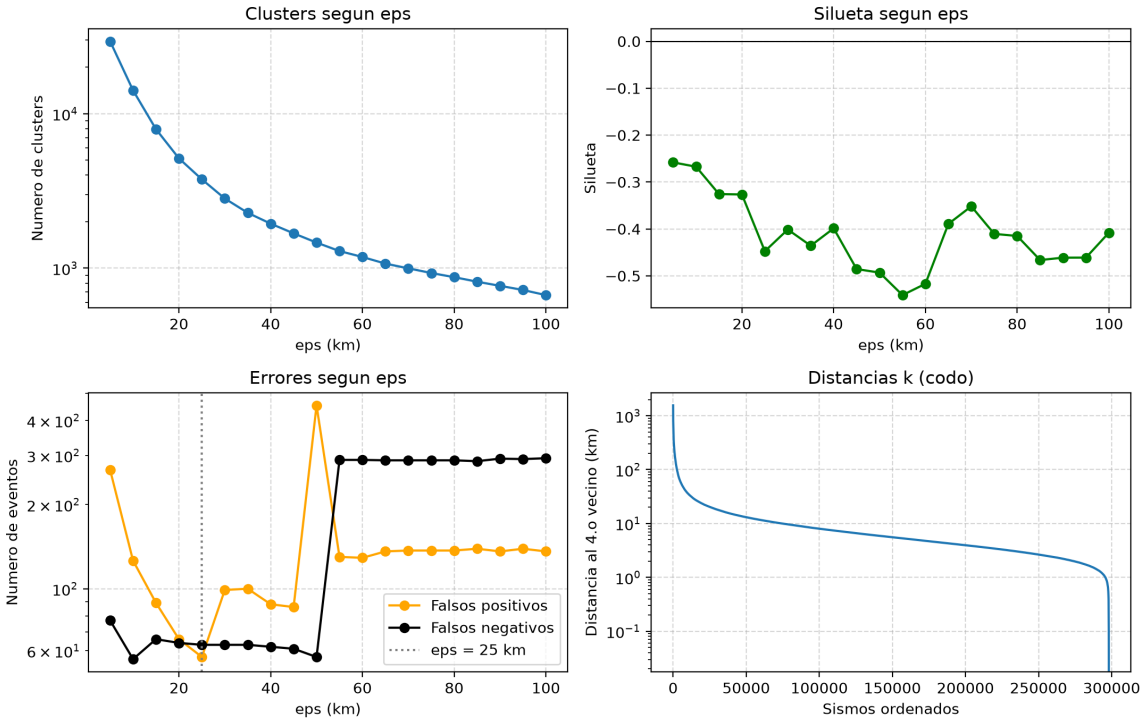


Figura 6: Validació de ε. (a) Nombre de clústers. (b) Silueta. (c) Falsos positius i falsos negatius; la línia de punts marca $\varepsilon = 25$ km. (d) Distància de cada sisme al seu 4t veí, ordenada (colze clàssic de DBSCAN). Els eixos verticals de (a) i (c) són logarítmics.

- **La silueta no serveix per triar ε (panell b).** La silueta [9] mesura si els grups són compactes i estan ben separats. Aquí és negativa per a tots els valors de ε (entre $-0{,}26$ i $-0{,}54$) i no té cap màxim ni cap tendència, així que no ens diu quin ε és millor. El motiu és que DBSCAN uneix els sismes en cadenes llargues, com les d'una falla, i aquests grups no són compactes. El gràfic de distàncies al 4t veí (panell d) tampoc no té un colze clar.

- **Els errors sí que ajuden a triar-lo (panell c).** Amb ε petit (5–20 km) hi ha molts falsos positius (de 266 a 66), perquè molts terratrèmols superficials formen grups petits propis. Els FP tenen el mínim, 57, a $\varepsilon = 25$ km, i els FN es mantenen entre 56 i 66 per a tot $\varepsilon \leq 50$ km. A 50 km els FP pugen de sobte a 453 (és probable que un grup superficial gran n'absorbeixi molts d'altres) i a partir de 55 km els FN salten d'uns 60 a uns 290 i s'hi queden: els grups d'explosions es fonen amb grups de terratrèmols més profunds i la seva mediana deixa de ser superficial. Per això triem $\varepsilon = 25$ km: és on hi ha menys FP sense perdre explosions. Aquí sí que es mira l'etiqueta.
- **Estabilitat.** L'ARI [10] val 1 si dues particions coincideixen i 0 si s'assemblen com dues a l'atzar. Comparem el clustering de tot el catàleg amb el d'una mostra aleatòria del 50 % (5 llavors, $\varepsilon = 25$ km): val entre 0,54 i 0,64. És moderat, perquè en treure sismes es trenquen cadenes de DBSCAN.

3.8 Resultats

Amb els paràmetres fixos: 551 encerts, 57 FP i 63 FN, és a dir, precisió del 90,6 %, recall del 89,7 % i $F_1 = 0{,}902$.

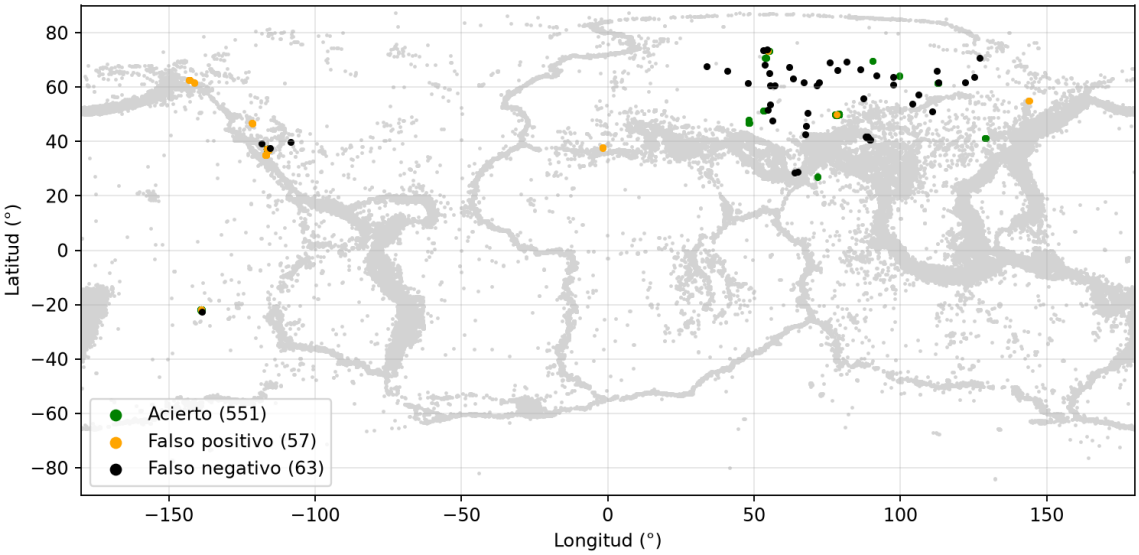


Figura 7: Resultat final: encerts (verd), falsos positius (taronja) i falsos negatius (negre).

3.9 Què hi ha darrere de cada clúster

DBSCAN no en sap res, d'història, però els clústers que troba són els polígons d'assaig de la Guerra Freda. De les 614 explosions, 574 cauen en 19 clústers i 40 queden com a soroll (sismes aïllats); la taula mostra els clústers més grans, amb el lloc que dona el mateix catàleg de l'USGS.

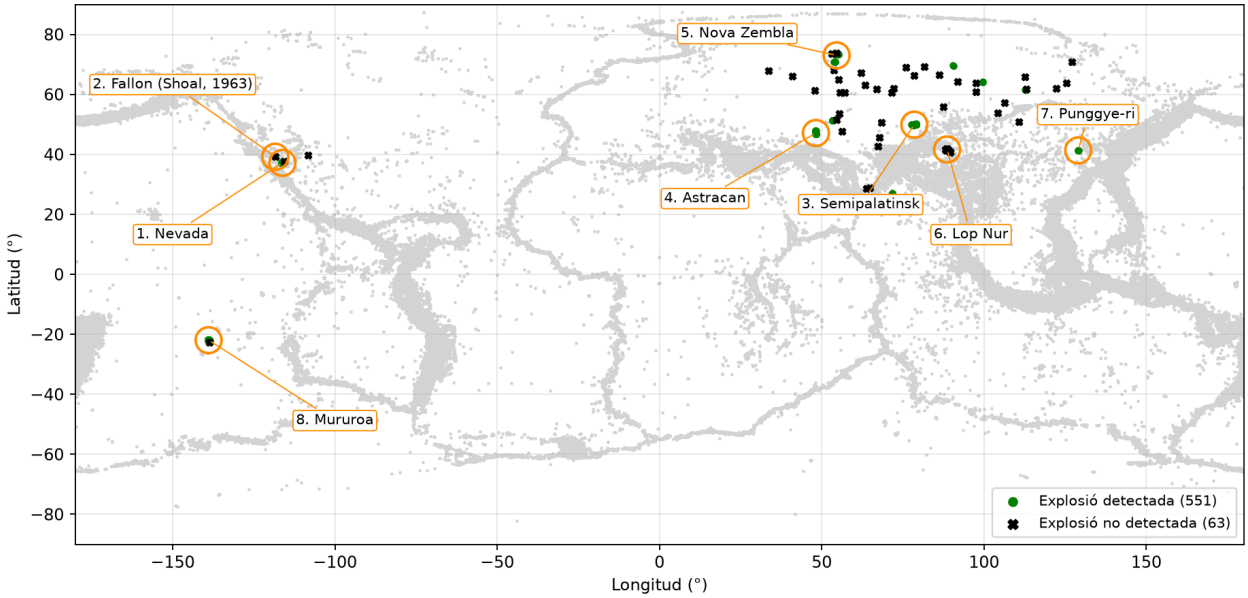


Figura 8: Les explosions nuclears del catàleg sobre el mapa de tots els terratrèmols (gris). Els cercles taronja marquen els polígons d'assaig i els clústers de DBSCAN dels quals parlen els punts següents. En verd, les explosions que es detecten (551); amb una creu negra, les que no (63): les de Lop Nur, la Bomba Tsar, l'assaig de Fallon i les explosions aïllades de Rússia i del Kazakhstan, que queden com a soroll.

Polígon	Anys	Explosions	Esdeveniments	mitjana (km)	Detectat?
Nevada (EUA)	1962–1992	230	256	0,0	Sí
Semipalatinsk, Balapan	1973–1989	92	92	0,0	Sí
Semipalatinsk, Degelen	1973–1989	86	87	0,0	Sí
Mururoa (Polinèsia Francesa)	1977–1996	74	76	0,0	Sí
Nova Zembla, Matotxkin Xar	1973–1990	20	21	0,0	Sí
Lop Nur (Xina)	1976–1996	18	47	15,7	No
Astracan (Rússia)	1980–1984	15	15	0,0	Sí
Punggye-ri (Corea del Nord)	2009–2017	5	5	0,0	Sí

Taula 5: Clústers de DBSCAN amb més explosions ($\varepsilon = 25$ km, $v_{\min} = 2$).

- **Nevada.** És el polígon on els Estats Units van fer la majoria dels seus assajos: 928 (100 atmosfèrics i 828 subterranis) segons la llista oficial del Departament d'Energia [6]; des del juliol de 1962 tots van ser subterranis. Al catàleg ($M \geq 4{,}5$) en queden 230, tan junts que DBSCAN els encadena en un únic clúster. També és el que aporta més falsos positius: els 26 esdeveniments del clúster que no són explosions nuclears (16 terratrèmols, 6 `explosion`, 3 esfondraments i 1 voladura) es marquen amb ell. Després d'un assaig subterrani, el sostre de la cavitat es pot enfonsar i aquest esfondrament genera el seu propi senyal sísmic, de tipus implosiu [16]; alguns d'aquests esdeveniments podrien ser-ho, o bé proves que l'USGS va registrar amb una altra etiqueta.
- **Semipalatinsk.** Al polígon soviètic del Kazakhstan s'hi van fer 456 explosions nuclears fins al 1989 [12]. Apareix partit en dos clústers separats per uns 60 km: Balapan, amb assajos en pous verticals, i el massís de Degelen, amb assajos en galeries. Són 178 explosions amb mitjana de profunditat 0 i gairebé cap terratrèmol al voltant: el cas més fàcil.
- **Mururoa.** França va fer 147 assajos subterranis entre 1975 i 1996, 137 a Mururoa i 10 a Fangataufa [13]. Lluny de qualsevol zona sísmica, el clúster de Mururoa conté 74 explosions i només 2 esdeveniments més.

- **Nova Zembla.** L'arxipèlag àrtic rus dona dos clústers petits: Matotxkin Xar, la zona central d'assajos subterranis en galeries, i Txernaia Guba, al sud. Més al nord, sobre la península de Sukhoi Nos, va esclatar el 30 d'octubre de 1961 la *Bomba Tsar*, d'uns 50 Mt, l'assaig més gran de la història [12]. Va ser una explosió aèria a uns 4 km d'altura i l'USGS la registra a -4 km, per sobre de la superfície: queda fora de la finestra $[0; 2{,}5)$ i, a més, està sola: és un dels 63 falsos negatius.
- **Lop Nur.** La Xina hi va fer els seus 45 assajos entre 1964 i 1996 [12], al costat del Tian Shan, una serralada amb molta sismicitat natural. És la gran fallada del mètode: les 18 explosions del clúster cauen al costat de 29 terratrèmols, amb mitjana de 24,5 km, i diverses explosions figuren a 33 km, una profunditat fixa que el catàleg feia servir quan no la podia resoldre. La mitjana del clúster puja a 15,7 km i es perd tot el grup: són 18 dels 63 FN. Dels 63, 10 tenen aquesta profunditat de 33 km.
- **Astracan i les explosions civils de Sibèria.** Les 15 d'Astracan (1980–1984), del programa soviètic d'explosions nuclears amb finalitats civils, van crear cavitats en doms de sal per emmagatzemar gas i formen un clúster petit que es detecta. Moltes altres explosions civils de Rússia i del Kazakhstan, en canvi, van ser assajos aïllats a centenars de quilòmetres de qualsevol altre: amb $v_{\min} = 2$ queden com a soroll, i són 40 dels 63 FN.
- **Punggye-ri.** Els cinc assajos nord-coreans amb $M \geq 4{,}5$ (2009–2017); el del 2006 va tenir una magnitud inferior i queda per sota del tall. El del 3 de setembre de 2017, de magnitud 6,3, és l'explosió més gran del segle XXI al catàleg. Uns 8,5 minuts després, el sostre de la cavitat es va enfonsar i va produir un segon esdeveniment de magnitud propera a 4 [14], que no entra al nostre catàleg per magnitud.
- **Un assaig amagat entre terratrèmols.** El 26 d'octubre de 1963, els Estats Units van fer l'assaig *Shoal*, de 12 kt, en granit a prop de Fallon (Nevada), lluny del polígon [6]. Formava part del programa Vela Uniform, que estudiava com detectar assajos subterranis, i es va fer en una zona amb terratrèmols reals: la seqüència del 1954 de Rainbow Mountain, Fairview Peak i Dixie Valley [15]. DBSCAN l'agrupa amb aquests terratrèmols i la mitjana deixa de ser superficial: el mètode falla just on l'explosió s'assembla a la sismicitat natural.

Limitacions i honestedat del resultat.

- **Les explosions aïllades es perden:** amb $v_{\min} = 2$, un sisme sol en un radi de 25 km és soroll. Això treu molts terratrèmols superficials (els FP baixen de 115 a 57), però també 40 explosions que van ser assajos aïllats. Amb $v_{\min} = 1$ no es perd cap per aquest motiu (FN 28), però el F_1 és menor (0,891). No hi ha una elecció que guanyi en tot: és un compromís entre precisió i recall.
- **Enfocament híbrid, no purament no supervisat:** DBSCAN agrupa sense etiquetes i la finestra de profunditat és un criteri físic previ, però ε s'ha triat mirant l'F_1 contra l'etiqueta entre uns pocs valors, perquè ni la silueta ni el colze no el determinen (vegeu la validació).
- **Generalització:** no hi ha cap subconjunt de prova separat: s'ajusta i s'avalua en el mateix catàleg.
- **Convenció del catàleg:** el 85 % de les explosions figura amb profunditat exactament 0,0 km. Una finestra més estreta, $[0; 0{,}1)$, donaria $F_1 = 0{,}922$ però mesuraria aquesta convenció de l'USGS i no la física.
- **Falsos positius:** terratrèmols molt superficials (anys 80 a Washington, Califòrnia i Alaska) i altres esdeveniments no sísmics. Dels 57 FP, 14 són d'un altre tipus: 10 `explosion`, 3 esfondraments de mina i 1 voladura de pedrera; cap de les 71 erupcions volcàniques no es marca. Si es descartessin els altres 100 esdeveniments no sísmics (només terratrèmols i explosions

nuclears), serien 43 FP i $F_1 = 0{,}912$. Algunes proves oficials de Nevada figuren a l'USGS com a `earthquake`; aquest error és de l'etiqueta, no del mètode.

- **Biaix d'època:** no es fan servir l'any ni el nombre d'estacions com a variables, perquè delaten l'època del catàleg i no la física.

3.10 Conclusions

- Un clustering espacial sense etiquetes, combinat amb la profunditat mitjana de cada grup, recupera el 90 % de les explosions del catàleg ($F_1 = 0{,}902$) amb 57 falsos positius entre gairebé 300 000 esdeveniments.
- El senyal útil és doble i físic: repetició als mateixos polígons d'assaig i profunditat gairebé nul · la.
- Línies de millora: triar ε en un subconjunt i avaluar-lo en un altre; afegir la magnitud i la forma d'ona com a variables; i fer servir la llista oficial DOE/NV-209 [6] en lloc de l'etiqueta de l'USGS per a les proves de Nevada.

4 Problema de Matías: terratrèmols, patrons i anomalies amb K-Means

4.1 Plantejament del problema

4.1.1 Context i interès

Els serveis sismològics registren milers d'esdeveniments al mes, la gran majoria de magnitud petita; revisar-los un a un és inviable. Calen procediments automàtics que (a) els organitzin en grups amb propietats semblants, (b) assenyalin els casos excepcionals que mereixen l'atenció d'un sismòleg i (c) ajudin a detectar si un grup reflecteix la física del terratrèmol o simplement com es mesura (cobertura de les xarxes). El problema connecta amb el tòpic de l'exposició, l'*aprenentatge no supervisat* (clustering i detecció d'anomalies): no hi ha etiquetes "correctes", de manera que la qualitat s'ha de provar amb criteris interns i contrastos entre mètodes.

4.1.2 Objectius mesurables

O1 Carregar i netejar el catàleg conservant el 100 % de les files amb magnitud, profunditat, latitud i longitud vàlides.

O2 Particionar els esdeveniments en $K = 3$ grups, caracteritzar-los (mida, magnitud, profunditat, regió) i assolir una silueta mitjana $\bar{s} > 0{,}3$ (estructura moderada [33]).

O3 Identificar els 5 esdeveniments més anòmals i interpretar-ne l'origen.

O4 Avaluar l'estabilitat del clustering respecte a la llavor aleatòria (objectiu: ARI $\geq 0{,}95$) i el cost computacional (objectiu: < 1 s per fase).

O5 Contrastar l'elecció de K i la llista d'anomalies amb alternatives (altres K, altres k, Isolation Forest, LOF).

4.1.3 Abast i supòsits

S'usa un únic fitxer (`earthquakes.csv`, format USGS ComCat [5]) i quatre variables numèriques: magnitud, profunditat (km), latitud i longitud. *Supòsits:* (i) la distància euclidiana sobre variables estandarditzades és una mesura de semblança admissible; (ii) $K = 3$ és fix i es contrasta a posteriori; (iii) latitud i longitud es tracten com a variables lineals tot i que la longitud és circular (discutit a la Secció 4.5). *Fora d'abast:* predicció sísmica, mecanisme focal i estimació de risc.

4.2 Fonamentació teòrica

4.2.1 Les dades sísmiques

Un esdeveniment s'identifica per la seva localització (latitud, longitud, profunditat de l'hipocentre) i la seva magnitud, una mesura logarítmica de l'energia alliberada. La magnitud de moment M_w [24] és la més consistent físicament, però els catàlegs barregen escales (`ml`, `md`, `mb`, `mww`...) segons la xarxa i la mida de l'esdeveniment; en aquest fitxer predominen `ml` (6 668), `md` (2 468) i `mb` (889). La distribució de magnituds segueix aproximadament la llei de Gutenberg–Richter [25], $\log_{10} N = a - bM$: hi ha moltes magnituds baixes i molt poques d'altes, la qual cosa condiciona tant el clustering com la detecció d'anomalies.

4.2.2 Normalització z-score

Com que la profunditat (0–665 km) té una escala molt superior a la magnitud ($-1{,}3$–$7{,}7$), una distància sense escalar estaria dominada per la profunditat. Cada variable j es transforma en

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \qquad \mu_j = \frac{1}{n}\sum_i x_{ij}, \quad \sigma_j = \sqrt{\frac{1}{n}\sum_i (x_{ij} - \mu_j)^2}, \tag{5}$$

de manera que totes tenen mitjana 0 i desviació 1. Si $\sigma_j = 0$ es fixa $\sigma_j = 1$ per evitar una divisió per zero.

4.2.3 K-Means (algorisme de Lloyd)

K-Means [26, 27] cerca K centroides $\mathbf{c}_1, \ldots, \mathbf{c}_K$ que minimitzen la inercia

$$J = \sum_{i=1}^{n} \min_{k} \|\mathbf{z}_i - \mathbf{c}_k\|^2, \tag{6}$$

iterant dues passes: assignació de cada punt al centroide més proper i actualització de cada centroide com a mitjana del seu grup. Cada iteració costa $O(nKd)$, però només garanteix un mínim local, per la qual cosa el resultat depnén de la inicialització (existeix `k-means++` [28] per millorar-la). Com a alternatives: DBSCAN (no requereix K i detecta soroll, però exigeix triar ε i densitat), models de mixtura gaussiana (clústers el · líptics i assignació suau) i el clúster jeràrquic ($O(n^2)$ en memòria).

4.2.4 Detecció d'anomalies per distància als k veïns

Es defineix la puntuació d'anomalia d'un punt com la mitjana de les distàncies als seus k veïns més propers [29]:

$$s(\mathbf{z}) = \frac{1}{k} \sum_{m=1}^{k} d(\mathbf{z}, \mathbf{z}_{(m)}). \tag{7}$$

Els punts en regions poc denses tenen s alt. És una tècnica simple i interpretable, però $O(n^2)$ i sensible a k i a l'escala. Alternatives: LOF (compara densitats locals), Isolation Forest i mètodes de reconstrucció [32].

4.2.5 Mètriques de validació

El *coeficient de silueta* [9] d'un punt és $s_i = (b_i - a_i)/\max(a_i, b_i)$, on a_i és la distància mitjana al seu clúster i b_i la distància mitjana al clúster alternatiu més proper; val entre -1 i 1. L'*índex de Rand* compara dues particions parella a parella (1 = idèntiques) i s'usa per mesurar l'estabilitat entre llavors.

4.3 Metodologia i solució proposada

4.3.1 Visió general i estructura del codi

La solució consta de només dos scripts (Figura 9). `presentacio_MATIAS.py` conté les funcions del projecte (càrrega, normalització, K-Means, anomalies i gràfic), cadascuna amb una única responsabilitat, docstring i paràmetres en lloc de valors fixos, i el pipeline principal que les encadena. `validacio_MATIAS.py` *importa* aquestes funcions i hi afegeix l'avaluació de K i de l'estabilitat, l'anàlisi complementària (Isolation Forest, LOF, sensibilitat a k), els gràfics de validació i les proves automàtiques; així la lògica (primer fitxer) queda separada de la validació i les proves (segon fitxer). S'usen `pandas` [36], `scikit-learn` [11] i `matplotlib` [37] en lloc d'implementacions pròpies, per fiabilitat i velocitat.

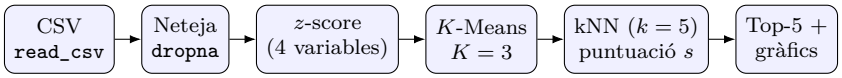


Figura 9: Fases de `presentacio_MATIAS.py`, cada una implementada per una funció del mateix fitxer. `validacio_MATIAS.py` reutilitza les fases 1–3 i afegeix l'avaluació de K, l'estabilitat i el mapa.

4.3.2 Parts del codi, funcions i justificació

Funció	Paper i justificació
`carrega_dades(path)`	`pd.read_csv` i `dropna(subset=features)`: elimina només les files amb NaN a les 4 variables usades. Comprova que hi ha les columnes i que queda alguna fila (`ValueError`); `FileNotFoundError` si el fitxer no existeix.
`normalitza_zscore(df)`	z-score vectoritzat per columnes (`(X-X.mean())/X.std()`); si una columna és constant, fixa $\sigma = 1$ per evitar divisions per zero. Preferit a min–max perquè els extrems (profunditat > 600 km, $M > 7$) comprimirien la resta.
`entrena_kmeans(X,k)`	`KMeans(random_state=42, n_init=10)`: `k-means++` amb 10 reinicis i es queda la menor inèrcia (evita mínims locals). Valida que $1 \leq k \leq n$.
`resum_clusters(df)`	`groupby("cluster").agg`: nombre, magnitud i profunditat mitjanes per clúster.
`puntuacio_anomalia(X,k)`	`NearestNeighbors(n_neighbors=k+1).kneighbors`: distàncies exactes; se n'ignora la columna 0 (el propi punt) i es fa la mitjana dels k restants $\Rightarrow$ puntuació s. `top_anomalies` tria les n més altes amb `nlargest`.
`avalua_k`, `avalua_estabilitat` (a `validacio_MATIAS.py`)	Inèrcia, `silhouette_score` (mostra de 2 000 punts i dades senceres) i `davies_bouldin_score` per a cada K; `adjusted_rand_score` entre la llavor 42 i les llavors 1–5.
`contrast_detectors`, `sensibilitat_k`, `experiment_mag_prof` (a `validacio_MATIAS.py`)	Isolation Forest i LOF de `scikit-learn` amb correlació de Spearman; coincidència del top-5 en variar k; K-Means només amb magnitud i profunditat.
`figura_clusters`, `figura_mapa`, `figura_k`, `figura_anomalies`	Només dibuixen (`scatter`, eix de profunditat invertit perquè creix cap avall, anomalies com a quadrats vermells) i desen el PNG; no calculen res.

Taula 6: Elements del codi i la seva funció.

El nucli del càlcul de la puntuació d'anomalia $s(\mathbf{z})$ s'implementa de forma exacta mitjançant `NearestNeighbors` amb $k + 1$ veïns (ignorant la distància zero al propi punt i calculant la mitjana de les distàncies als k restants).

4.3.3 Decisions de disseny justificades

$K = 3$: hipòtesi de tres règims (petit i superficial, intermedi, gran i profund); contrastada amb $K = 2, \ldots, 8$ (Taula 8). **Distància exacta als veïns** (no mostrejada): amb $n \approx 10^4$ costa $< 0{,}1$ s, per tant no cal aproximar. $k = 5$: valor petit que detecta regions molt buides; se'n comprova la sensibilitat (Secció 4.4.4). **Mateixa normalització** a ambdós scripts perquè els resultats siguin comparables.

4.3.4 Proves automàtiques

`validacio_MATIAS.py` conté **35 proves** (`unittest`, també detectades per `pytest`) que s'executen automàticament abans de la validació en ≈ 1 s i passen totes: *casos normals* (el z-score deixa mitjana 0 i desviació 1; K-Means separa tres grups sintètics ben definits; l'outlier obvi obté la puntuació més alta; la puntuació val exactament 1,5 en un exemple calculat a mà); *casos límit* (columna constant, punts duplicats, $K = 1$, `sample_size` superior a n, NaN en columnes no usades, demanar més anomalies de les que hi ha); *casos erronis* (fitxer inexistent, columna que falta, tot NaN, k no vàlid, K fora de rang); la generació de les figures; i una *prova d'integració* que comprova que amb `earthquakes.csv` es reprodueixen els resultats d'aquest informe (10 174 files, mides 5 721/3 414/1 039, inèrcia 19 486,7, primera anomalia i profunditats > 280 km); també es proven les funcions de l'anàlisi complementària.

4.4 Resultats i anàlisi

4.4.1 Neteja i descripció de les dades

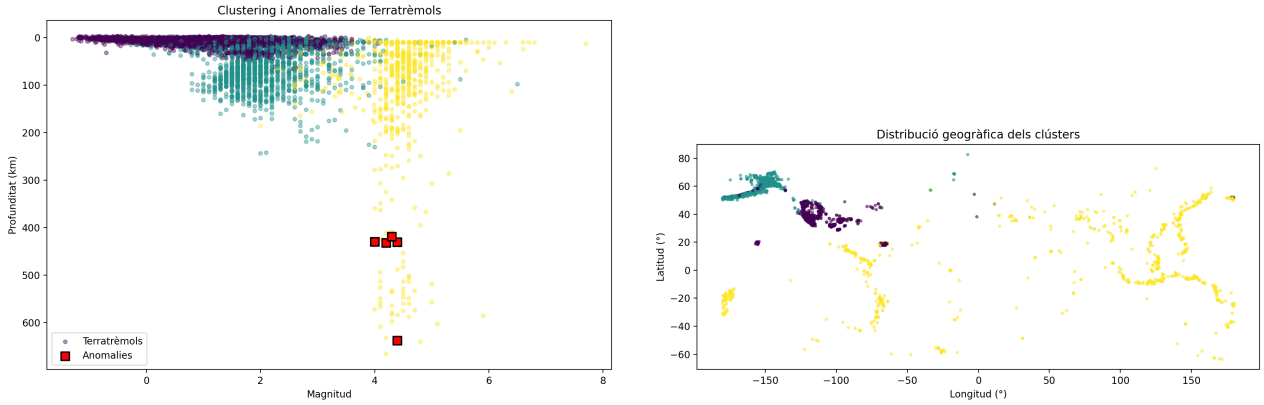
Les 10 174 files són vàlides (cap NaN a les 4 variables; O1 complert). Magnitud: $-1{,}29$ a 7,70 (mitjana 1,71); profunditat: $-3{,}4$ a 665 km (mitjana 22,9, mediana 8,1; 351 valors negatius per elevació del

terreny); data entre 15/09 i 15/10/2026. Hi ha 9 938 terratrèmols i 236 esdeveniments d'altres tipus que el programa **no filtra** (132 voladures de pedrera, 73 explosions, 27 *ice quakes*, 4 altres). Xarxes dominants: `ak` (2 446), `nc` (1 538), `ci` (1 326), `us` (1 215), `tx` (837), `av` (798). Les escales de magnitud es barregen (`ml` 6 668, `md` 2 468, `mb` 889, `mww` 102).

4.4.2 Clústers trobats

Clúster	n	$\bar{M}$	$\bar{p}$ (km)	p_{max}	$\bar{\varphi}$	$\bar{\lambda}$	Xarxes dominants
0	3 414	1,52	33,0	243,6	58,9	−154,8	`ak` (2 425), `av` (781): Alaska
1	5 721	1,31	7,7	88,2	33,8	−114,4	`nc`, `ci`, `tx`, `hv`: Califòrnia, Texas, Hawaii
2	1 039	4,50	73,0	665,1	5,9	49,4	`us` (985): global, $M \gtrsim 4$

Taula 7: Perfil dels clústers ($K = 3$). $\bar{M}$: magnitud mitjana; $\bar{p}$, p_{max}: profunditat mitjana i màxima; $\bar{\varphi}, \bar{\lambda}$: centre geogràfic.



(a) Magnitud vs. profunditat (eix invertit).

(b) Distribució geogràfica.

Figura 10: Clústers de K-Means (mateixos colors a ambdós panells: lila = 0, verd = 1, groc = 2). A (a), els quadrats vermells són les 5 anomalies.

Interpretació crítica. El clúster 1 agrupa esdeveniments petits i superficials de xarxes regionals de Califòrnia, Texas i Hawaii; el 0, esdeveniments petits i de profunditat moderada a Alaska (zona de subducció, xarxa molt sensible); el 2, la sismicitat global registrada per l'USGS, que només inclou $M \gtrsim 4$ (magnitud mínima 1,27, mitjana 4,50). El mapa (Fig. 10b) mostra que **els clústers se separen per regió**: latitud i longitud, dues de les quatre variables, tenen molta variació i dominen la distància. El clúster 2 és "gran" sobretot per *cobertura del catàleg* (una xarxa regional detecta $M < 1$, la global no), no per la física. Un indici addicional de la limitació de tractar la longitud com a lineal: els esdeveniments de les Aleutianes a $\lambda \approx +179°$ cauen al clúster 2 (groc) tot i ser veïns dels de $\lambda \approx -179°$ (lila).

4.4.3 Validació: elecció de K i qualitat

K	2	3	4	5	6	7	8
Inèrcia J	24 346	19 487	14 659	12 256	10 184	8 780	7 623
Silueta (mostra 2 000)	0,640	0,411	0,417	0,427	0,334	0,358	0,358
Silueta (totes les dades)	0,654	0,402	0,414	0,422	0,338	0,360	0,360
Davies–Bouldin	0,925	1,042	0,905	0,989	0,948	0,906	0,884

Taula 8: Inèrcia i índexs de qualitat per a $K = 2, \ldots, 8$ (llavor 42, `n_init=10`).

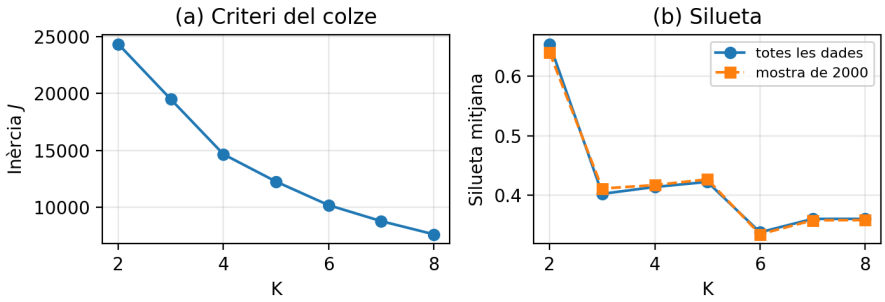


Figura 11: (a) Inèrcia en funció de K: no hi ha un colze clar. (b) Silueta mitjana: el màxim és a $K = 2$.

Amb $K = 3$ la silueta és 0,402 (totes les dades; la mostra de 2 000 en dona 0,411, diferència de 0,009, per tant el mostreig és fiable): O2 complert. Per clúster és molt desigual: 0,530 (clúster 1, compacte), 0,256 (clúster 0) i només 0,177 (clúster 2, molt heterogeni: cobreix tot el planeta). $K = 2$ **obté la millor silueta (**0,654**)**, i en aquest cas separa essencialment el clúster global (1 039 + 18 esdeveniments) de tota la resta regional (matriu de contingència: 3 413 + 5 704 regionals queden junts). La corba d'inèrcia no té colze i Davies–Bouldin no afavoreix cap K de manera clara. Per tant $K = 3$ és una elecció defensable per interpretabilitat (separa Alaska de Califòrnia), però *no és òptima segons les mètriques*.

Estabilitat. Amb les llavors 1–5, l'ARI respecte a la llavor 42 és 1,0000 en els 5 casos i la inèrcia és 19 486,7 a totes (O4 complert). Això millora la versió anterior amb inicialització aleatòria simple, que queia a un mínim local pitjor ($J = 19\,639$, ARI 0,89): `k-means++` amb `n_init=10` resol el problema.

Experiment complementari: només magnitud i profunditat. Per comprovar l'efecte de la geografia, es repeteix $K = 3$ sense latitud ni longitud: la silueta puja a 0,568 i la partició canvia molt (ARI 0,30 respecte a la base), obtenint tres grups *físics*: 8 042 esdeveniments petits i superficials ($\bar{M} = 1{,}22$, $\bar{p} = 11{,}5$ km), 2 067 moderats ($\bar{M} = 3{,}53$, $\bar{p} = 53$ km) i 65 *profunds* ($\bar{p} = 478$ km). Confirma que la tipologia física només apareix quan les variables geogràfiques no dominen la distància.

4.4.4 Anomalies

#	Esdeveniment (`place`)	M	Prof. (km)	Coordenades	s
1	236 km ESE of Makarov, Russia	4,1	493,9	(48,11, 145,87)	2,67
2	Vanuatu region	4,2	665,1	(−14,57, 170,40)	2,36
3	81 km NNW of Malfa, Italy	4,9	367,1	(39,21, 14,35)	1,98
4	43 km SSE of Otorohanga, New Zealand	5,3	286,0	(−38,55, 175,38)	1,85
5	47 km SSE of Irpa Irpa, Bolivia	4,0	359,3	(−18,07, −66,03)	1,84

Taula 9: Cinc esdeveniments amb major puntuació s ($k = 5$). Tots són terratrèmols (`type = earthquake`), de la xarxa `us` i del clúster 2.

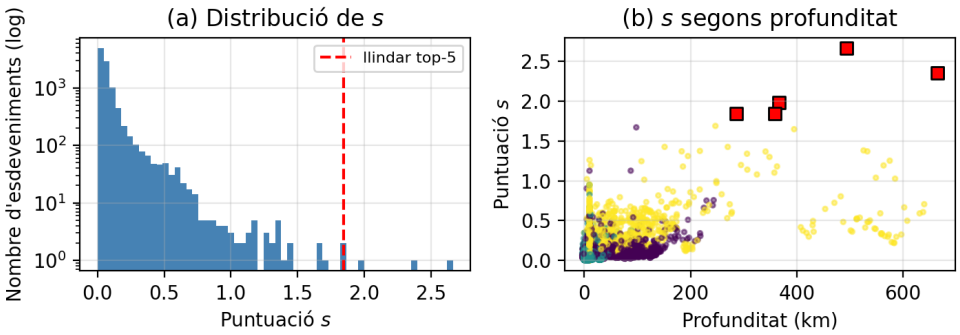


Figura 12: (a) Distribució de s (escala log): cua molt llarga; mediana 0,047, percentil 99 = 0,65, màxim 2,67. (b) s segons la profunditat; quadrats vermells = top-5.

Interpretació. Les cinc anomalies són terratrèmols **profunds (286–665 km)** de zones de subducció amb sismicitat profunda coneguda [35] (mar d'Okhotsk, Vanuatu, mar Tirrè, Nova Zelanda, Bolívia). No destaquen per energia ($M \approx 4$–5) sinó per *raresa multivariant*: profunditat molt per sobre de la mediana del catàleg (8,1 km) i ubicació aïllada. El terratrèmol més gran ($M = 7{,}7$, Panamà, 12,6 km) té $s = 1{,}20$ i només és el #23: el mètode detecta raresa, no gravetat. Cap anomalia és una voladura o explosió. Entre els 50 primers, 18 dels 58 esdeveniments del catàleg amb profunditat > 300 km (mediana de profunditat del top-50: 217,6 km).

Sensibilitat a k i contrast amb altres mètodes.

Comparació amb el top-5 base ($k = 5$)	Coincidència top-5	Coincidència top-50	Spearman
kNN, $k = 3$ / $k = 10$ / $k = 20$	5/5 / 4/5 / 4/5	—	—
Isolation Forest (200 arbres)	0/5	10/50	0,61
LOF (20 veïns)	0/5	6/50	0,40

Taula 10: Robustesa de la llista d'anomalies.

La llista és molt estable respecte a k (4–5 de 5 coincidències), però **no coincideix amb altres detectors**: Isolation Forest destaca esdeveniments profunds de la regió de Fiji (519–640 km, $M = 4{,}8$–$5{,}9$) i LOF els de Panamà ($M = 6{,}6$ i $7{,}7$) i alguns esdeveniments aïllats d'Austràlia, Nova Zelanda i Utah. La correlació de rangs és moderada (0,61 i 0,40). No és una contradicció: cada mètode formalitza "anomalia" de manera diferent (aïllament, densitat relativa, distància als veïns); el kNN premia els esdeveniments *individualment aïllats*, mentre que, probablement, una zona profunda amb molts esdeveniments (Fiji) els fa semblar veïns entre si i en redueix la puntuació. Per això convé donar la llista kNN com a "candidats a revisió" i no com a veritat.

4.4.5 Eficiència

Execució en l'entorn de prova (Python 3.12.3, scikit-learn 1.8.0, pandas 3.0.2, $n = 10\,174$): `presentacio_MATIAS.py` triga $\approx$ 2,2 s en total (`KMeans` $\approx$ 0,05 s, kNN exacte $\approx$ 0,06 s), i `validacio_MATIAS.py` $\approx$ 3,2 s (inclou 7 valors de K, 5 llavors i la silueta). El cost del kNN exacte és $O(n^2)$ en el pitjor cas, però per a $n \sim 10^4$ és negligible (O4 complert); per a milions d'esdeveniments caldria un índex d'arbre (`algorithm="kd_tree"`) o aproximació.

4.5 Conclusions, limitacions i millores

Obj.	Resultat	Estat
O1	10 174/10 174 files conservades	Complert
O2	$K = 3$: 5 721/3 414/1 039; silueta 0,402 $>$ 0,3	Complert (grups geogràfics)
O3	Top-5: terratrèmols profunds (286–665 km) de zones de subducció	Complert
O4	ARI $= 1$ per a 5 llavors; fases $< 0{,}1$ s	Complert
O5	$K = 2$ té millor silueta; llista kNN estable en k però diferent d'IF i LOF	Parcial: validació interna

Taula 11: Compliment dels objectius.

Conclusions. (1) El pipeline és ràpid i reproduïble, i el clustering és perfectament estable amb `k-means++` i 10 inicialitzacions. (2) Els tres clústers separen *xarxes i regions*, no tipus de sisme: el clúster global és gran per cobertura del catàleg; només sense variables geogràfiques apareix un grup físic de terratrèmols profunds. (3) El detector kNN troba terratrèmols profunds i aïllats, geofísicament coherents, però la llista depèn del mètode, de manera que s'ha d'interpretar com a candidats a revisió.

Limitacions. (i) Latitud i longitud en graus euclidians distorsionen les distàncies reals i la longitud és circular. (ii) Barreja d'escales de magnitud i de 236 esdeveniments no sísmics. (iii) K fix; la silueta prefereix $K = 2$. (iv) Catàleg d'un sol mes i sense veritat de referència: la validació és interna. (v) Les proves verifiquen la correcció del codi i la reproducció de les xifres, però no la validesa científica de les conclusions (que depèn de la validació de la Secció 4.4).

Millores concretes. (1) Filtrar `type == "earthquake"`; (2) usar coordenades cartesianes 3D (o distància haversine) per resoldre la circularitat; (3) clustering només sobre magnitud i profunditat, o amb pesos per variable; (4) combinar kNN, LOF i Isolation Forest (consens de rangs); (5) afegir una interfície de línia d'ordres (`argparse`) per canviar K, k i el fitxer sense editar el codi i mesurar la cobertura de les proves; (6) ampliar a diversos mesos per provar la robustesa temporal.

4.6 Reproducibilitat

Entorn: Python 3.12.3, scikit-learn 1.8.0, pandas 3.0.2, matplotlib 3.10.8, NumPy 2.4.4, SciPy; versions fixades al `requirements.txt`. Instruccions al `README`. Fitxers: `presentacio_MATIAS.py` (Taules 7 i 9, Fig. 10a), `validacio_MATIAS.py` (Taules 8 i 10, estabilitat, Figs. 10b, 11 i 12, i les proves) i `earthquakes.csv` (dades d'exemple, mateix directori). Ordres: `python presentacio_MATIAS.py` i `python validacio_MATIAS.py` (executa primer les proves); només les proves: `python -m unittest -v validacio_MATIAS`. Totes les llavors són fixes (42), per tant la sortida és determinista amb les mateixes dades i versions.

5 Problema de Martí: expressió gènica i clustering jeràrquic (leucèmia ALL/AML)

Resum. Aquesta implementació aplica l'aprenentatge no supervisat al conjunt de dades de leucèmia de Golub et al. (72 pacients, 7.129 gens) per comprovar, primer, si és possible recuperar sense etiquetes la distinció entre leucèmia limfoblàstica aguda (ALL) i mieloide aguda (AML) i, segon, quins grups de gens mostren patrons d'expressió semblants. Després d'un preprocessament logarítmic i d'una selecció dels 500 gens més variables, s'agrupen els pacients amb clustering jeràrquic (tres tipus d'enllaç) i K-Means, i els gens amb clustering jeràrquic de distància de correlació. Els diagnòstics clínics s'usen només per validar els models. K-Means assoleix un ARI de 0,89 i l'enllaç *complete* de 0,79, mentre que el coeficient de Silhouette indica $k = 2$ com a nombre òptim de grups.

5.1 Plantejament del problema

Les cèl · lules fabriquen proteïnes a partir de la informació dels gens, i ho fan a través de l'ARN missatger (mRNA): com més activitat té un gen, més mRNA se'n detecta. Aquesta quantitat s'anomena *nivell d'expressió*. Tècniques com el microarray d'oligonucleòtids (usat a [7]) o la seqüenciació d'ARN la mesuren per a milers de gens alhora, de manera que cada pacient queda descrit per un vector amb els nivells d'expressió de tots els gens mesurats. Les leucèmies agudes limfoblàstica (ALL) i mieloide (AML) deriven de línies cel · lulars diferents de la sang i requereixen tractaments diferents; per això distingir-les bé és clínicament rellevant.

El problema és naturalment no supervisat per dos motius. Primer, no sabem a priori quins gens funcionen junts: els gens que s'expressen amb patrons semblants entre pacients (gens co-expressats) sovint estan regulats conjuntament o participen en processos biològics comuns [8], però aquesta informació no ve etiquetada. Segon, volem comprovar si l'estructura de les dades, per si sola, reprodueix el diagnòstic clínic sense haver-lo vist durant el modelatge. A més, es treballa amb alta dimensionalitat (7.129 gens per només 72 pacients), una situació on les distàncies són poc intuïtives i cal escollir amb cura la mètrica i el preprocessament.

Els objectius de la implementació són els següents:

1. Identificar les leucèmies ALL/AML sense etiquetes, tallant l'arbre o K-Means a $k = 2$, amb un ARI superior a 0,7.
2. Comparar tres criteris d'enllaç (*single*, *complete*, *average*) i K-Means, amb una mètrica interna (Silhouette) i una d'externa (ARI).
3. Identificar mòduls de gens co-expressats i triar-ne el nombre amb el coeficient de Silhouette.
4. Visualitzar conjuntament gens i pacients amb un mapa de calor (via dendrogrames).

Pel que fa a l'abast i els supòsits, s'usa un únic conjunt de dades, es treballa amb els 500 gens més variables, la distància és de correlació (o euclidiana), les etiquetes ALL/AML només s'usen després del clustering per validar, no s'elimina cap pacient i no s'interpreten biològicament els mòduls de gens.

Com a aportacions pròpies, el treball agrupa tant pacients com gens i els mostra junts, compara el mapa de calor brut amb el reordenat pels dendrogrames per veure què aporta el clustering, i corregeix un problema de preprocessament detectat en una primera versió (apartat de Metodologia).

5.2 Fonament teòric

Per comparar perfils d'expressió interessa la *forma* del patró i no la seva magnitud: dos gens que pugen i baixen igual entre pacients han de ser veïns encara que un tingui el doble d'amplitud. Per això s'usa la distància de correlació de Pearson, $d_r(u, v) = 1 - r(u, v)$, que val 0 si els perfils estan perfectament correlacionats i 2 si estan perfectament anticorrelacionats; combinada amb l'enllaç *average*, és l'opció clàssica en expressió gènica [8]. K-Means, en canvi, usa la distància euclidiana.

El clustering jeràrquic aglomeratiu parteix de cada element com a clúster propi i fusiona a cada pas els dos clústers més propers; el resultat és un arbre (dendrograma) que es pot tallar a l'altura desitjada per obtenir k grups. Els criteris d'enllaç difereixen en com mesuren la distància entre clústers:

- **Single:** distància mínima entre parells d'elements (sensible a punts aïllats i a l'efecte cadena).
- **Complete:** distància màxima entre parells; afavoreix clústers compactes.
- **Average:** distància mitjana entre tots els parells; equilibri entre els dos anteriors.

K-Means divideix les dades en k grups minimitzant la *inèrcia*, és a dir, la suma de quadrats de les distàncies de cada punt al centre del seu grup. Cal fixar k per endavant i el resultat depèn de la inicialització, per això es repeteix diverses vegades i es guarda la millor. El *mètode del colze* representa la inèrcia en funció de k i busca el punt on la millora deixa de ser apreciable.

Per validar sense etiquetes s'usa el *coeficient de Silhouette* [9], que mesura com de bé encaixa cada element i en el seu grup, $s(i) = \frac{b(i)-a(i)}{\max\{a(i),b(i)\}} \in [-1, 1]$, on $a(i)$ és la distància mitjana als altres elements del seu grup i $b(i)$ la del grup veí més proper; se'n tria el k de silueta mitjana màxima. Com a validació externa s'usa l'*Adjusted Rand Index* (ARI) [10], que compara dues particions comptant els parells d'elements que coincideixen i corregeix l'acord esperat per atzar: val 1 si són idèntiques, aproximadament 0 si equivalen a una partició aleatòria i pot ser lleugerament negatiu. Les fórmules completes són a la Secció 5.7.

Finalment, un *clustermap* mostra la matriu d'expressió com un mapa de calor amb files (gens) i columnes (pacients) reordenades segons els seus dendrogrames, de manera que els blocs de color revelen gens co-expressats en grups de pacients [8].

5.3 Metodologia

Dades. S'ha utilitzat el conjunt de Golub et al. [7], descarregat d'OpenML (ID 1104): l'expressió de 7.129 gens, mesurada amb microarrays Affymetrix, en 72 pacients (47 ALL i 25 AML), organitzada en una matriu $X \in \mathbb{R}^{7129\times72}$. Les etiquetes clíniques no intervenen en cap etapa del modelatge. La matriu en brut no té valors nuls, va de -28.400 a 71.369 i és molt asimètrica (mitjana 619,78, mitjana 120,00); els valors negatius provenen de la correcció del fons i no tenen sentit com a expressió.

Preprocessament. S'inspira en el de Golub et al. [7]. Primer, un retall de rang a [100, 16.000] (`np.clip`), que elimina els valors negatius i les fluctuacions per sota del límit de detecció i limita la saturació dels detectors. Després, la transformació $x' = \log_2(x+1)$, que redueix l'asimetria, estabilitza la variància i fa que les diferències es llegeixin com a canvis relatius d'expressió (*fold-change*); com que $x \geq 100$, el $+1$ és innecessari però inofensiu. Una primera versió retallava només a 0: concentrava més de 10^5 valors en un sol punt i feia aparèixer gens amb variàncies artificialment altes, que haurien dominat la selecció posterior. Finalment, es conserven els $N = 500$ gens de variància més alta, perquè els gens gairebé constants no informen sobre diferències entre pacients (selecció sense etiquetes), i cada gen s'estandarditza amb el z-score, $z = (x - \mu)/\sigma$ entre pacients. El resultat és una matriu $X_{\text{clean}} \in \mathbb{R}^{500\times72}$.

Clustering dels pacients. S'agrupen els 72 pacients, cadascun descrit pels seus 500 gens, amb distància de correlació i tres criteris d'enllaç (*single*, *complete* i *average*). Per a cada enllaç es talla l'arbre a $k = 2$ i es calcula l'ARI contra el diagnòstic. El dendrograma i el clustermap es fan amb *average*, que s'ha fixat des del principi (no pas mirant l'ARI) perquè és l'opció estàndard amb distància de correlació en expressió gènica [8]. Amb K-Means es fa servir $k = 2, \ldots, 8$, amb 10 inicialitzacions i llavor fixa; per a cada k es guarden la inèrcia i la silueta mitjana, i per a $k = 2$ l'ARI.

Mòduls de gens i mapes de calor. S'agrupen els 500 gens, cadascun descrit pels seus valors en els 72 pacients, amb distància de correlació i enllaç *average*. Per a $k = 2, \ldots, 10$ es talla l'arbre, es calcula la silueta amb la matriu de distàncies precalculada i es tria el k de silueta màxima, que defineix el mòdul de cada gen. Després es representa X_{clean} en dues versions: sense reordenar (ordre original

dels pacients i ordre de selecció dels gens) i reordenada pels dos dendrogrames (clustermap), amb barres de color pel diagnòstic i pel mòdul. Comparar-les mostra què aporta el clustering.

Implementació. El flux computacional s'ha desenvolupat en Python emprant NumPy i pandas per a les dades, SciPy per al clustering jeràrquic, scikit-learn [11] per a K-Means, la silueta i l'ARI, i Matplotlib i seaborn per a les visualitzacions. Totes les llavors aleatòries són fixes per garantir la reproductibilitat de les figures i resultats obtinguts.

5.4 Resultats i anàlisi

La Figura 13 mostra l'efecte del retall i del logaritme: la distribució original, molt asimètrica i amb valors negatius, queda acotada entre $\log_2(101) \approx 6{,}66$ i $\log_2(16001) \approx 13{,}97$. Els dos pics extrems corresponen als valors retallats (47,0 % al terra i 0,8 % al sostre), una limitació del retall perquè tots els gens poc expressats queden al mateix valor. El filtre per variància conserva els 500 gens amb variància $\geq 1{,}30$.

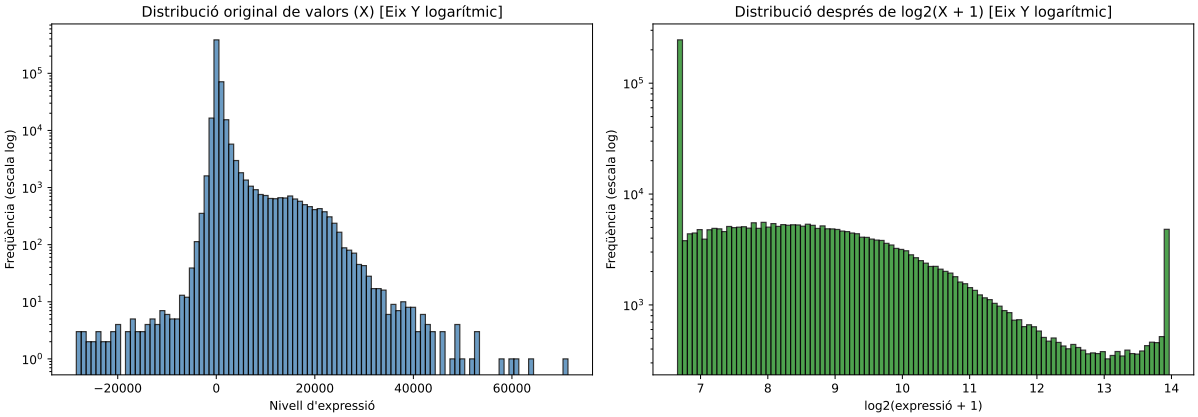


Figura 13: Distribució de les intensitats d'expressió abans (esquerra) i després (dreta) del retall a $[100, 16000]$ i de la transformació $\log_2(x+1)$. L'eix vertical és logarítmic.

La Taula 12 resumeix els quatre mètodes sobre els 72 pacients i la Figura 14 mostra el dendrograma de l'enllaç *average*.

Mètode	Distància	Mides dels 2 grups	ARI
Single	correlació	[71, 1]	−0,013
Complete	correlació	[29, 43]	0,787
Average	correlació	[31, 41]	0,690
K-Means	euclidiana	–	**0,890**

Taula 12: Comparació de mètodes per a $k = 2$ (mides reals: 47 ALL i 25 AML). En negreta, l'ARI màxim (K-Means).

- **Single** falla: separa un únic pacient i deixa la resta junta (ARI ≈ 0) per l'efecte cadena.
- **Complete** té el millor ARI entre els jeràrquics (0,787), per sobre de 0,7.
- **Average**, l'enllaç triat per al dendrograma i el clustermap, queda just per sota (0,690): l'enllaç condiciona el resultat.

Cap partició té mides 47/25, així que cap recupera exactament el diagnòstic; tanmateix, **K-Means** és la que s'hi acosta més (ARI 0,890).

Pel que fa a K-Means (Figura 15), la inèrcia baixa de manera contínua (de 30.821 a $k = 2$ fins a 22.841 a $k = 8$) i no mostra un colze clar, de manera que el mètode del colze no ajuda a triar k. La silueta, en canvi, és màxima a $k = 2$ (0,1352) i decreix fins a 0,0683 a $k = 8$, la qual cosa coincideix

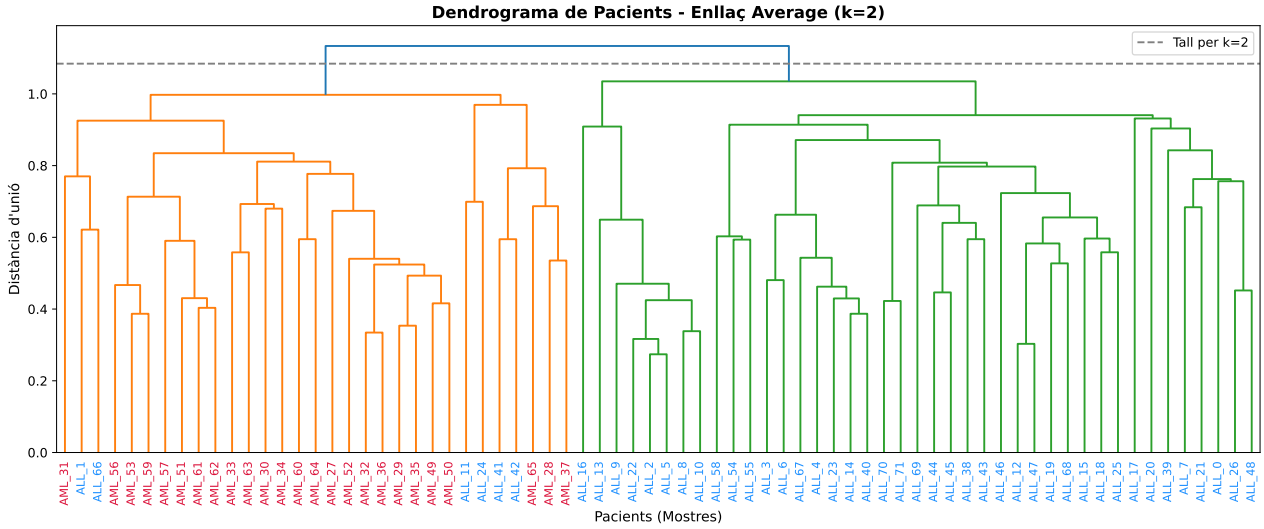


Figura 14: Dendrograma dels 72 pacients (enllaç *average*, distància de correlació). Les etiquetes són blaves per a ALL i vermelles per a AML; la línia grisa discontínua és el tall a $k = 2$.

amb els dos diagnòstics reals. Els valors són baixos (inferiors a 0,14): els grups són reconeixibles però no estan gaire separats en un espai de 500 dimensions.

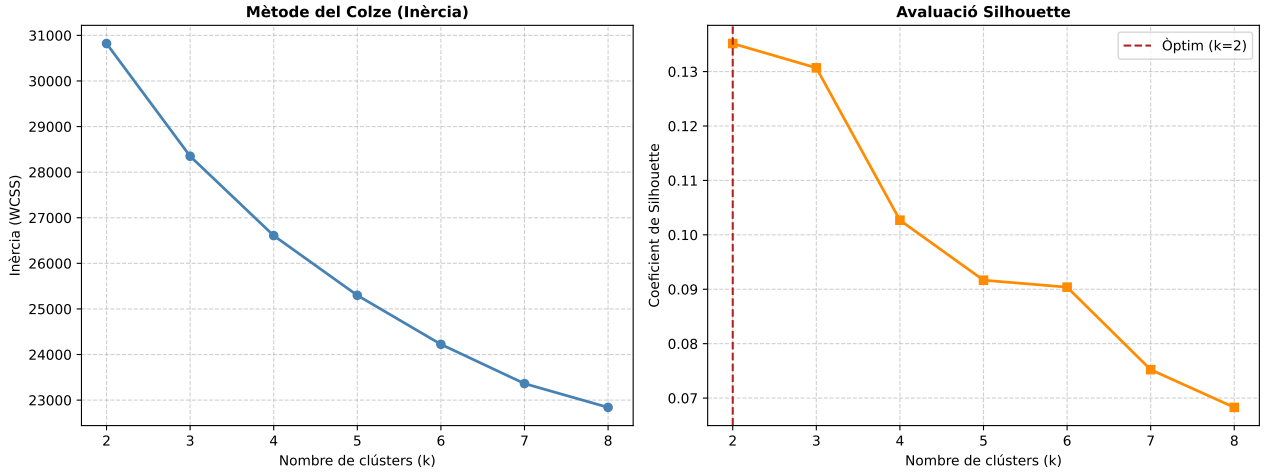


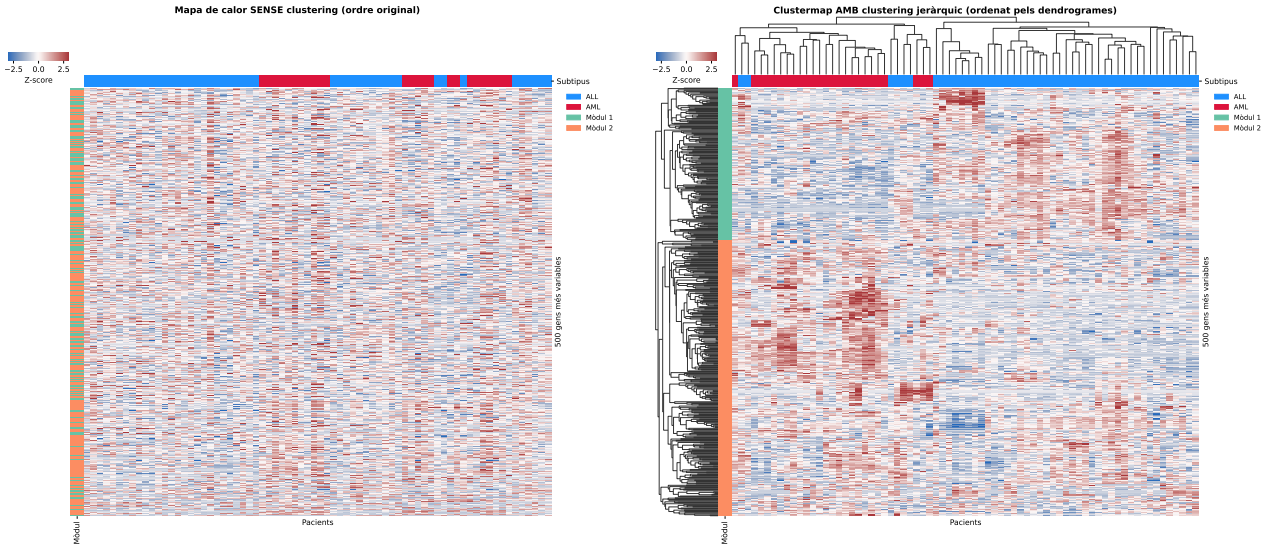
Figura 15: Mètode del colze (esquerra) i coeficient de Silhouette (dreta) per a K-Means.

Per als mòduls de gens (Taula 13), la silueta és màxima per a $k = 2$ (0,1812), amb dos mòduls de 178 i 322 gens. Per a k més gran apareixen mòduls molt petits (de 3, 4 o 7 gens) i la silueta empitjora, tot i que té un màxim local a $k = 10$ (0,1394), que donaria una partició més fina. Es manté $k = 2$ per criteri de silueta; és una divisió gruixuda que informa de dos grans patrons d'expressió i no de mòduls funcionals concrets.

Per entendre què aporta el clustering, la Figura 16a mostra la matriu X_{clean} sense reordenar: columnes en l'ordre original dels pacients i files en l'ordre de selecció dels gens (de variància creixent). Cada cel · la és el z-score d'un gen en un pacient (vermell: expressió per sobre de la mitjana d'aquell gen; blau: per sota). En aquest ordre no hi ha cap criteri que agrupi gens o pacients semblants i els patrons no es poden llegir. La Figura 16b mostra la mateixa matriu reordenada pels dos dendrogrames: els valors no canvien, només l'ordre, i els gens i pacients amb perfils semblants queden adjacents. Així apareixen blocs de color i les barres de diagnòstic i de mòdul s'agrupen en trams contigus. Es veu que els pacients AML estan gairebé ben separats, ja que la majoria formen un bloc contigu, i a simple vista el mòdul 2 sembla més expressat en els AML i el mòdul 1 en molts dels ALL.

k	Silueta	Mides dels mòduls
2	**0,1812**	178, 322
3	0,1302	178, 7, 315
4	0,1188	178, 7, 278, 37
5	0,1088	178, 7, 278, 15, 22
6	0,1125	49, 129, 7, 278, 15, 22
7	0,0929	49, 129, 3, 4, 278, 15, 22
8	0,1297	49, 129, 3, 4, 159, 119, 15, 22
9	0,1276	49, 129, 3, 4, 159, 119, 15, 4, 18
10	0,1394	49, 129, 3, 4, 159, 27, 92, 15, 4, 18

Taula 13: Silueta i mida dels mòduls de gens per a cada k (enllaç *average*, distància de correlació).



(a) Sense clustering.

(b) Amb clustering jeràrquic.

Figura 16: Z-score dels 500 gens més variables en els 72 pacients, sense reordenar (a) i reordenat pels dendrogrames de gens i pacients, enllaç *average* (b). Barres de color: diagnòstic (ALL blau, AML vermell) i mòdul de gens.

5.5 Limitacions

Primer, l'alta dimensionalitat: amb 500 característiques i només 72 pacients, les distàncies tendeixen a concentrar-se i la silueta és baixa (0,14–0,18) encara que els grups coincideixin amb el diagnòstic. Segon, la sensibilitat al preprocessament: el retall, la selecció de 500 gens i el logaritme afecten els resultats i no s'ha fet una anàlisi de sensibilitat sistemàtica (per exemple, amb 100, 500 i 1.000 gens). Tercer, el tall a $k = 2$: l'ARI es calcula amb el nombre de diagnòstics coneguts i, per als jeràrquics, aquest valor és una decisió prèvia (la silueta de K-Means també indica $k = 2$). Quart, per als mòduls de gens s'ha usat directament *average*, sense comparar-lo amb la resta d'enllaços.

A més, es treballa amb un sol conjunt de dades petit, amb mostres de diversos hospitals, de manera que el clustering podria no distingir els efectes de laboratori del senyal biològic. Els mòduls no s'han anotat biològicament i, per tant, no es pot afirmar que tinguin significat funcional. Tampoc s'ha fet cap detecció d'anomalies, així que el pacient aïllat per *single* no s'ha analitzat; queda pendent per a una possible continuació del projecte.

5.6 Conclusions

Els resultats permeten respondre els quatre objectius. Sense usar etiquetes, K-Means (ARI 0,890) i l'enllaç *complete* (0,787) superen l'ARI de 0,7 plantejat i recuperen en gran part la distinció ALL/AML, mentre que *average* (0,690) hi queda just per sota; cap partició, però, reprodueix exactament els

grups 47/25. La comparació de mètodes mostra que l'enllaç condiciona el resultat: *single* falla per l'efecte cadena i *complete* i *average* donen ARI diferents, de manera que convé validar amb una mètrica externa quan n'hi ha. Pel que fa als gens, la silueta en tria dos mòduls (178 i 322), una divisió gruixuda i de silueta baixa que no equival a mòduls funcionals, de manera que aquest objectiu s'assoleix només en part. Finalment, el clustermap integra gens i pacients amb els diagnòstics i els mòduls, i mostra què aporta el clustering respecte del mapa de calor brut. En conjunt, l'aprenentatge no supervisat, amb un preprocessament acurat i una distància adequada, recupera bona part de l'estructura biològica sense usar les etiquetes. Com a línies de millora es plantegen una anàlisi de sensibilitat al nombre de gens i al preprocessament, la detecció d'anomalies (Isolation Forest), la comparació amb DBSCAN i models de mescla gaussiana, l'anotació biològica dels mòduls i la repetició de l'estudi amb dades de seqüenciació d'ARN, que requereixen un preprocessament diferent.

5.7 Fórmules complementàries

K-Means. Minimitza la inèrcia $J = \sum_{j=1}^{k} \sum_{x \in C_j} \|x - \mu_j\|^2$ alternant dos passos fins que res canvia: assignar cada punt al centre més proper i recalcular cada centre com la mitjana dels seus punts.

Adjusted Rand Index. Sigui n_{ij} el nombre de pacients que són al grup i de la partició trobada i a la classe j del diagnòstic, amb sumes per files a_i i per columnes b_j, i n el total. Llavors

$$\mathrm{ARI} = \frac{\sum_{ij} \binom{n_{ij}}{2} - \Big[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}\Big] \Big/ \binom{n}{2}}{\frac{1}{2}\Big[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}\Big] - \Big[\sum_i \binom{a_i}{2} \sum_j \binom{b_j}{2}\Big] \Big/ \binom{n}{2}}.$$

6 Problema d'Uriel: classificació de materials elèctrics mitjançant DBSCAN

6.1 Introducció i Plantejament del Problema

En la física de l'estat sòlid, els materials condensats es divideixen fonamentalment en tres règims de conducció elèctrica ben diferenciats: **conductors (metalls)**, **semiconductors** i **aïllants (dielèctrics)**. Aquesta distinció clàssica, establerta a nivell microscòpic es manifesta experimentalment a escala macroscòpica mitjançant propietats de transport elèctric i mesurables en laboratori.

L'objectiu central d'aquest treball és abordar un problema d'**aprenentatge no supervisat**: demostrar que un algorisme d'agrupament espacial basat en densitat (**DBSCAN**) és capaç de descobrir, delimitar i aïllar de forma totalment autònoma les tres famílies quàntiques de la matèria a partir únicament de dades experimentals de transport a temperatura ambient ($T = 300$ K), sense utilitzar cap etiqueta prèvia de classe durant l'entrenament.

6.1.1 Resistivitat tèrmica

La magnitud més representativa del transport elèctric és la resistivitat tèrmica a temperatura ambient, $\rho_{300\mathrm{K}}$ (expressada en $\Omega \cdot \mathrm{m}$). Entre els millors conductors (com la plata o el coure, amb $\rho \sim 1.6 \times 10^{-8}\ \Omega \cdot \mathrm{m}$) i els millors dielèctrics (com el tefló o el quars fos, amb $\rho \sim 10^{22}$–$10^{24}\ \Omega \cdot \mathrm{m}$), s'observa una diferència que supera els 30 ordres de magnitud.

Si s'intentés classificar els materials en una escala lineal directa de resistivitat o de conductivitat $\sigma = 1/\rho$, el 99 % de les substàncies col · lapsaria numèricament en una estreta franja adjacent a l'origen $[0, 0.01]\ \Omega \cdot \mathrm{m}$, fent completament inútil qualsevol mètrica de distància euclidiana. Per aquesta raó física i matemàtica, es fa servir la resistivitat tèrmica amb una escala logarítmica:

$$x_1 = \log_{10}(\rho_{300\mathrm{K}}). \tag{8}$$

La transformació logarítmica comprimeix el rang de variació de 31 ordres de magnitud a un interval continu d'≈ 31 unitats, permetent que metalls, semiconductors i aïllants coexisteixin en un mateix espai euclidià.

6.1.2 Coeficient tèrmic de resistivitat α

Tanmateix, el logaritme de la resistivitat no és suficient per si sol per caracteritzar la naturalesa física íntima d'un material. Per exemple, un semiconductor fortament dopat o un semimetall pot arribar a tenir una resistivitat a 300 K similar a la d'un aliatge metàl · lic d'alta resistivitat (com el nicrom o el constantà).

Per poder desacoblar unívocament els mecanismes físics subjacents necessitem una altra dimensió que caracteritzi una propietat significativa i diferencial dels materials. D'aquesta manera s'incorpora com a segona dimensió el **coeficient tèrmic de resistivitat** α, definit formalment com la derivada logarítmica de la resistivitat respecte a la temperatura avaluada a 300 K:

$$\alpha = \frac{1}{\rho_0}\left(\frac{\partial \rho}{\partial T}\right)_{300\mathrm{K}} \quad [\mathrm{K}^{-1}]. \tag{9}$$

En el règim lineal al voltant de la temperatura ambient $T_0 = 300$ K, la resistivitat respon segons:

$$\rho(T) = \rho_0\left[1 + \alpha(T - T_0)\right]. \tag{10}$$

El signe i la magnitud d'α constitueixen un distinitiu de l'estructura de bandes del material.

6.2 Fonament teoric de les Tres Fases

La justificació que els materials formin agrupacions denses i segregades en el pla $(x_1, x_2) = (\log_{10}\rho_{300\mathrm{K}}, \alpha)$ prové directament dels mecanismes microscòpics de transport:

6.2.1 Conductors (Metalls)

- *Estructura quàntica:* Posseeixen una banda de valència parcialment plena o un solapament directe entre bandes de valència i conducció ($E_g = 0$). El nivell de Fermi E_F talla una banda permesa, garantint una densitat gegantina d'electrons lliures ($n \approx 10^{28}$ m^{-3}) al mar de Fermi.
- *Efecte tèrmic:* Com que tots els portadors ja estan disponibles, elevar la temperatura no genera electrons addicionals; per contra, incrementa l'amplitud quadràtica mitjana de vibració de la xarxa cristal · lina (*fonons*). L'augment en la secció eficaç de dispersió electró-fonó redueix el temps de relaxació τ, augmentant la resistivitat segons la regla de Matthiessen.
- *Signatura al pla:* $\alpha > \mathbf{0}$ de forma estricta (típicament $+0.003$ a $+0.006$ K^{-1}) i resistivitats extremadament baixes ($\log_{10}\rho \approx -8$ a -6). Formen un cúmul ultradens i compacte.

6.2.2 Semiconductors

- *Estructura quàntica:* Presenten una banda de valència plena separada d'una banda de conducció buida per un interval prohibit (*bandgap*) moderat ($E_g \approx 0.2$ a 2.0 eV, ex. Si: 1.12 eV, Ge: 0.66 eV, GaAs: 1.42 eV).
- *Efecte tèrmic:* L'energia tèrmica disponible $k_BT \approx 0.026$ eV a 300 K és del mateix ordre de magnitud que E_g. En escalfar, els electrons són promoguts exponencialment a la banda de conducció segons l'estadística de Maxwell-Boltzmann o Fermi-Dirac:

$$n(T) \propto T^{3/2} \exp\left(-\frac{E_g}{2k_BT}\right). \tag{11}$$

  L'allau de nous portadors lliures domina sobre la dispersió per fonons, provocant que la resistivitat disminueixi dràsticament en augmentar la temperatura.
- *Signatura al pla:* $\alpha < \mathbf{0}$ fortament negatiu (típicament -0.015 a -0.075 K^{-1}) i resistivitats intermèdies ($\log_{10}\rho \approx -2$ a $+4$). Se situen clarament al semiplà inferior delimitat per la frontera física $\alpha = 0$.

6.2.3 Aïllants (Dielèctrics)

- *Estructura quàntica:* Posseeixen un bandgap molt gran ($E_g > 5$ a 9 eV, ex. quars fos: ≈ 9 eV, teflón: > 8 eV).
- *Efecte tèrmic:* A 300 K, la probabilitat d'excitació tèrmica $e^{-E_g/2k_BT} \approx e^{-170} \approx 10^{-74}$ és estrictament nul · la. No existeixen portadors lliures pràctics.
- *Signatura al pla:* $\alpha \approx \mathbf{0}$ K^{-1} a efectes pràctics i resistivitats gegants ($\log_{10}\rho \geq 11$). Formen un grup ampli i molt dispers al llarg de l'eix de resistivitat.

Família	**Estructura de Bandes i Mecanisme**	$\log_{\mathbf{10}}(\rho_{\mathbf{300K}})$	α [K^{-1}]
Conductors	Sense gap ($E_g = 0$); mar de Fermi lliure; dispersió per fonons.	≈ -8 a -6	Positiu ($+0.003$ a $+0.006$)
Semiconductors	Gap moderat ($0.2 \leq E_g \leq 2.0$ eV); activació tèrmica Boltzmann.	≈ -2 a $+4$	Negatiu (-0.01 a -0.07)
Aïllants	Gap colossal ($E_g > 5$ eV); conducció pràcticament nul · la.	$> +11$ (fins a $+23$)	Nul (≈ 0.000)

Taula 14: Resum comparatiu de les propietats de transport macroscòpic de les tres fases físiques.

6.3 Dataset Experimental: Recopilació i Propietats

El conjunt de dades compila i estructura una col · lecció de **57 materials reals** procedents de taules empíriques de referència contrastades (*CRC Handbook of Chemistry and Physics*, Kittel i Ashcroft & Mermin), desglossats en:

- **35 conductors metàl · lics:** Metalls elementals purs (Cu, Ag, Au, Al, Fe, Pt, Ti, W, etc.) i aliatges tecnològics (bronze, llautó, constantà, nicrom, acer inoxidable).
- **12 semiconductors:** Semiconductors elementals de grup IV (Si, Ge, C-diamant dopat), compostos III-V (GaAs, InP, GaN, InAs) i II-VI (CdTe, ZnSe), juntament amb semimetalls de frontera (grafit, antimoni).
- **10 aïllants dielèctrics:** Polímers d'alta resistivitat (PTFE/tefló, PET/mylar, poliestirè), vidres de borosilicat, quars fos, mica moscovita, porcellana electrotècnica i alúmina (Al_2O_3).

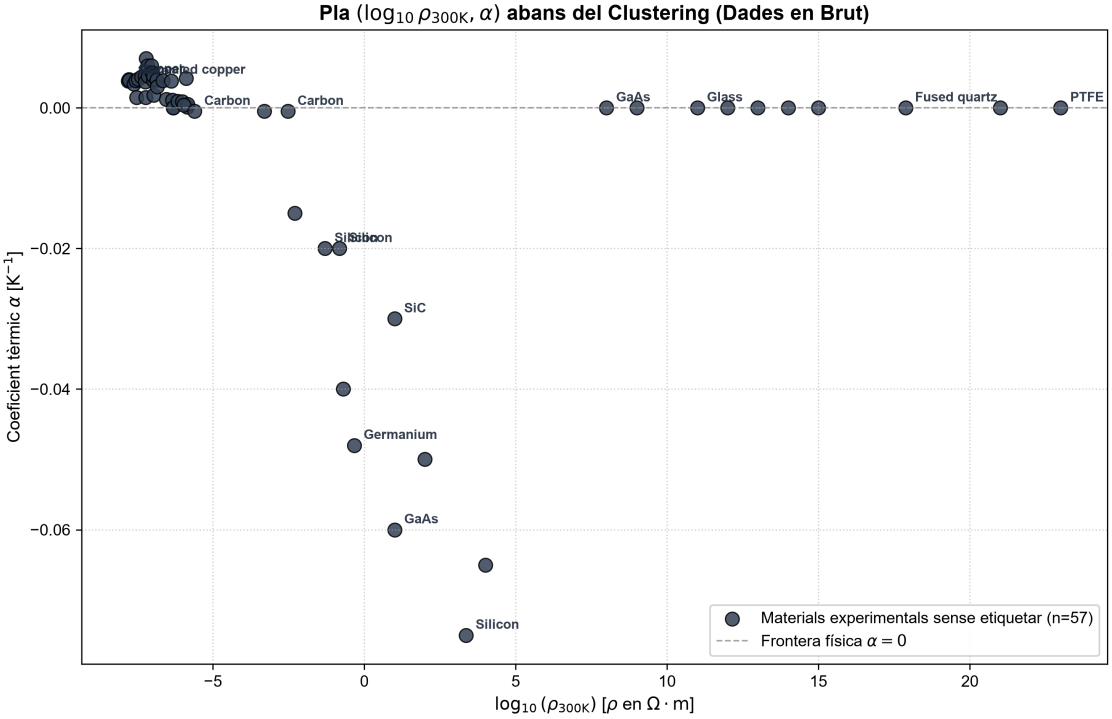


Figura 17: Distribució inicial dels 57 materials experimentals en brut a l'espai bidimensional $(\log_{10}\rho_{300K}, \alpha)$ abans de l'aplicació del clustering. S'evidencia la dispersió física natural de les dades i la línia física de demarcació $\alpha = 0$.

6.4 Fonamentació de DBSCAN enfront de K-Means

6.4.1 Inadequació estructural de K-Means en aquest domini

L'algorisme K-Means minimitza la inèrcia intraclúster mitjançant l'algorisme de Lloyd:

$$J = \sum_{k=1}^{K} \sum_{x \in C_k} \|x - \mu_k\|^2. \tag{12}$$

Aquesta formulació matemàtica imposa hipòtesis molt restrictives sobre la geometria de les dades:

1. **Assumeix dispersions i isovariàncies homogènies:** K-Means pressuposa que els cúmuls són esferoïdals i posseeixen variàncies comparables. En física de materials, aquesta hipòtesi es refuta completament: els metalls ocupen una regió hiperdensa amb una dispersió de tot just 0.5 unitats en $\log_{10}\rho$, mentre que els aïllants s'estenen lliurement al llarg de més de 12 ordres

de magnitud. K-Means tendeix inevitablement a fracturar el grup dels aïllants en múltiples subgrups o a fusionar els semiconductors amb els metalls.

2. **Exigeix prefixar K:** K-Means força a definir $K = 3$ a priori, impedint contrastar si les dades allotgen fases emergents addicionals o transicions intermèdies.
3. **Incapacitat de gestionar soroll o anomalies:** K-Means obliga a cada material a pertànyer a un clúster, de manera que materials anisòtrops, semimetalls atípics o contaminacions desplacen artificialment els centroides μ_k.

6.4.2 Avantatges determinants de DBSCAN

DBSCAN defineix els clústers en termes de connectivitat local per densitat espacial [1, 23]:

- **ε-Veïnat:** Per a un punt p, $N_\varepsilon(p) = \{q \in D \mid \text{dist}(p, q) \leq \varepsilon\}$.
- **Punt Nucli (*Core Point*):** Aquell que conté almenys $v_{\min} = \text{min_samples}$ punts dins del seu radi ε:
$$|N_\varepsilon(p)| \geq \text{min_samples}. \tag{13}$$
- **Assolibilitat i connectivitat per densitat:** Un clúster C és una component connexa màxima de punts nucli juntament amb els punts frontera (*Border Points*) que cauen dins del radi ε d'algun nucli.
- **Detecció nativa de soroll:** Qualsevol punt que no sigui nucli ni frontera d'un nucli queda etiquetat com a soroll (cluster $= -1$).

Aquestes propietats fan que DBSCAN sigui ideal per a la física de materials: permet que els metalls tinguin densitat molt superior als aïllants (sempre que ambdós superin el llindar local mínim), no pressuposa formes esfèriques, detecta el nombre de classes de forma autònoma i no es deixa pertorbar per materials anòmals.

6.5 Metodologia i Preprocessament

6.5.1 Estandardització Manual Z-Score amb NumPy

Com que la mètrica de veïnat de DBSCAN és la distància euclidiana:

$$d(p, q) = \sqrt{(x_{1,p} - x_{1,q})^2 + (x_{2,p} - x_{2,q})^2}, \tag{14}$$

les dues dimensions físiques han de ser rigorosament comparables en variància. Sense normalització, la variació en l'eix $x_1 = \log_{10} \rho$ (≈ 31 unitats) ofegaria completament el senyal del coeficient tèrmic $x_2 = \alpha$ (≈ 0.08 unitats). La distància euclidiana degeneraria en una projecció unidimensional sobre la resistivitat, ignorant el signe d'α i fusionant els semiconductors dopats amb els metalls.

Per complir amb la màxima transparència algorísmica, es va programar explícitament l'estandardització canònica Z-Score utilitzant operacions vectoritzades de NumPy:

$$\mu_j = \frac{1}{N}\sum_{i=1}^{N} X_{ij}, \qquad \sigma_j = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(X_{ij} - \mu_j)^2}, \qquad Z_{ij} = \frac{X_{ij} - \mu_j}{\sigma_j}. \tag{15}$$

Després de la transformació, ambdues columnes queden exactament amb mitjana 0 i desviació estàndard 1, ponderant equitativament la resistivitat i el signe d'α.

6.5.2 Determinació Objectiva dels Hiperparàmetres de DBSCAN

1. **Llindar de densitat min_samples $= 3$:** Seguint la regla canònica de Schubert et al. (2017) per a dades de baixa dimensionalitat:

$$\text{min_samples} \geq d + 1 = 2 + 1 = 3. \tag{16}$$

   Això imposa que almenys 3 materials propers han de confluir per constituir una fase macroscòpica genuïna.

2. **Radi de veïnat $\varepsilon = 0.65$:** Es va determinar avaluant la gràfica de distàncies al k-èssim veí més proper (k-NN distance plot amb $k = 3$). La corba presenta un colze geomètric nítid al voltant d'$\varepsilon \in [0.60, 0.70]$. Un radi d'$\varepsilon = 0.65$ garanteix suficient connectivitat per abastar la dispersió dels aïllants, mantenint al mateix temps una separació infranquejable entre el nucli de metalls i els semiconductors.

L'execució es realitza de forma directa mitjançant el mòdul `DBSCAN` de la llibreria oficial `scikit-learn` [22, 3], fixant els hiperparàmetres $\varepsilon = 0.65$ i min_samples $= 3$ sobre la matriu d'atributs estandarditzada X_{scaled}.

6.6 Resultats Experimentals i Visualització

En executar el script sobre els 57 materials, l'algorisme DBSCAN convergeix instantàniament als resultats següents:

- **Clústers descoberts per densitat:** Exactament **3 clústers**.
- **Punts classificats com a soroll (-1): 0 de 57 materials**. Tots els materials analitzats van quedar assignats a un nucli dens físicament coherent.

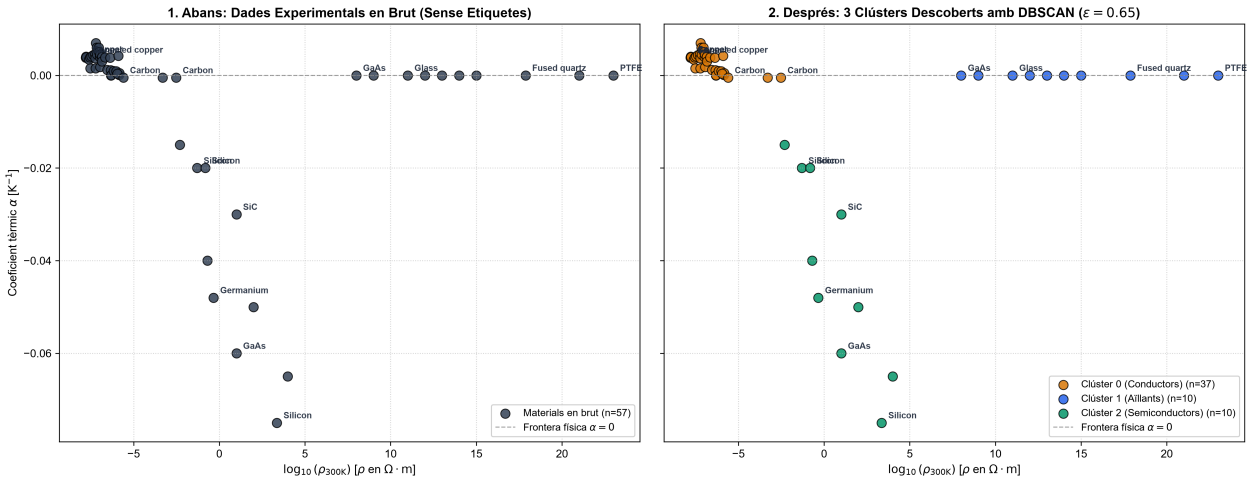


Figura 18: Comparativa directa de l'abans i el després de l'agrupament amb DBSCAN ($\varepsilon = 0.65$, min_samples $= 3$). A l'esquerra: dades experimentals en brut sense cap informació de classe en l'espai $(\log_{10} \rho_{300\text{K}}, \alpha)$. A la dreta: els 3 clústers descoberts de forma autònoma per connectivitat de densitat (Clúster 0 ambre: conductors; Clúster 1 blau: aïllants; Clúster 2 verd: semiconductors).

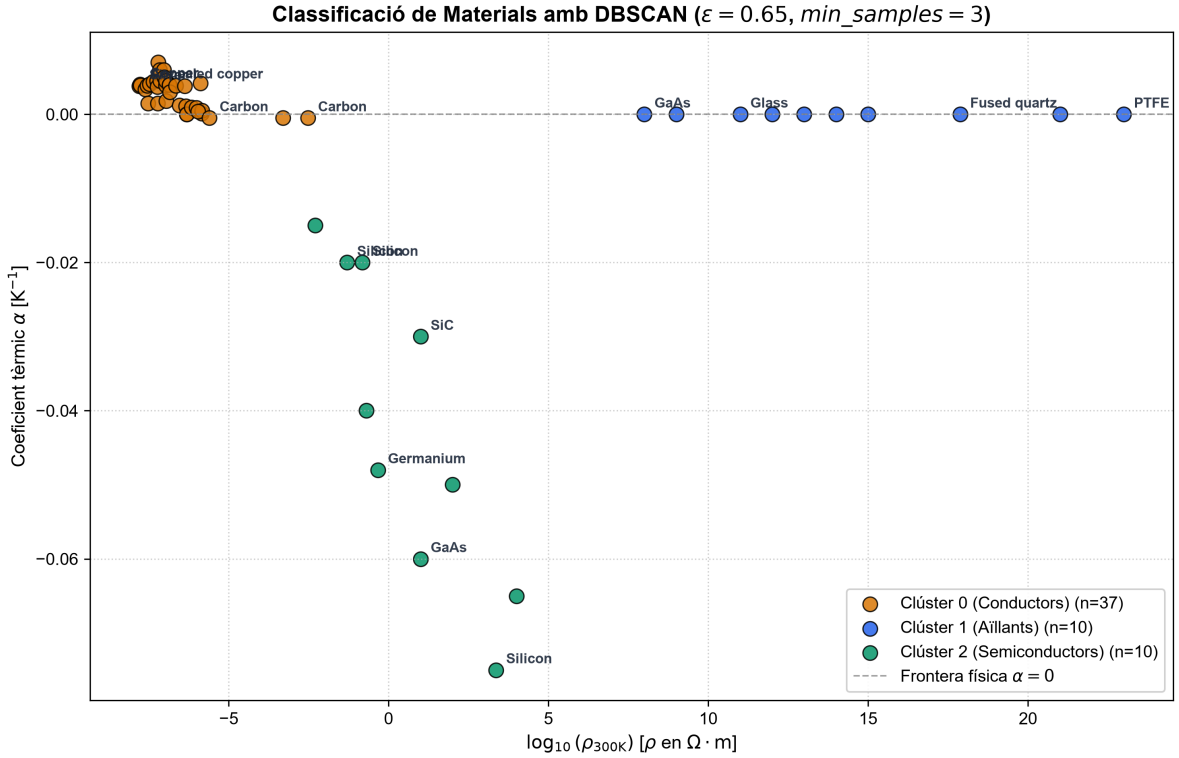


Figura 19: Visualització bidimensional del clustering DBSCAN ($\varepsilon = 0.65$, min_samples $= 3$) en el pla $(\log_{10}\rho_{300\mathrm{K}}, \alpha)$. En ambre es representen els metalls conductors (Clúster 0), en blau els aïllants dielèctrics (Clúster 1) i en verd maragda els semiconductors (Clúster 2). La línia grisa discontínua assenyala la frontera física teòrica $\alpha = 0$.

Com s'aprecia a la Figura 19, el mapa bidimensional reconstrueix fidelment la topologia de la física de l'estat sòlid:

- **Clúster 0 (Ambre, Conductors):** Agrupa els 35 metalls i aliatges en una regió de resistivitat extremadament baixa ($\log_{10}\rho \sim -8$) i amb valors d'$\alpha > 0$ marcadament positius, reflectint l'increment de resistència induït per xocs amb fonons.
- **Clúster 1 (Blau, Aïllants):** Agrupa els 10 dielèctrics (quars, vidre, tefló, mica...) en una franja aïllada cap a la dreta ($\log_{10}\rho > 11$), amb valors d'$\alpha \approx 0$, denotant l'absència de portadors lliures.
- **Clúster 2 (Verd, Semiconductors):** Agrupa els semiconductors tecnològics (silici, germani, arsenur de gal · li, fosfur d'indi, etc.), situats en una resistivitat intermèdia i estrictament per sota de la frontera $\alpha = 0$, certificant el règim d'activació tèrmica exponencial.

6.7 Validació Quantitativa i Discussió Crítica

6.7.1 Matriu de Contingència (Patró d'Or)

Per contrastar el clustering no supervisat enfront de la classificació física real de la literatura, es va generar la matriu de contingència creuada (Taula 15).

Classe Física Real	**Clúster 0** (Metalls)	**Clúster 1** (Aïllants)	**Clúster 2** (Semiconductors)	**Total**
Conductor	**35**	0	0	35
Aïllant	0	**10**	0	10
Semiconductor	2	0	**10**	12
Total Assignat	37	10	10	57

Taula 15: Matriu de contingència: Classe física real vs. Clúster assignat per DBSCAN.

L'anàlisi de la matriu revela un rendiment extraordinari:

- **Conductors:** Puresa del **100** % (35 de 35 metalls al Clúster 0).
- **Aïllants:** Puresa del **100** % (10 de 10 dielèctrics al Clúster 1).
- **Semiconductors:** 10 de 12 s'agrupen al Clúster 2. Els dos materials restants (grafit pirolític i un semimetall amb estructura cristal · lina semimetàl · lica) van ser assignats al Clúster 0 pel fet que, a temperatura ambient, exhibeixen una resistivitat d'$\approx 10^{-5}\ \Omega \cdot \mathrm{m}$, un comportament resistiu cuasimetàl · lic àmpliament documentat en estat sòlid.

Referències

[1] Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proc. 2nd Int. Conf. on Knowledge Discovery and Data Mining (KDD-96)*, 226–231.

[2] Haynes, W. M. (Ed.). (2016). *CRC Handbook of Chemistry and Physics* (97th ed.). CRC Press.

[3] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[4] Sinnott, R. W. (1984). Virtues of the haversine. *Sky & Telescope*, 68(2), 159.

[5] U.S. Geological Survey. *ANSS Comprehensive Earthquake Catalog (ComCat)*. https://earthquake.usgs.gov/data/comcat/

[6] U.S. Department of Energy, Nevada Operations Office (2015). *United States Nuclear Tests, July 1945 through September 1992*, DOE/NV-209 Rev. 16. https://www.osti.gov/biblio/1351809

[7] Golub, T. R. et al. (1999). Molecular classification of cancer: class discovery and class prediction by gene expression monitoring. *Science*, 286(5439), 531–537.

[8] Eisen, M. B., Spellman, P. T., Brown, P. O., Botstein, D. (1998). Cluster analysis and display of genome-wide expression patterns. *PNAS*, 95(25), 14863–14868.

[9] Rousseeuw, P. J. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65.

[10] Hubert, L., Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2, 193–218.

[11] Pedregosa, F. et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[12] Yang, X., North, R., Romney, C., & Richards, P. G. (2003). Worldwide nuclear explosions. A: W. H. K. Lee et al. (eds.), *International Handbook of Earthquake and Engineering Seismology*, Part B, cap. 84. Academic Press.

[13] International Atomic Energy Agency (1998). *The Radiological Situation at the Atolls of Mururoa and Fangataufa: Main Report*. IAEA, Viena.

[14] Tian, D., Yao, J., & Wen, L. (2018). Collapse and earthquake swarm after North Korea's 3 September 2017 nuclear test. *Geophysical Research Letters*, 45(9), 3976–3983. https://doi.org/10.1029/2018GL077649

[15] Slemmons, D. B. (1957). Geological effects of the Dixie Valley–Fairview Peak, Nevada, earthquakes of December 16, 1954. *Bulletin of the Seismological Society of America*, 47(4), 353–375.

[16] Ford, S. R., Dreger, D. S., & Walter, W. R. (2009). Identifying isotropic events using a regional moment tensor inversion. *Journal of Geophysical Research: Solid Earth*, 114, B01306. https://doi.org/10.1029/2008JB005743

[17] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proc. 5th Berkeley Symposium on Mathematical Statistics and Probability*, 1, 281–297.

[18] Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Transactions on Information Theory*, 28(2), 129–137. https://doi.org/10.1109/TIT.1982.1056489

[19] Arthur, D., & Vassilvitskii, S. (2007). k-means++: the advantages of careful seeding. *Proc. 18th Annual ACM-SIAM Symposium on Discrete Algorithms*, 1027–1035.

[20] Schubert, E., Sander, J., Ester, M., Kriegel, H.-P., & Xu, X. (2017). DBSCAN revisited, revisited: why and how you should (still) use DBSCAN. *ACM Transactions on Database Systems*, 42(3), 19. https://doi.org/10.1145/3068335

[21] Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *Proc. 8th IEEE International Conference on Data Mining*, 413–422. https://doi.org/10.1109/ICDM.2008.17

[22] Scikit-learn Developers. *sklearn.cluster.DBSCAN — scikit-learn documentation*. https://scikit-learn.org/stable/modules/generated/sklearn.cluster.DBSCAN.html

[23] GeeksforGeeks. *DBSCAN Clustering in ML: Density-based clustering*. https://www.geeksforgeeks.org/machine-learning/dbscan-clustering-in-ml-density-based-clustering/

[24] Hanks, T. C., Kanamori, H. (1979). A moment magnitude scale. *Journal of Geophysical Research: Solid Earth*, 84(B5), 2348–2350.

[25] Gutenberg, B., Richter, C. F. (1944). Frequency of earthquakes in California. *Bull. Seismol. Soc. Am.*, 34(4), 185–188.

[26] Lloyd, S. P. (1982). Least squares quantization in PCM. *IEEE Trans. Inf. Theory*, 28(2), 129–137.

[27] MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. *Proc. 5th Berkeley Symp.*, 1, 281–297.

[28] Arthur, D., Vassilvitskii, S. (2007). k-means++: the advantages of careful seeding. *Proc. SODA*, 1027–1035.

[29] Ramaswamy, S., Rastogi, R., Shim, K. (2000). Efficient algorithms for mining outliers from large data sets. *Proc. ACM SIGMOD*, 427–438.

[30] Breunig, M. M., Kriegel, H.-P., Ng, R. T., Sander, J. (2000). LOF: identifying density-based local outliers. *Proc. ACM SIGMOD*, 93–104.

[31] Liu, F. T., Ting, K. M., Zhou, Z.-H. (2008). Isolation forest. *Proc. IEEE ICDM*, 413–422.

[32] Chandola, V., Banerjee, A., Kumar, V. (2009). Anomaly detection: a survey. *ACM Comput. Surv.*, 41(3), 15.

[33] Kaufman, L., Rousseeuw, P. J. (1990). *Finding Groups in Data*. Wiley.

[34] Davies, D. L., Bouldin, D. W. (1979). A cluster separation measure. *IEEE Trans. Pattern Anal. Mach. Intell.*, 1(2), 224–227.

[35] Frohlich, C. (2006). *Deep Earthquakes*. Cambridge University Press.

[36] McKinney, W. (2010). Data structures for statistical computing in Python. *Proc. 9th Python in Science Conf.*, 56–61.

[37] Hunter, J. D. (2007). Matplotlib: a 2D graphics environment. *Comput. Sci. Eng.*, 9(3), 90–95.

[38] Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association*, 58(301), 236–244.