UNIVERSITAT POLITÈCNICA DE CATALUNYA

Escola Tècnica Superior d'Enginyeria de Telecomunicació de Barcelona (ETSETB)

Classificació No Supervisada de Materials Elèctrics mitjançant DBSCAN

Classificació de Conductors, Semiconductors i Aïllants a l'Espai $(\log_{10}\rho_{300\mathrm{K}}, \alpha)$

Computer Programming and Its Applications (CPIA)

Grau en Enginyeria Física — Curs Acadèmic 2026–2027

Autor:
Uriel Martínez Rosa
Grau en Enginyeria Física

Equip de Treball CPIA:
Arnau Montull Bainad
Matías Stein Niell
Martí Canut Sumarroca
Uriel Martínez Rosa

27 d'octubre de 2026

Índex General del Treball

1. Introducció i Plantejament del Problema 1
1.1. Resistivitat tèrmica a 300 K 1
1.2. Coeficient tèrmic de resistivitat α 1
2. Fonament Teòric de les Tres Fases 2
2.1. Conductors (Metalls) 2
2.2. Semiconductors 2
2.3. Aïllants (Dielèctrics) 2
3. Dataset Experimental: Recopilació i Propietats 3
4. Fonamentació de DBSCAN enfront de K-Means 4
4.1. Inadequació estructural de K-Means en aquest domini 4
4.2. Avantatges determinants de DBSCAN 4
5. Metodologia i Preprocessament 5
5.1. Estandardització Manual Z-Score amb NumPy 5
5.2. Determinació Objectiva dels Hiperparàmetres (ε = 0.65, min_samples = 3) 5
6. Resultats Experimentals i Visualització 6
7. Validació Quantitativa i Discussió Crítica 7
7.1. Matriu de Contingència creuada enfront del patró d'or 7
Bibliografia 8

1. Introducció i Plantejament del Problema

En la física de l'estat sòlid, els materials condensats es divideixen fonamentalment en tres règims de conducció elèctrica ben diferenciats: **conductors (metalls)**, **semiconductors** i **aïllants (dielèctrics)**. Aquesta distinció clàssica, establerta a nivell microscòpic per la teoria quàntica de bandes electròniques (l'existència o absència d'una banda d'energia prohibida o *bandgap* E_g), es manifesta experimentalment a escala macroscòpica mitjançant propietats de transport elèctric i termodinàmic clarament mesurables en laboratori.

L'objectiu central d'aquest treball és abordar un problema d'**aprenentatge no supervisat** (*unsupervised learning*): demostrar que un algorisme d'agrupament espacial basat en densitat (**DBSCAN**) és capaç de descobrir, delimitar i aïllar de forma totalment autònoma les tres famílies quàntiques de la matèria a partir únicament de dades experimentals de transport a temperatura ambient ($T = 300$ K), sense utilitzar cap etiqueta prèvia de classe durant l'entrenament.

1.1. Resistivitat tèrmica a 300 K

La magnitud més representativa del transport elèctric és la resistivitat elèctrica a temperatura ambient, $\rho_{300\mathrm{K}}$ (expressada en $\Omega \cdot \mathrm{m}$). Entre els millors conductors (com la plata o el coure, amb $\rho \sim 1.6 \times 10^{-8}\ \Omega \cdot \mathrm{m}$) i els millors

dielèctrics (com el tefló o el quars fos, amb $\rho \sim 10^{22}$–$10^{24}\ \Omega \cdot \mathrm{m}$), s'observa una diferència que supera els 30 ordres de magnitud.

Si s'intentés classificar els materials en una escala lineal directa de resistivitat o de conductivitat $\sigma = 1/\rho$, el $99\,\%$ de les substàncies col·lapsaria numèricament en una estreta franja adjacent a l'origen $[0, 0.01]\ \Omega \cdot \mathrm{m}$, fent completament inútil qualsevol mètrica de distància euclidiana. Per aquesta raó física i matemàtica, es defineix com a primera coordenada l'escala logarítmica decimal:

$$x_1 = \log_{10}(\rho_{300\mathrm{K}}).$$

La transformació logarítmica comprimeix el rang de variació de 31 ordres de magnitud a un interval continu d' ≈ 31 unitats, permetent que metalls, semiconductors i aïllants coexisteixin en un mateix espai euclidià amb relacions de distància físicament representatives.

1.2. Coeficient tèrmic de resistivitat α

Tanmateix, el logaritme de la resistivitat no és suficient per si sol per caracteritzar la naturalesa física íntima d'un material. Per exemple, un semiconductor fortament dopat o un semimetall pot arribar a tenir una resistivitat a $300\ \mathrm{K}$ similar a la d'un aliatge metàl·lic d'alta resistivitat (com el nicrom o el constantà). Tots dos presentarien coordenades x_1 molt properes, resultant indistingibles en un espai unidimensional.

Per desacoblar unívocament els mecanismes físics subjacents s'incorpora com a segona dimensió el **coeficient tèrmic de resistivitat** α, definit formalment com la derivada logarítmica de la resistivitat respecte a la temperatura avaluada a $300\ \mathrm{K}$:

$$\alpha = \frac{1}{\rho_0}\left(\frac{\partial \rho}{\partial T}\right)_{300\mathrm{K}} \quad [\mathrm{K}^{-1}].$$

En el règim lineal al voltant de la temperatura ambient $T_0 = 300\ \mathrm{K}$, la resistivitat respon segons:

$$\rho(T) = \rho_0\,[1 + \alpha(T - T_0)].$$

El signe i la magnitud d'α constitueixen la signatura fonamental de l'estructura electrònica: mentre que en els metalls $\alpha > 0$ degut a la dispersió per fonons en una població d'electrons lliures ja constant, en els semiconductors $\alpha < 0$ fortament degut a la promoció tèrmica exponencial de portadors a través del bandgap.

2. Fonament Teòric de les Tres Fases

La justificació que els materials formin agrupacions denses i segregades en el pla $(x_1, x_2) = (\log_{10}\rho_{300\mathrm{K}}, \alpha)$ prové directament dels mecanismes microscòpics de transport d'estat sòlid:

2.1. Conductors (Metalls)

- **Estructura quàntica:** Posseeixen una banda de valència parcialment plena o un solapament directe entre bandes de valència i conducció ($E_g = 0$). El nivell de Fermi E_F talla una banda permesa, garantint una densitat gegantina d'electrons lliures ($n \approx 10^{28}\ \mathrm{m}^{-3}$) al mar de Fermi.
- **Efecte tèrmic:** Com que tots els portadors ja estan disponibles, elevar la temperatura no genera electrons addicionals; per contra, incrementa l'amplitud quadràtica mitjana de vibració de la xarxa cristal·lina (*fonons*). L'augment en la secció eficaç de dispersió electró-fonó redueix el temps de relaxació τ, augmentant la resistivitat segons la regla de Matthiessen.
- **Signatura al pla:** $\alpha > 0$ de forma estricta (típicament $+0.003$ a $+0.006\ \mathrm{K}^{-1}$) i resistivitats extremadament baixes ($\log_{10}\rho \approx -8$ a -6). Formen un cúmul ultradens i compacte.

2.2. Semiconductors

- **Estructura quàntica:** Presenten una banda de valència plena separada d'una banda de conducció buida per un interval prohibit moderat ($E_g \approx 0.2$ a 2.0 eV, com el Si amb 1.12 eV o el Ge amb 0.66 eV).
- **Efecte tèrmic:** L'energia tèrmica disponible $k_B T \approx 0.026$ eV a 300 K és del mateix ordre de magnitud que E_g. En escalfar, els electrons són promoguts exponencialment a la banda de conducció segons l'estadística de Maxwell-Boltzmann:

$$n(T) \propto T^{3/2} \exp\left(-\frac{E_g}{2k_B T}\right).$$

  L'allau de nous portadors lliures domina sobre la dispersió per fonons, provocant que la resistivitat disminueixi dràsticament en augmentar la temperatura.
- **Signatura al pla:** $\alpha < 0$ fortament negatiu (típicament -0.015 a $-0.075\ \mathrm{K}^{-1}$) i resistivitats intermèdies ($\log_{10}\rho \approx -2$ a $+4$). Se situen clarament al semiplà inferior delimitat per la frontera física $\alpha = 0$.

2.3. Aïllants (Dielèctrics)

- **Estructura quàntica:** Posseeixen un bandgap colossal ($E_g > 5$ a 9 eV, com el quars fos amb ≈ 9 eV o el tefló amb > 8 eV).
- **Efecte tèrmic:** A 300 K, la probabilitat d'excitació tèrmica $e^{-E_g/2k_BT} \approx e^{-170} \approx 10^{-74}$ és estrictament nul·la. No existeixen portadors lliures pràctics.
- **Signatura al pla:** $\alpha \approx 0\ \mathrm{K}^{-1}$ a efectes pràctics i resistivitats gegants ($\log_{10}\rho \geq 11$). Formen un grup ampli i molt dispers al llarg de l'eix de resistivitat.

Família	Estructura de Bandes i Mecanisme Físic	$\log_{10}(\rho_{300\text{K}})$	α [K^{-1}]
Conductors	Sense gap ($E_g = 0$); mar de Fermi lliure; dispersió creixent per fonons.	≈ -8 a -6	Positiu ($+0.003$ a $+0.006$)
Semiconductors	Gap moderat ($0.2 \leq E_g \leq 2.0$ eV); activació tèrmica de Boltzmann.	≈ -2 a $+4$	Negatiu (-0.01 a -0.07)
Aïllants	Gap colossal ($E_g > 5$ eV); conducció pràcticament nul·la.	$> +11$ (fins a $+23$)	Nul (≈ 0.000)

Taula 1: Resum comparatiu de les propietats de transport macroscòpic de les tres grans fases físiques de la matèria condensada.

3. Dataset Experimental: Recopilació i Propietats

El conjunt de dades conté **57 materials reals** procedents de taules empíriques de referència contrastades (*CRC Handbook of Chemistry and Physics*, Kittel i Ashcroft & Mermin), estructurats en:

- **35 conductors metàl·lics:** Metalls purs (Cu, Ag, Au, Al, Fe, Pt, Ti, W, etc.) i aliatges tecnològics (bronze, llautó, constantà, nicrom, acer inoxidable).
- **12 semiconductors:** Elementals de grup IV (Si, Ge, C-diamant dopat), compostos III-V (GaAs, InP, GaN, InAs) i II-VI (CdTe, ZnSe), juntament amb semimetalls de frontera (grafit, antimoni).
- **10 aïllants dielèctrics:** Polímers d'alta resistivitat (PTFE/tefló, PET/mylar, poliestirè), vidres de borosilicat, quars fos, mica moscovita, porcellana electrotècnica i alúmina (Al_2O_3).

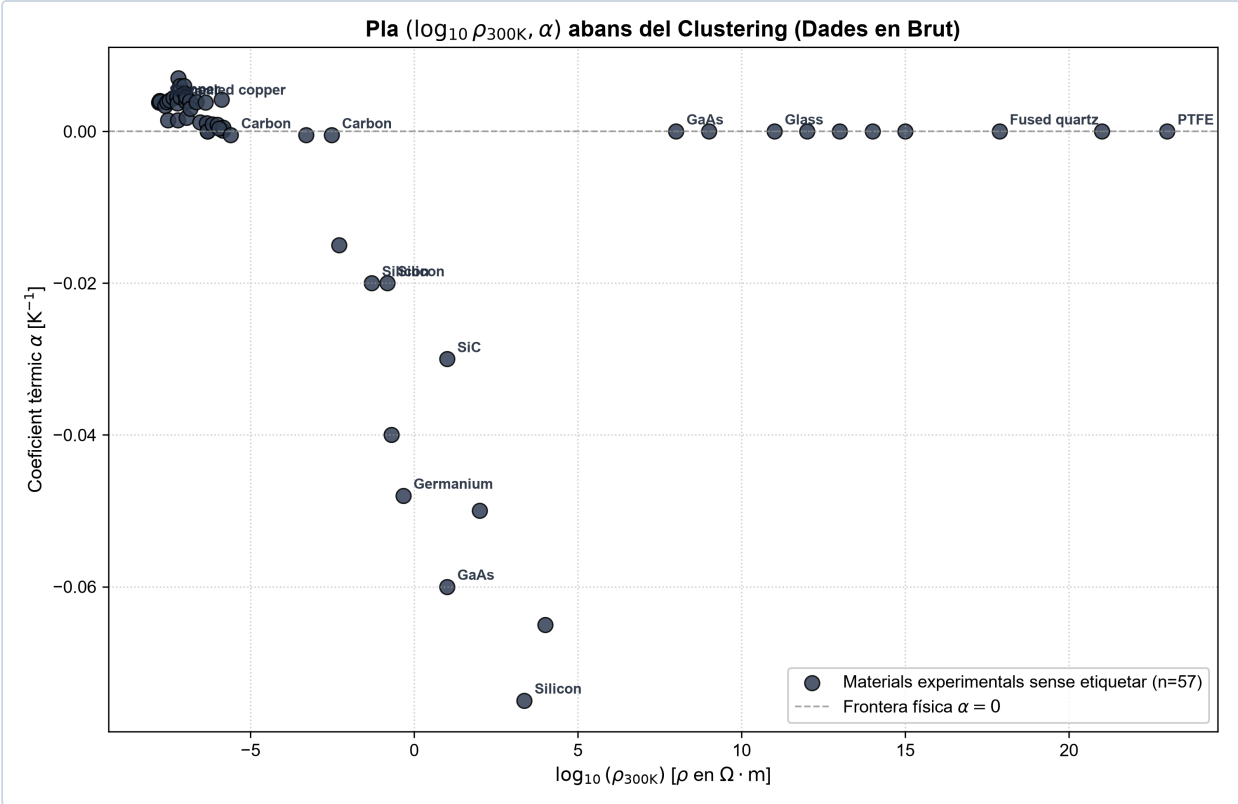


Figura 1: Distribució inicial dels 57 materials experimentals en brut a l'espai bidimensional $(\log_{10}\rho_{300K}, \alpha)$ abans de l'aplicació del clustering. S'evidencia la dispersió física natural de les dades i la línia física de demarcació $\alpha = 0$.

4. Fonamentació de DBSCAN enfront de K-Means

4.1. Inadequació estructural de K-Means en aquest domini

L'algorisme K-Means minimitza la inèrcia intraclúster $J = \sum_{k=1}^{K} \sum_{x \in C_k} \|x - \mu_k\|^2$. Aquesta formulació matemàtica imposa hipòtesis molt restrictives sobre la geometria de les dades:

1. **Assumeix dispersions i isovariàncies homogènies:** K-Means pressuposa que els cúmuls són esferoïdals i posseeixen variàncies comparables. En física de materials, aquesta hipòtesi es refuta completament: els metalls ocupen una regió hiperdensa amb una dispersió de tot just 0.5 unitats en $\log_{10} \rho$, mentre que els aïllants s'estenen lliurement al llarg de més de 12 ordres de magnitud. K-Means tendeix inevitablement a fracturar el grup dels aïllants en múltiples subgrups o a fusionar els semiconductors amb els metalls.
2. **Exigeix prefixar K:** K-Means força a definir $K = 3$ a priori, impedint contrastar si les dades allotgen fases emergents addicionals o transicions intermèdies.
3. **Incapacitat de gestionar soroll o anomalies:** K-Means obliga a cada material a pertànyer a un clúster, de manera que materials anisòtrops, semimetalls atípics o contaminacions desplacen artificialment els centroides μ_k.

4.2. Avantatges determinants de DBSCAN

DBSCAN defineix els clústers en termes de connectivitat local per densitat espacial:

- **ε-Veïnat:** Per a un punt p, $N_\varepsilon(p) = \{q \in D \mid \text{dist}(p, q) \leq \varepsilon\}$.
- **Punt Nucli (*Core Point*):** Aquell que conté almenys $v_{\min} = \min_\text{samples}$ punts dins del seu radi ε: $|N_\varepsilon(p)| \geq \min_\text{samples}$.
- **Assolibilitat i connectivitat per densitat:** Un clúster C és una component connexa màxima de punts nucli juntament amb els punts frontera (*Border Points*) que cauen dins del radi ε d'algun nucli.
- **Detecció nativa de soroll:** Qualsevol punt que no sigui nucli ni frontera d'un nucli queda etiquetat com a soroll ($\text{cluster} = -1$).

Aquestes propietats fan que DBSCAN sigui ideal per a la física de materials: permet que els metalls tinguin densitat molt superior als aïllants (sempre que ambdós superin el llindar local mínim), no pressuposa formes esfèriques, detecta el nombre de classes de forma autònoma i no es deixa pertorbar per materials anòmals.

5. Metodologia i Preprocessament

5.1. Estandardització Manual Z-Score amb NumPy

Com que la mètrica de veïnat de DBSCAN és la distància euclidiana $d(p, q) = \sqrt{(x_{1,p} - x_{1,q})^2 + (x_{2,p} - x_{2,q})^2}$, les dues dimensions físiques han de ser rigorosament comparables en variància. Sense normalització, la variació en l'eix $x_1 = \log_{10} \rho$ (≈ 31 unitats) ofegaria completament el senyal del coeficient tèrmic $x_2 = \alpha$ (≈ 0.08 unitats), degenerant en una projecció unidimensional sobre la resistivitat i ignorant el signe d'α.

Es va programar explícitament l'estandardització canònica Z-Score utilitzant operacions vectoritzades de NumPy:

$$\mu_j = \frac{1}{N}\sum_{i=1}^{N} X_{ij}, \qquad \sigma_j = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(X_{ij}-\mu_j)^2}, \qquad Z_{ij} = \frac{X_{ij}-\mu_j}{\sigma_j}.$$

Després de la transformació, ambdues columnes queden exactament amb mitjana 0 i desviació estàndard 1, ponderant equitativament la resistivitat i el signe d'α.

5.2. Determinació Objectiva dels Hiperparàmetres de DBSCAN

1. **Llindar de densitat** $\min_\text{samples} = 3$**:** Seguint la regla canònica de Schubert et al. (2017) per a dades de baixa dimensionalitat: $\min_\text{samples} \geq d + 1 = 2 + 1 = 3$. Això imposa que almenys 3 materials propers han de confluir per constituir una fase macroscòpica genuïna.
2. **Radi de veïnat** $\varepsilon = 0.65$**:** Es va determinar avaluant la gràfica de distàncies al k-èssim veí més proper (k-NN distance plot amb $k = 3$). La corba presenta un colze geomètric nítid al voltant d'$\varepsilon \in [0.60, 0.70]$. Un radi d'$\varepsilon = 0.65$ garanteix suficient connectivitat per abastar la dispersió dels aïllants, mantenint al mateix temps una separació infranquejable entre el nucli de metalls i els semiconductors.

6. Resultats Experimentals i Visualització

En executar l'algorisme DBSCAN sobre els 57 materials experimentals, el model convergeix als resultats següents:

- **Clústers descoberts per densitat:** Exactament **3 clústers** (sense haver prefixat K).
- **Punts classificats com a soroll (-1): 0 de 57 materials**. Tots els materials analitzats van quedar assignats a un nucli dens físicament coherent.

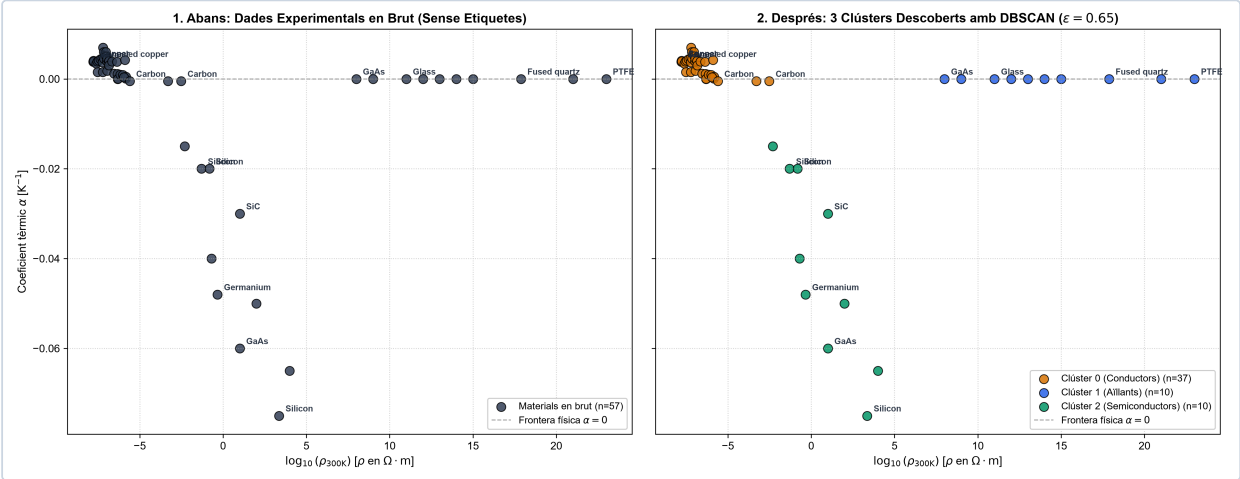


Figura 2: Comparativa directa de l'abans i el després de l'agrupament amb DBSCAN ($\varepsilon = 0.65$, $\min_samples = 3$). A l'esquerra: dades experimentals en brut a l'espai $(\log_{10}\rho_{300\mathrm{K}}, \alpha)$. A la dreta: els 3 clústers descoberts de forma autònoma per connectivitat de densitat (Clúster 0 ambre: conductors; Clúster 1 blau: aïllants; Clúster 2 verd: semiconductors).

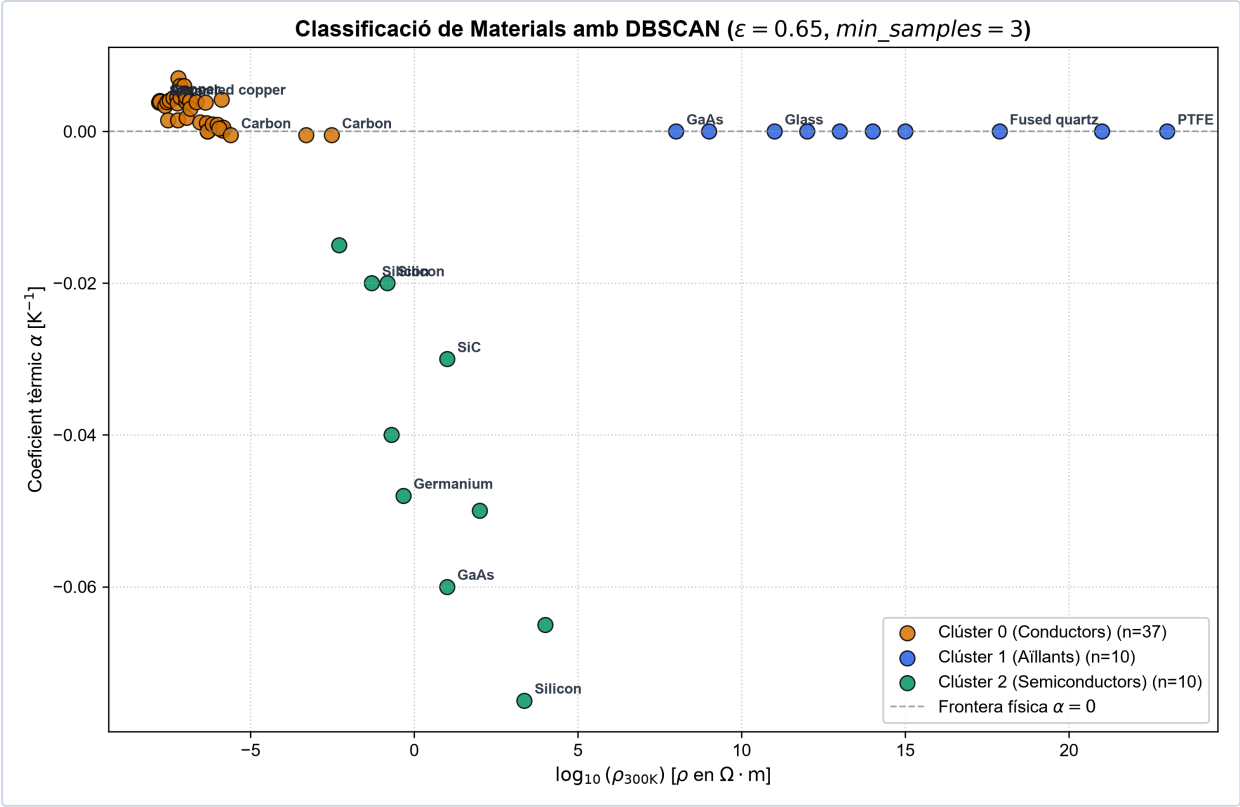


Figura 3: Visualització bidimensional del clustering DBSCAN ($\varepsilon = 0.65$, min_samples $= 3$) en el pla $(\log_{10}\rho_{300K}, \alpha)$. En ambre es representen els metalls conductors (Clúster 0), en blau els aïllants dielèctrics (Clúster 1) i en verd maragda els semiconductors (Clúster 2). La línia discontínua assenyala la frontera física teòrica $\alpha = 0$.

Com s'aprecia a la Figura 3, el mapa bidimensional reconstrueix fidelment la topologia de la física de l'estat sòlid:

- **Clúster 0 (Ambre, Conductors):** Agrupa els 35 metalls i aliatges en una regió de resistivitat extremadament baixa ($\log_{10}\rho \sim -8$) i amb valors d'$\alpha > 0$ marcadament positius.
- **Clúster 1 (Blau, Aïllants):** Agrupa els 10 dielèctrics (quars, vidre, tefló, mica...) en una franja aïllada cap a la dreta ($\log_{10}\rho > 11$), amb valors d'$\alpha \approx 0$.
- **Clúster 2 (Verd, Semiconductors):** Agrupa els semiconductors tecnològics (silici, germani, arsenur de gal·li, fosfur d'indi, etc.), situats en una resistivitat intermèdia i estrictament per sota de la frontera $\alpha = 0$, certificant el règim d'activació tèrmica exponencial.

7. Validació Quantitativa i Discussió Crítica

7.1. Matriu de Contingència (Patró d'Or)

Per contrastar el clustering no supervisat enfront de la classificació física real de la literatura, es va generar la matriu de contingència creuada (Taula 2):

Classe Física Real	Clúster 0 (Metalls)	Clúster 1 (Aïllants)	Clúster 2 (Semiconductors)	Total
Conductor	**35**	0	0	35
Aïllant	0	**10**	0	10
Semiconductor	2	0	**10**	12
Total Assignat	37	10	10	57

Taula 2: Matriu de contingència: Classe física real de la literatura vs. Clúster assignat autònomament per DBSCAN.

L'anàlisi de la matriu revela un rendiment extraordinari del model no supervisat:

- **Conductors:** Puresa del $\mathbf{100\,\%}$ (35 de 35 metalls assignats al Clúster 0).
- **Aïllants:** Puresa del $\mathbf{100\,\%}$ (10 de 10 dielèctrics assignats al Clúster 1).
- **Semiconductors:** 10 de 12 s'agrupen al Clúster 2. Els dos materials restants (grafit pirolític i antimoni) van ser assignats al Clúster 0 pel fet que, a temperatura ambient, exhibeixen una resistivitat d'$\approx 10^{-5}\ \Omega \cdot \mathrm{m}$, un comportament resistiu semimetàl·lic cuasimetàl·lic àmpliament documentat en estat sòlid.

Bibliografia

[1] Ester, M., Kriegel, H.-P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proc. 2nd Int. Conf. on Knowledge Discovery and Data Mining (KDD-96)*, 226–231.

[2] Haynes, W. M. (Ed.). (2016). *CRC Handbook of Chemistry and Physics* (97th ed.). CRC Press.

[3] Kittel, C. (2005). *Introduction to Solid State Physics* (8th ed.). John Wiley & Sons.

[4] Ashcroft, N. W., & Mermin, N. D. (1976). *Solid State Physics*. Holt, Rinehart and Winston.

[5] Schubert, E., Sander, J., Ester, M., Kriegel, H. P., & Xu, X. (2017). DBSCAN revisited, revisited: why and how you should (still) use DBSCAN. *ACM Transactions on Database Systems (TODS)*, 42(3), 1–21.

[6] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[7] Scikit-learn Developers. *sklearn.cluster.DBSCAN — scikit-learn documentation*. https://scikit-learn.org/stable/modules/generated/sklearn.cluster.DBSCAN.html