UNIVERSITAT POLITÈCNICA DE CATALUNYA · ETSETB

Grau en Enginyeria Física · Curs Acadèmic 2026–2027

GUÍA MAESTRA DE DEFENSA ANTE EL TRIBUNAL

Banco Exhaustivo de Preguntas, Demostraciones Teóricas y Respuestas Estratégicas: Problema de Materiales, DBSCAN, K-Means, Isolation Forest, Silhouette Score, Método del Codo y Análisis Comparativo

APRENDIZAJE NO SUPERVISADO | DETECCIÓN DE ANOMALÍAS | PREGUNTAS TRAMPA 🔥 | 35 PREGUNTAS Y RESPUESTAS

Asignatura:	Computer Programming and Its Applications / Programación de Computadores y Sus Aplicaciones (CPIA)
Estudiante / Ponente:	**Uriel Martínez Rosa**
Problema Defendido:	Clasificación No Supervisada de Materiales Eléctricos mediante DBSCAN en el espacio $(\log_{10}\rho_{300K}, \alpha)$
Equipo CPIA:	Martí Canut Sumarroca, Uriel Martínez Rosa, Arnau Montull Bainad, Matías Stein Niell
Propósito Académico:	Entrenamiento integral ante el tribunal evaluador: fundamentación microscópica, derivaciones matemáticas, código Python y límites de cada algoritmo.

1. Estrategia de Defensa Verbal ante el Tribunal

> **Consejo clave para Uriel:** El tribunal evaluará tanto el rigor técnico de la solución como tu aplomo y capacidad de síntesis. Cada pregunta debe estructurarse con la **Técnica de los 3 Tiempos**.

Tiempo de Respuesta	Objetivo Comunicativo	Ejemplo Práctico en Sala
1. Afirmación Directa (0 – 10 segundos)	Responde con un "Sí", "No" o definición tajante. Muestra convicción inmediata y elimina ambigüedades.	*"Utilizamos $\log_{10}\rho$ porque la resistividad eléctrica en la materia condensada abarca más de 30 órdenes de magnitud."*
2. Justificación Física / Algorítmica (10 – 40 segundos)	Aporta el argumento físico o la demostración matemática formal que sostiene tu afirmación.	*"Si usáramos la escala lineal, la distancia euclidiana colapsaría: los conductores ($\sim 10^{-8}$) y semiconductores (~ 1) quedarían indistinguibles frente al teflón (10^{22}), anulando el gradiente métrico."*
3. Límite o Conexión (Solo si el tribunal insiste)	Menciona una alternativa, el caso límite o la conexión con otro método del equipo (DBSCAN vs K-Means).	*"Por eso complementamos la resistividad con el coeficiente térmico α, cuya derivada térmica refleja directamente la presencia o ausencia de brecha prohibida (E_g)."*

Estructura del Banco de Preguntas

Esta guía se organiza en 8 bloques temáticos que cubren desde los fundamentos de estado sólido hasta la complejidad asintótica de los algoritmos:

- **Bloque 1:** El Problema de Uriel – Física de Estado Sólido, Preprocesamiento y Dataset (Preguntas 1 a 7).
- **Bloque 2:** DBSCAN en Profundidad – Topología de Densidad, Hiperparámetros y Complejidad (Preguntas 8 a 12).
- **Bloque 3:** K-Means – Algoritmo de Lloyd, Inercia, Supuestos y Limitaciones (Preguntas 13 a 16).
- **Bloque 4:** Isolation Forest – Detección de Anomalías, Formulación de $c(n)$ y Scores (Preguntas 17 a 22).
- **Bloque 5:** Métricas de Evaluación – Silhouette Score, Método del Codo, Índices DB y CH (Preguntas 23 a 27).
- **Bloque 6:** Clustering Jerárquico (HAC) y Conexión de los 4 Problemas del Equipo (Preguntas 28 a 30).
- **Bloque 7:** Preguntas "De Despacho" y Situaciones de Presión ante el Tribunal (Preguntas 31 a 35).
- **Bloque 8:** Chuleta Resumen de Fórmulas y Mapa Conceptual para la Presentación.

2. Bloque 1: El Problema de Uriel – Física de Estado Sólido y Preprocesamiento

> Este bloque evalúa el rigor físico del modelado, la justificación del espacio de representación bidimensional $(\log_{10}\rho_{300K}, \alpha)$ y el tratamiento matemático de las variables.

Pregunta 1

FUNDAMENTACIÓN MATEMÁTICA / FÍSICA

¿Por qué utilizó el logaritmo en base 10 de la resistividad ($\log_{10}\rho$) en lugar del valor directo de la resistividad (ρ) en escala lineal?

> 🎯 **Respuesta Rápida (30 segundos):** Porque la resistividad eléctrica en la materia condensada es la propiedad macroscópica con mayor rango dinámico de toda la física: abarca más de 30 órdenes de magnitud (desde la plata a $1.59 \times 10^{-8}\,\Omega\cdot\mathrm{m}$ hasta el teflón a $10^{22}\,\Omega\cdot\mathrm{m}$). En escala lineal, la distancia euclidiana colapsaría por completo, haciendo que conductores y semiconductores fueran indistinguibles entre sí al estar aplastados en el cero.

🔬 **Desarrollo Técnico y Demostración:**
Cualquier algoritmo métrico como DBSCAN o K-Means utiliza la norma euclidiana:

$$d(p,q) = \sqrt{(\rho_p - \rho_q)^2 + (\alpha_p - \alpha_q)^2}$$

Si comparamos la plata ($\rho \approx 10^{-8}\,\Omega\cdot\mathrm{m}$), el silicio intrínseco ($\rho \approx 2.3 \times 10^{3}\,\Omega\cdot\mathrm{m}$) y el teflón ($\rho \approx 10^{22}\,\Omega\cdot\mathrm{m}$):

- Distancia lineal plata-silicio: $|10^{-8} - 2300| \approx 2300$.
- Distancia lineal silicio-teflón: $|2300 - 10^{22}| \approx 10^{22}$.

En escala lineal, la distancia plata-silicio relativa a la escala global es $\frac{2300}{10^{22}} = 2.3 \times 10^{-19} \approx 0$. Todo el espacio se convertiría en un único punto concentrado con una anomalía solitaria en 10^{22}.
Al aplicar la transformación logarítmica $\tilde{x}_1 = \log_{10}(\rho)$, el rango se mapea al intervalo acotado $[-8, +22]$ (amplitud total de 30 unidades). En este espacio logarítmico, distancias iguales representan *órdenes de magnitud multiplicativos relativos*, permitiendo discriminar densidades en escalas subatómicas.

> ⚠️ **Qué NO decir:** "Lo hice porque en los tutoriales de Machine Learning siempre se usa el logaritmo cuando los datos son grandes". Debes justificarlo por el *rango de 30 órdenes de magnitud* y el colapso de la distancia euclidiana.

Pregunta 2

FÍSICA CUÁNTICA DEL ESTADO SÓLIDO

¿Cuál es el significado físico microscópico del coeficiente térmico de resistividad (α) y por qué es una firma inequívoca para separar conductores de semiconductores?

🎯 **Respuesta Rápida (30 segundos):** El coeficiente $\alpha = \frac{1}{\rho}\frac{d\rho}{dT}$ mide la variación fraccionaria de la resistividad frente a la temperatura. Su signo discrimina radicalmente el mecanismo de transporte cuántico: en los metales conductores es estrictamente positivo ($\alpha > 0$) porque domina la dispersión creciente electrón-fonón, mientras que en los semiconductores es marcadamente negativo ($\alpha < 0$) debido a la generación térmica exponencial de portadores a través de la brecha prohibida (E_g).

🔬 **Desarrollo Técnico y Demostración:**
A partir del modelo de Drude-Lorentz, la conductividad eléctrica viene dada por $\sigma = \frac{1}{\rho} = ne\mu$, donde n es la densidad de portadores, e la carga fundamental y $\mu = \frac{e\tau}{m^*}$ la movilidad electrónica (τ es el tiempo de relajación medio entre colisiones). La derivada logarítmica respecto a la temperatura es:

$$\alpha = \frac{1}{\rho}\frac{d\rho}{dT} = -\frac{1}{\sigma}\frac{d\sigma}{dT} = -\left(\frac{1}{n}\frac{dn}{dT} + \frac{1}{\mu}\frac{d\mu}{dT}\right)$$

Examinemos los dos regímenes fundamentales:

1. **Conductors (Metalls):** La banda de conducción está semillena (mar de Fermi, $E_g = 0$). La densidad de portadores libres es gigantesca ($n \sim 10^{28}\,\mathrm{m^{-3}}$) y está congelada por la estadística de Fermi-Dirac ($dn/dT \approx 0$). Al subir T, aumenta la población de fonones acústicos según la distribución de Bose-Einstein ($N_q \propto T$), reduciendo el camino libre medio $\ell = v_F\tau$. Por la *Regla de Matthiessen*, la resistividad crece linealmente a $300\,\mathrm{K}$:
$\rho(T) \propto T \implies \frac{d\rho}{dT} > 0 \implies \alpha > 0$ ($+0.003$ a $+0.006\,\mathrm{K^{-1}}$).
2. **Semiconductors:** Presentan una banda prohibida finita ($E_g \sim 0.2$ a $2.0\,\mathrm{eV}$). A $T = 0\,\mathrm{K}$ son aislantes perfectos. A $T > 0$, la excitación térmica promueve electrones a la banda de conducción según la ley de acción de masas:
$$n_i(T) = \sqrt{N_c N_v}\exp\left(-\frac{E_g}{2k_B T}\right)$$
Aunque la movilidad μ disminuye por dispersión fonónica ($\mu \propto T^{-3/2}$), el crecimiento exponencial de portadores supera brutalmente a la pérdida de movilidad:
$$\frac{1}{n}\frac{dn}{dT} = \frac{E_g}{2k_B T^2} \gg \left|\frac{1}{\mu}\frac{d\mu}{dT}\right| \implies \alpha \approx -\frac{E_g}{2k_B T^2} < 0$$
A $300\,\mathrm{K}$, esto genera coeficientes fuertemente negativos ($\alpha \in [-0.07, -0.02]\,\mathrm{K^{-1}}$).
3. **Aïllants (Dielèctrics):** Poseen $E_g > 5\,\mathrm{eV}$. A $300\,\mathrm{K}$, la probabilidad de excitación $\exp(-E_g/2k_BT) \approx \exp(-100) \sim 10^{-44}$, por lo que no hay portadores detectables ($n \approx 0$) y su coeficiente térmico empírico medible es prácticamente nulo ($\alpha \approx 0$).

⚠️ **Qué NO decir:** "Alpha es positivo en metales porque se calientan y negativo en semiconductores porque se enfrían". La temperatura exterior sube en ambos casos; lo que cambia es si se crean portadores o si se frena a los existentes.

Pregunta 3

PREPROCESAMIENTO MATEMÁTICO

¿Por qué es conceptualmente obligatorio aplicar estandarización Z-Score antes de ejecutar DBSCAN si ya había tomado el logaritmo de la resistividad?

🎯 **Respuesta Rápida (30 segundos):** Porque $\log_{10}\rho$ y α poseen unidades físicas, órdenes de dispersión y varianzas completamente incomparables. El rango de $\log_{10}\rho$ abarca 30 unidades (desde -8 hasta $+22$), mientras que el rango de α abarca apenas 0.08 unidades (desde -0.07 hasta $+0.006$). Sin estandarización, la métrica euclidiana de DBSCAN estaría dominada en un 99.9% por la resistividad, degradando el clustering bidimensional a una simple partición unidimensional.

🔬 **Desarrollo Técnico y Demostración:**
En DBSCAN, el entorno de radio ε define una hiperesfera métrica en el espacio de entrada:

$$B_\varepsilon(x) = \{y \in \mathbb{R}^D : \|x - y\|_2 \leq \varepsilon\}$$

La distancia euclidiana no normalizada entre dos materiales i y j es:

$$d(i,j)^2 = (\Delta \log_{10}\rho)^2 + (\Delta\alpha)^2$$

Obsérvese el orden de magnitud de cada término:

- Varianza no escalada de la resistividad: $\sigma^2_{x_1} = \mathrm{Var}(\log_{10}\rho) \approx 58.4$.
- Varianza no escalada del coeficiente térmico: $\sigma^2_{x_2} = \mathrm{Var}(\alpha) \approx 0.00015$.

El ratio de varianzas es $\frac{\sigma^2_{x_1}}{\sigma^2_{x_2}} \approx 380\,000$. En consecuencia, un valor de $\varepsilon = 0.65$ sobre datos en bruto crearía un entorno con forma de "cilindro achatado": abarcaría una milésima de la variación de α pero requeriría variaciones enormes de $\log\rho$, deformando la topología de densidades.
Mediante la estandarización Z-Score:

$$Z_k = \frac{X_k - \mu_k}{\sigma_k}, \quad k \in \{1, 2\}$$

Se impone $\mathbb{E}[Z_k] = 0$ y $\mathrm{Var}(Z_k) = 1$. Esto transforma las hiperesferas de radio ε en el espacio escalado en hiperelipsoides métricamente ponderados de Mahalanobis en el espacio original:

$$d_M(x,y)^2 = (x-y)^T \Sigma^{-1} (x-y)$$

donde $\Sigma = \mathrm{diag}(\sigma^2_{x_1}, \sigma^2_{x_2})$, otorgando idéntico peso geométrico a la física del bandgap (α) y al transporte macroscópico ($\log\rho$).

⚠️ **Qué NO decir:** "Apliqué Z-score porque scikit-learn lo pide por defecto". Scikit-learn ejecuta DBSCAN directamente sobre lo que le pases; la estandarización es una decisión metodológica del ingeniero.

Pregunta 4 · PREGUNTA TRAMPA 🔥 CLASIFICACIÓN FÍSICA VS ALGORITMO

En su matriz de contingencia, el grafito pirolítico y el antimonio fueron clasificados por DBSCAN en el Clúster 0 (Conductors) cuando teóricamente están catalogados como semiconductores/semimetales. ¿Es esto un error o fallo de su modelo no supervisado?

🎯 **Respuesta Rápida (30 segundos):** ¡Rotundamente no es un error! Es una de las pruebas más brillantes de la potencia física del modelo. El grafito y el antimonio son **semimetales**: su estructura de bandas presenta un solapamiento nulo o ligeramente negativo entre la banda de valencia y la de conducción. A temperatura ambiente ($300\,\mathrm{K}$), su resistividad es extremadamente baja ($\approx 10^{-6}\,\Omega\cdot\mathrm{m}$) y su concentración de portadores libres es tan elevada que su transporte eléctrico es indistinguible del de metales pobres como el bismuto o el manganeso. El algoritmo descubrió la física real de transporte en lugar de dejarse engañar por etiquetas nominales.

🔬 **Desarrollo Técnico y Demostración:**
Analicemos los datos empíricos de los dos materiales en cuestión:

Material	$\log_{10}(\rho_{300\mathrm{K}})$	$\alpha\ [\mathrm{K}^{-1}]$	Clase Nominal	Clúster DBSCAN	Estructura Cuántica
Grafito pirolítico	-5.00	-0.00020	Semiconductor	**0 (Conductor)**	Semimetal de Dirac (bandas cruzadas en esquinas de Brillouin)
Antimoni (Sb)	-6.41	$+0.00360$	Semiconductor	**0 (Conductor)**	Semimetal del grupo 15 (solapamiento de bandas $\approx 0.18\,\mathrm{eV}$)

Nótese que:

1. El antimonio tiene $\alpha = +0.0036\,\mathrm{K}^{-1} > 0$. ¡Su resistencia *crece* al calentarse, exactamente como en el cobre o el hierro! Físicamente se comporta como un metal.
2. El grafito pirolítico tiene una resistividad de $10^{-5}\,\Omega\cdot\mathrm{m}$, solo dos órdenes de magnitud por encima del cobre (1.68×10^{-8}) y diez órdenes por debajo del silicio (2.3×10^{3}).

En el espacio estandarizado $(\log_{10}\rho, \alpha)$, la distancia de estos materiales al núcleo de conductores es menor que $\varepsilon = 0.65$. Si DBSCAN los hubiera agrupado con el silicio o el germanio, *eso sí habría sido un error topológico*, porque habría conectado densidades separadas por un vacío métrico de más de 4 desviaciones estándar.

⚠️ **Qué NO decir:** "Es un fallo de DBSCAN porque no teníamos suficientes datos" o "Habría que ajustar los hiperparámetros para forzar que caigan con los semiconductores". Forzar eso destruiría el modelo creando clústeres artificiales.

Pregunta 5

SELECCIÓN DE HIPERPARÁMETROS

¿Cómo justificó formalmente la selección de los hiperparámetros $\varepsilon = 0.65$ y min_samples = 3? ¿Fue por ensayo y error o mediante una regla heurística fundamentada?

🎯 **Respuesta Rápida (30 segundos):** Se fijaron mediante la regla heurística consolidada de Schubert et al. (2017) para DBSCAN: $\text{MinPts} \geq 2 \cdot D$ (donde la dimensión es $D = 2$, lo que sugiere $\text{MinPts} \geq 4$, ajustado conservadoramente a 3 por el tamaño muestral de 57 elementos), combinado con el análisis del **gráfico de k-distancias** con $k = 3$. En dicho gráfico, la curva de distancias presenta un codo de inflexión de densidad en el rango $\varepsilon \in [0.55, 0.75]$, donde la topología de 3 clústeres es invariante y estable.

🔬 **Desarrollo Técnico y Demostración:**
El procedimiento riguroso para sintonizar DBSCAN consta de dos etapas:

1. **Fijación de min_samples (k):** Ester et al. (1996) y Schubert et al. (2017) demostraron que en espacios bidimensionales ruidosos $\text{MinPts} = 4$ es la cota teórica para suprimir fluctuaciones estadísticas locales de Poisson. Al trabajar con datos tabulados del *CRC Handbook* (sin ruido estocástico de medición instrumental), $k = 3$ garantiza que bastan tres materiales con propiedades similares para declarar un núcleo de fase condensada.
2. **Gráfico de k-distancias ($k = 3$):** Para cada punto x_i, se calcula la distancia euclidiana a su 3-ésimo vecino más cercano, $d_3(x_i)$. Se ordenan estas distancias de menor a mayor y se grafican.
   - Los puntos correspondientes a clústeres densos muestran distancias d_3 bajas y una meseta plana ($d_3 \in [0.2, 0.5]$).
   - Los puntos aislados o regiones de transición muestran un crecimiento abrupto (el "codo" de densidad).

   El codo exacto ocurre alrededor de $d_3 \approx 0.65$. Al fijar $\varepsilon = 0.65$, se asegura que todos los puntos dentro de las cuencas de atracción de metales, aislantes y semiconductores queden interconectados por densidad, evitando la fragmentación en micro-clústeres espurios.

⚠️ **Qué NO decir:** "Probé valores al azar hasta que vi 3 colores bonitos en el gráfico". El tribunal penaliza la falta de método sistemático.

Pregunta 6

DETECCIÓN DE ANOMALÍAS / RUIDO

DBSCAN clasifica los puntos de baja densidad como ruido (etiqueta -1). En su resultado final hay exactamente 0 puntos clasificados como ruido (0 de 57). ¿Indica esto que su modelo está sobreajustado o que el radio ε es excesivamente permisivo?

🎯 **Respuesta Rápida (30 segundos):** No indica sobreajuste, sino la coherencia intrínseca de la física de la materia condensada. Las tres fases (conductores, semiconductores y aislantes) no forman un espectro continuo en la naturaleza, sino cuencas discretas de atracción topológica debidas a la cuantización de las bandas de energía. Al haber seleccionado materiales arquetípicos y contrastados de la literatura física (CRC, Kittel), cada material pertenece genuinamente a su fase física y cuenta con al menos dos vecinos representativos en el espacio $(\log \rho, \alpha)$.

🔬 **Desarrollo Técnico y Demostración:**
Para demostrar que $\varepsilon = 0.65$ no es excesivamente permisivo, se realizó un análisis de sensibilidad de hiperparámetros:

- Si $\varepsilon \geq 1.45$: El radio es tan grande que el Clúster 0 (metales) se fusiona con el Clúster 2 (semiconductores), perdiéndose la separación de fases y convergiendo a 2 o 1 clúster.
- Si $\varepsilon \leq 0.40$: El algoritmo se vuelve excesivamente restrictivo y empieza a aislar materiales reales (como el titanio, el carburo de silicio o el diamante) como puntos de ruido (-1), destruyendo la conectividad de los semiconductores.
- En el intervalo $\varepsilon \in [0.55, 0.80]$: La solución es **topológicamente estable**: se mantienen invariantes los 3 clústeres macroscópicos y el ruido permanece en 0.

En aprendizaje no supervisado, una meseta de invariancia paramétrica es la prueba de que el algoritmo ha descubierto una estructura natural del fenómeno físico y no un artefacto de sobreajuste.

⚠️ **Qué NO decir:** "DBSCAN siempre intenta meter todo en algún clúster". Falso: el propósito fundacional de DBSCAN frente a K-Means es precisamente descartar datos atípicos como ruido cuando no alcanzan la densidad crítica.

Pregunta 7

GENERALIZACIÓN E INFERENCIA

Si le proporcionamos un material desconocido a temperatura ambiente, ¿cómo lo clasifica su modelo? ¿Tiene DBSCAN un método predict directo como K-Means?

🎯 **Respuesta Rápida (30 segundos):** DBSCAN estándar en `scikit-learn` es un algoritmo de agrupamiento transductivo, no inductivo: carece de método `predict()` directo porque no almacena centroides ni fronteras paramétricas. Para clasificar una muestra nueva x_{nuevo}, se estandariza con la media μ y desviación σ del entrenamiento, se calculan las distancias a todos los puntos núcleo preexistentes y se le asigna el clúster del punto núcleo más cercano si dicha distancia es $\leq \varepsilon$. Si no dista $\leq \varepsilon$ de ningún punto núcleo, se clasifica como anomalía o ruido (-1).

🔬 **Desarrollo Técnico y Demostración:**
La regla formal de asignación para inferencia inductiva a partir de un modelo DBSCAN ya entrenado es:

$$y(x^*) = \begin{cases} \mathcal{C}(c^*), & \text{si } \min_{c \in \mathcal{K}_{\text{core}}} \|Z(x^*) - Z(c)\|_2 \leq \varepsilon \\ -1, & \text{en cas contrari (soroll / anomalia)} \end{cases}$$

donde $\mathcal{K}_{\text{core}}$ es el subconjunto de muestras que alcanzaron la condición de punto núcleo durante el entrenamiento ($|N_\varepsilon(c)| \geq \text{min_samples}$), y c^* es el núcleo más próximo a x^*.
Esta formulación tiene dos ventajas capitales:

1. Preserva la capacidad de detectar **nuevas fases o anomalías**: si introducimos un superconductor a $300\,\text{K}$ con $\rho = 0$ y $\alpha = 0$, la distancia a los metales superará ε y será detectado inmediatamente como anomalía física (-1).
2. Evita la distorsión del modelo original al no obligar a la nueva muestra a alterar los núcleos ya descubiertos.

⚠️ **Qué NO decir:** "Sí, simplemente llamo a `dbscan.predict(nuevo_punto)`". Ese método no existe en DBSCAN de `scikit-learn` y si lo dices ante el tribunal revelará que no conoces la API de la biblioteca.

3. Bloque 2: DBSCAN en Profundidad – Topología de Densidad y Complejidad

> Este bloque evalúa el dominio riguroso del algoritmo DBSCAN (Ester et al., 1996), sus definiciones matemáticas fundamentales, su comportamiento topológico y su complejidad computacional.

Pregunta 8

DEFINICIONES FORMALES DEL ALGORITMO

Explique las definiciones matemáticas formales de Punto Núcleo (Core Point), Punto de Borde (Border Point) y Punto de Ruido (Noise Point) en DBSCAN.

🎯 **Respuesta Rápida (30 segundos):** Dado un espacio métrico (X, d), un radio de vecindad $\varepsilon > 0$ y un umbral $\text{MinPts} \geq 1$, el ε-vecindario de un punto p es $N_\varepsilon(p) = \{q \in X \mid d(p,q) \leq \varepsilon\}$. A partir de ahí:

1. **Punto Núcleo (Core):** $|N_\varepsilon(p)| \geq \text{MinPts}$ (tiene suficiente masa local).
2. **Punto de Borde (Border):** $|N_\varepsilon(p)| < \text{MinPts}$, pero pertenece al vecindario de algún punto núcleo ($p \in N_\varepsilon(c)$ con c núcleo).
3. **Punto de Ruido (Noise):** No es núcleo ni pertenece al vecindario de ningún núcleo (-1).

🔬 **Desarrollo Técnico y Demostración:**
La elegancia de DBSCAN radica en que descompone el conjunto de datos X en una partición de puntos interiores (núcleos), frontera (borde) y exterior (ruido):

$$X = \mathcal{K}_{\text{core}} \cup \mathcal{K}_{\text{border}} \cup \mathcal{K}_{\text{noise}}, \quad \text{con disyunción dos a dos}$$

A diferencia de los métodos de particionado espacial estricto (como K-Means o Voronoi), la inclusión de $\mathcal{K}_{\text{noise}}$ otorga a DBSCAN una **función de corte de densidad**: no intenta optimizar el coste de asignar puntos atípicos a algún centroide forzado, lo que lo hace inmune a la distorsión por valores extremos.

⚠️ **Qué NO decir:** "Un punto de borde es un punto que está lejos". Debe definirse formalmente: tiene menos de MinPts vecinos pero cae dentro del radio ε de un núcleo.

Pregunta 9

TOPOLOGÍA MATEMÁTICA

¿Cuál es la diferencia entre densidad-alcanzabilidad y densidad-conectividad en DBSCAN? ¿Por qué la primera no es simétrica y la segunda sí?

🎯 **Respuesta Rápida (30 segundos):** La *densidad-alcanzabilidad* es una relación dirigida: un punto q es directamente alcanzable por densidad desde p si p es núcleo y $q \in N_\varepsilon(p)$. No es simétrica porque si q es un punto de borde, p no es alcanzable desde q (ya que q no puede propagar densidad). Para solucionar esto y definir clústeres como clases de equivalencia, se define la *densidad-conectividad*: dos puntos p y q son densidad-conectados si existe un tercer punto núcleo común o desde el cual ambos son densidad-alcanzables. Esta relación sí es reflexiva y simétrica.

🔬 **Desarrollo Técnico y Demostración:**

1. **Densidad-alcanzable directamente ($p \to_1 q$):** $p \in \mathcal{K}_{\text{core}}$ y $q \in N_\varepsilon(p)$. Si q es borde ($q \notin \mathcal{K}_{\text{core}}$), entonces $q \not\to_1 p$. Por tanto, $\to_1$ **no es simétrica**.
2. **Densidad-alcanzable en cadena ($p \to_* q$):** Existe una secuencia de puntos $p_1, p_2, \ldots, p_n$ con $p_1 = p$ y $p_n = q$ tal que $p_i \to_1 p_{i+1}$ para todo i. Si el último punto p_n es de borde, la cadena no puede invertirse hacia atrás.
3. **Densidad-conectividad ($p \sim q$):** $\exists o \in \mathcal{K}_{\text{core}}$ tal que $o \to_* p$ y $o \to_* q$.

$$p \sim q \iff \exists o \in X : (o \to_* p) \land (o \to_* q)$$

Como la existencia de o es independiente del orden de evaluación, $p \sim q \iff q \sim p$ (**simetría garantizada**).

Gracias a la densidad-conectividad, un **clúster** en DBSCAN se define formalmente como un subconjunto maximal no vacío $C \subseteq X$ que satisface:

- **Maximalidad:** $\forall p, q \in X$, si $p \in C$ y $p \to_* q$, entonces $q \in C$.
- **Conectividad:** $\forall p, q \in C$, $p \sim q$.

⚠️ **Qué NO decir:** "Son lo mismo pero con palabras diferentes". Son conceptos topológicos formales que permiten definir clases de equivalencia matemática sobre grafos de vecindad.

Pregunta 10

COMPLEJIDAD COMPUTACIONAL Y ALGORITMOS

¿Cuál es la complejidad algorítmica temporal y espacial de DBSCAN? ¿Cómo varía en función de la dimensionalidad y las estructuras de datos espaciales empleadas?

🎯 **Respuesta Rápida (30 segundos):** La complejidad espacial es siempre $\mathcal{O}(n)$. La complejidad temporal depende de cómo se ejecuten las consultas de rango de radio ε:

- **Fuerza bruta (matriz de distancias completa):** $\mathcal{O}(n^2)$ siempre.
- **Con indexación espacial (k-d trees o Ball Trees):** $\mathcal{O}(n \log n)$ en dimensiones bajas ($d \leq 10$).
- **En alta dimensión ($d \gg 20$):** La indexación espacial degenera a búsqueda lineal por la *maldición de la dimensionalidad*, volviendo a $\mathcal{O}(n^2)$.

🔬 **Desarrollo Técnico y Demostración:**
El algoritmo recorre cada uno de los n puntos exactamente una vez. Para cada punto, debe responder a la consulta de vecindad: ¿cuántos puntos caen dentro del radio ε?

Estructura de Datos	Coste de Consulta Vecindad	Complejidad Temporal Total	Condición de Rendimiento Óptimo
Sin índice (Fuerza bruta)	$\mathcal{O}(n)$	$\mathcal{O}(n^2)$	Siempre aplicable, intensivo en memoria si se precalcula la matriz.
k-d Tree	$\mathcal{O}(\log n)$	$\mathcal{O}(n \log n)$	Excelente para $D = 2$ (como nuestro espacio de materiales $(\log \rho, \alpha)$).
Ball Tree	$\mathcal{O}(\log n)$	$\mathcal{O}(n \log n)$	Excelente para métricas no euclidianas (como Haversine en el problema de Arnau).
Alta dimensión ($D > 50$)	$\mathcal{O}(n)$	$\mathcal{O}(n^2)$	La distancia de todos los puntos al centro de la celda se vuelve idéntica.

En nuestro problema de materiales ($n = 57, D = 2$), la ejecución con k-d tree toma menos de 2 milisegundos.

⚠️ **Qué NO decir:** "DBSCAN siempre es $\mathcal{O}(n \log n)$". Solo lo es si se utiliza un árbol de partición espacial y la dimensión es moderada.

Pregunta 11

LIMITACIONES TEÓRICAS DEL ALGORITMO

¿Cuáles son las dos limitaciones teóricas más graves de DBSCAN y qué algoritmos modernos se desarrollaron para superarlas (OPTICS y HDBSCAN)?

🎯 **Respuesta Rápida (30 segundos):** Las dos grandes debilidades de DBSCAN son:

1. **Incapacidad para manejar clústeres con densidades locales muy diferentes:** al utilizar un único ε global, si un clúster es muy disperso y otro muy denso, un ε grande fusionará los densos y uno pequeño marcará el disperso como ruido.
2. **Sensibilidad crítica a la elección del hiperparámetro ε:** no existe una escala intrínseca única.

Para solucionar esto, se crearon **OPTICS** (que genera un gráfico de alcanzabilidad multiescala) y **HDBSCAN** (que construye una jerarquía de densidades sobre árboles de expansión mínima y extrae los clústeres con mayor estabilidad de persistencia sin fijar ε).

🔬 **Desarrollo Técnico y Demostración:**

- **El problema de la densidad no uniforme:** Supongamos dos grupos C_A y C_B. La densidad de C_A es $\rho_A = 100\,\text{puntos/unidad}^2$ (distancia media 0.1), mientras que en C_B es $\rho_B = 5\,\text{puntos/unidad}^2$ (distancia media 0.8). Si fijamos $\varepsilon = 0.3$, C_A se detecta como clúster perfecto, pero todo C_B se destruye como ruido. Si fijamos $\varepsilon = 0.9$, C_B se recupera, pero C_A puede fusionarse con ruido circundante.
- **La solución HDBSCAN (Campello et al., 2013):** Transforma el espacio calculando la *distancia de alcanzabilidad mutua*:

$$d_{\text{mreach}-k}(a,b) = \max\{\text{core}_k(a), \text{core}_k(b), d(a,b)\}$$

  Construye un árbol de expansión mínima (MST) y lo compacta en un dendrograma jerárquico. Luego, calcula la **estabilidad** de cada clúster $\lambda = 1/\varepsilon$ midiendo cuánto "persiste" el clúster antes de dividirse, seleccionando las componentes más estables sin que el usuario tenga que adivinar ε.

⚠️ **Qué NO decir:** "DBSCAN es perfecto y no tiene ninguna limitación". Todo modelo tiene fronteras de validez, y conocer OPTICS/HDBSCAN demuestra madurez investigadora.

Pregunta 12

ANÁLISIS COMPARATIVO DEL EQUIPO CPIA

¿Qué diferencia metodológica y matemática fundamental existe entre el DBSCAN que usted utilizó para materiales y el DBSCAN que utilizó Arnau Montull para detectar ensayos nucleares?

🎯 **Respuesta Rápida (30 segundos):** La diferencia crítica radica en la **métrica de distancia subyacente y la topología del espacio de características**:

- **Uriel (Materiales):** Espacio euclidiano abstracto 2D $(\log_{10}\rho, \alpha)$ estandarizado con Z-score, donde la métrica es la norma euclidiana L_2 adimensional y la densidad refleja leyes de transporte cuántico.
- **Arnau (Sismos / Ensayos nucleares):** Espacio esférico bidimensional $(\text{latitud}, \text{longitud})$ medido sobre la superficie de la Tierra, donde la métrica euclidiana comete errores graves de distorsión y se sustituye obligatoriamente por la **distancia ortodrómica de Haversine** con radio terrestre $R \approx 6\,371\,\text{km}$.

🔬 **Desarrollo Técnico y Demostración:**
La fórmula de Haversine empleada por Arnau para calcular la distancia sobre la esfera terrestre entre dos epicentros (ϕ_1, λ_1) y (ϕ_2, λ_2) en radianes es:

$$d_H = 2R \arcsin\left(\sqrt{\sin^2\left(\frac{\Delta\phi}{2}\right) + \cos(\phi_1)\cos(\phi_2)\sin^2\left(\frac{\Delta\lambda}{2}\right)}\right)$$

Si Arnau hubiera utilizado la métrica euclidiana tradicional en coordenadas angulares:

$$d_{\text{euc}} = \sqrt{(\Delta\phi)^2 + (\Delta\lambda)^2}$$

un grado de longitud en el ecuador ($111.32\,\text{km}$) equivaldría al mismo valor métrico que un grado de longitud en el polígono nuclear de Novaya Zemlya a $75°\,\text{N}$ ($111.32 \times \cos(75°) \approx 28.8\,\text{km}$), deformando artificialmente los clústeres en los polos un 400%.
En mi caso (materiales), el espacio euclidiano Z-score es estrictamente ortogonal y plano, por lo que la norma euclidiana es físicamente exacta una vez normalizadas las varianzas.

⚠️ **Qué NO decir:** "Los dos usamos el mismo código de DBSCAN exactamente igual". Ambos usaron `sklearn.cluster.DBSCAN`, pero Arnau configuró `metric='haversine'` y convirtió a radianes, mientras que yo utilicé `metric='euclidean'` tras Z-score.

4. Bloque 3: K-Means y Métodos Particionales – Algoritmo de Lloyd e Inercia

> Este bloque evalúa el conocimiento de los métodos particionales basados en centroides, su formulación matemática de optimización, sus hipótesis implícitas y por qué fallan ante geometrías complejas o datos con ruido.

Pregunta 13

OPTIMIZACIÓN MATEMÁTICA / LLOYD

Describa el algoritmo estándar de Lloyd para K-Means. ¿Cuál es formalmente la función objetivo que optimiza y por qué no garantiza alcanzar el mínimo global?

🎯 **Respuesta Rápida (30 segundos):** K-Means optimiza la **Inercia** o Suma de Cuadrados Intra-Clúster (**WCSS**):

$$J = \sum_{k=1}^{K} \sum_{x \in S_k} \|x - \mu_k\|^2$$

Funciona alternando dos pasos deterministas hasta la convergencia:

1. **Paso de Asignación (Voronoi):** Cada muestra se asigna al centroide μ_k más cercano.
2. **Paso de Actualización:** Se recalcula cada μ_k como el baricentro de su clúster: $\mu_k = \frac{1}{|S_k|} \sum_{x \in S_k} x$.

No garantiza el mínimo global porque el problema de particionado óptimo es **NP-hard**; Lloyd realiza un descenso de gradiente por coordenadas discretas que converge a un **mínimo local** fuertemente dependiente de la inicialización de los centroides iniciales.

🔬 **Desarrollo Técnico y Demostración:**
Demostración de que la actualización baricéntrica minimiza J: Fijada la partición S_k, derivamos J respecto a un centroide genérico μ_k:

$$\nabla_{\mu_k} J = \nabla_{\mu_k} \sum_{x \in S_k} (x - \mu_k)^T (x - \mu_k) = -2 \sum_{x \in S_k} (x - \mu_k) = 0$$

Despejando μ_k:

$$\sum_{x \in S_k} x = \sum_{x \in S_k} \mu_k = |S_k| \mu_k \implies \mu_k^* = \frac{1}{|S_k|} \sum_{x \in S_k} x$$

Como la matriz hessiana es $\mathcal{H} = 2|S_k|\mathbb{I} > 0$ (estrictamente definida positiva), la media muestral minimiza globalmente el error cuadrático intra-clúster para esa partición fija.
Sin embargo, en cada paso el espacio de particiones discretas es de cardinalidad $S(n, K) = \frac{1}{K!} \sum_{j=0}^{K} (-1)^{K-j} \binom{K}{j} j^n$ (números de Stirling de segunda clase). Para $n = 57, K = 3$, existen más de 10^{26} particiones posibles. El algoritmo de Lloyd solo explora una trayectoria monotónica decreciente en el paisaje de energía, quedando atrapado en mínimos locales subóptimos si la inicialización no es idónea.

> ⚠️ **Qué NO decir:** "K-Means siempre encuentra la mejor solución posible". Siempre converge, pero casi nunca al óptimo global salvo que se use una inicialización privilegiada como K-Means++.

Pregunta 14

SUPUESTOS GEOMÉTRICOS E HIPÓTESIS

¿Cuáles son los supuestos matemáticos y geométricos implícitos de K-Means que restringen severamente su aplicabilidad en problemas científicos?

🎯 **Respuesta Rápida (30 segundos):** K-Means asume cuatro hipótesis críticas:

1. **Convexidad y esfericidad:** Asume que los clústeres son hiperesferas convexas e isotrópicas. Falla ante formas alargadas, filamentosas o en semiluna.
2. **Varianza homogénea:** Asume que todos los clústeres tienen una dispersión espacial similar.
3. **Equipoblación relativa:** Tiende a dividir artificialmente clústeres grandes para equilibrar el número de elementos.
4. **Ausencia de ruido / Partición exhaustiva:** Fuerza a que *absolutamente todos los puntos* pertenezcan a un clúster, absorbiendo anomalías extremas dentro de los centroides.

🔬 **Desarrollo Técnico y Demostración:**
Desde el punto de vista probabilístico, K-Means es equivalente a un **Modelo de Mezclas Gaussianas (GMM)** bajo tres restricciones extremas:

$$p(x \mid C_k) = \mathcal{N}(x \mid \mu_k, \Sigma_k), \quad \text{donde } \Sigma_k = \sigma^2 \mathbb{I} \quad \forall k, \quad \text{y } \sigma^2 \to 0$$

Es decir, todas las covarianzas son matrices diagonales idénticas proporcionales a la identidad (esfericidad perfecta) y las probabilidades a priori son uniformes ($P(C_k) = 1/K$).
Geométricamente, el paso de asignación de K-Means particiona el espacio en un **diagrama de Voronoi**: las fronteras entre clústeres son necesariamente hiperplanos afines lineales:

$$H_{ij} = \{x \in \mathbb{R}^D : 2(\mu_i - \mu_j)^T x = \|\mu_i\|^2 - \|\mu_j\|^2\}$$

En la física de estado sólido o en la geofísica, las fronteras naturales casi nunca son hiperplanos afines, sino regiones de densidad cuántica o fracturas tectónicas curvilíneas.

⚠️ **Qué NO decir:** "K-Means funciona bien para cualquier conjunto de datos si se elige bien K". Funciona bien *únicamente* cuando los clústeres son esferoidales y están bien aislados.

Pregunta 15

ALGORITMO K-MEANS++

¿Cómo funciona la inicialización K-Means++ (Arthur & Vassilvitskii, 2007) y qué garantía teórica ofrece respecto a la inicialización aleatoria tradicional?

🎯 **Respuesta Rápida (30 segundos):** K-Means++ sustituye la elección de centroides puramente aleatoria por un esquema probabilístico donde los nuevos centroides se eligen con probabilidad proporcional al cuadrado de la distancia a su centroide más cercano ya existente:

$$P(x) = \frac{D(x)^2}{\sum_{y \in X} D(y)^2}$$

Esto asegura que los centroides iniciales queden lo más separados posible entre sí en el espacio. Su ventaja teórica es monumental: garantiza una cota superior de aproximación de $\mathcal{O}(\log K)$ respecto a la inercia del óptimo global:

$$\mathbb{E}[J] \leq 8(\ln K + 2)J^*$$

🔬 **Desarrollo Técnico y Demostración:**
El algoritmo K-Means++ procede en 4 pasos:

1. Elegir el primer centroide μ_1 de forma uniformemente aleatoria entre los datos de X.
2. Para cada muestra $x \in X$, calcular $D(x) = \min_j \|x - \mu_j\|_2$ (la menor distancia a cualquiera de los centroides ya elegidos).
3. Elegir un nuevo centroide $\mu_{m+1} = x$ muestreando con probabilidad ponderada $P(x) \propto D(x)^2$.
4. Repetir los pasos 2 y 3 hasta haber seleccionado los K centroides iniciales, para luego proceder con las iteraciones estándar de Lloyd.

Al ponderar con $D(x)^2$, si dos candidatos están cerca de centroides ya establecidos, su probabilidad de selección es infinitesimal. En cambio, si un grupo denso aún no tiene centroide, sus puntos acumulan un valor elevado de $D(x)^2$, garantizando que prácticamente cada clúster natural reciba un centroide inicial.

⚠️ **Qué NO decir:** "K-Means++ garantiza que siempre encuentras el mínimo global absoluto". Garantiza una *cota esperada de aproximación* $\mathcal{O}(\log K)$, que evita soluciones catastróficas, pero sigue siendo una heurística estocástica.

Pregunta 16 · PREGUNTA TRAMPA 🔥 COMPARACIÓN METODOLÓGICA DIRECTA

Si ya sabía a priori que la física clasifica los materiales en tres fases (Conductors, Semiconductors, Aïllants), ¿por qué no aplicó directamente K-Means con $K = 3$ en lugar de DBSCAN? ¿Qué problemas concretos habría tenido?

🎯 **Respuesta Rápida (30 segundos):** Aplicar K-Means ($K = 3$) habría sido metodológicamente deficiente por dos razones físicas y matemáticas:

1. **Asimetría y dispersión alargada de los semiconductores:** Los semiconductores tienen una distribución muy elongada en el plano $(\log \rho, \alpha)$, ya que su resistividad abarca desde 10^{-4} hasta $10^{6}\ \Omega \cdot \mathrm{m}$ y α es fuertemente negativo. K-Means, al imponer celdas de Voronoi convexas, habría cortado la familia de semiconductores por la mitad, asignando los semiconductores de baja resistividad al centroide de metales y los de alta resistividad al de aislantes.
2. **Sensibilidad a casos extremos sin noción de ruido:** Si se introdujera un material anómalo (como un superconductor o un dieléctrico extremo), K-Means desplazaría violentamente la posición del centroide global para acomodarlo, falseando la clasificación de materiales estándar. DBSCAN preservó la conectividad de densidad y no necesitó imponer $K = 3$ de forma artificial.

🔬 **Desarrollo Técnico y Demostración:**
En la física del estado sólido, el salto cuántico entre metales (mar de Fermi continuo) y semiconductores (bandgap térmicamente activable) genera un "cuello de botella" de densidad.
DBSCAN reconoce este cuello de botella como una región donde la distancia entre materiales supera el radio $\varepsilon = 0.65$, deteniendo la propagación del clúster de forma natural e intrínseca.
K-Means, al carecer de noción de densidad local, simplemente calcula un hiperplano equidistante entre los centroides μ_{metal} y μ_{semicond}. Si añadimos más metales al dataset, el centroide μ_{metal} se movería hacia la izquierda, y el hiperplano divisorio se desplazaría hacia los semiconductores, reclasificando materiales de una fase a otra arbitrariamente en función del tamaño muestral relativo. DBSCAN es inmune a este sesgo porque las fronteras de clúster se fijan por el límite de densidad local, no por el balance de masas globales.

⚠️ **Qué NO decir:** "No usé K-Means porque el profesor me dijo que usara DBSCAN". La respuesta debe ser puramente metodológica: geometría elongada, sesgo de tamaño y ausencia de ruido.

5. Bloque 4: Isolation Forest y Detección de Anomalías – Principio, Deducción y Score

> Este bloque evalúa el dominio de las técnicas modernas de detección de anomalías sin supervisión, centrándose en el algoritmo de Isolation Forest (Liu, Ting & Zhou, 2008), su formulación matemática y su contraste con métodos de distancia y densidad.

Pregunta 17

PRINCIPIO FUNDAMENTAL DEL ALGORITMO

Explique el principio fundamental de Isolation Forest. ¿Por qué se considera un cambio de paradigma conceptual frente a los métodos clásicos de detección de anomalías basados en densidad o distancia?

> 🎯 **Respuesta Rápida (30 segundos):** Los métodos clásicos (como One-Class SVM, Local Outlier Factor o DBSCAN) intentan modelar primero el perfil de los datos "normales" (densidades altas o envolventes convexas) y luego clasifican como anomalía todo lo que quede fuera. **Isolation Forest invierte completamente este principio:** no modela lo normal, sino que **aísla directamente las anomalías** mediante árboles binarios de corte aleatorio. Como las anomalías son cuantitativamente *pocas* y cualitativamente *diferentes*, quedan aisladas muy cerca de la raíz del árbol (profundidades de partición muy bajas).

🔬 **Desarrollo Técnico y Demostración:**
El algoritmo construye un conjunto de t árboles de aislamiento aleatorios (*iTrees*). En cada nodo de un *iTree*:

1. Se selecciona uniformemente al azar una característica $q \in \{1, \ldots, D\}$.
2. Se selecciona uniformemente al azar un valor de corte p dentro del rango actual de dicha característica en el nodo: $p \in [\min(X_{*,q}), \max(X_{*,q})]$.
3. Se divide el espacio con el hiperplano ortogonal $x_q < p$, creando dos hijos izquierdo y derecho.
4. El proceso se repite recursivamente hasta que una muestra queda aislada en una hoja o se alcanza una profundidad máxima $h_{\max} = \lceil \log_2(\psi) \rceil$, donde ψ es el tamaño de submuestra (típicamente $\psi = 256$).

Propiedad geométrica: En un grupo denso de puntos normales, se requieren decenas de cortes aleatorios para separar un punto de sus congéneres. En cambio, un punto anómalo, al estar situado en una región de bajo soporte volumétrico, tiene una probabilidad geométrica altísima de ser separado en los primeros 2 o 3 cortes aleatorios.

> ⚠️ **Qué NO decir:** "Isolation Forest es un Random Forest que predice anomalías". No es un algoritmo supervisado ni clasifica clases; construye particiones puramente aleatorias no guiadas por etiquetas.

Pregunta 18

DEDUCCIÓN MATEMÁTICA FORMAL

Deduzca y justifique la fórmula matemática del Anomaly Score en Isolation Forest. ¿Qué representa la constante $c(n)$ y por qué proviene de la teoría de árboles binarios de búsqueda (BST)?

🎯 **Respuesta Rápida (30 segundos):** El Anomaly Score de una muestra x sobre una submuestra de tamaño n se define como:

$$s(x,n) = 2^{-\frac{\mathbb{E}[h(x)]}{c(n)}}$$

donde $h(x)$ es la longitud de camino (número de aristas desde la raíz hasta la hoja donde queda aislado x) y $\mathbb{E}[h(x)]$ es su promedio sobre el bosque. El término $c(n)$ es el **factor de normalización** que representa la longitud de camino media esperada en un Árbol Binario de Búsqueda (BST) no exitoso:

$$c(n) = 2\ln(n-1) + 2\gamma - \frac{2(n-1)}{n}$$

donde $\gamma \approx 0.5772156649$ es la constante de Euler-Mascheroni.

🔬 **Desarrollo Técnico y Demostración:**
La estructura de un *iTree* es estocásticamente equivalente a la inserción de claves aleatorias en un Árbol Binario de Búsqueda (BST). En la teoría clásica de estructuras de datos (Knuth, 1998; Flajolet & Sedgewick), la longitud media de búsqueda infructuosa en un BST construido con n elementos equivale a la profundidad esperada de un nodo externo:
A partir de los números armónicos $H_k = \sum_{i=1}^{k} \frac{1}{i} = \ln(k) + \gamma + \mathcal{O}\left(\frac{1}{k}\right)$:

$$c(n) = 2H_{n-1} - \frac{2(n-1)}{n} = 2\left(\ln(n-1) + 0.5772156649\right) - \frac{2(n-1)}{n}$$

Como $c(n)$ es la profundidad esperada promedio de un conjunto de n puntos aleatorios, el ratio:

$$r(x) = \frac{\mathbb{E}[h(x)]}{c(n)}$$

es una medida adimensional y normalizada que compara la facilidad de aislamiento de x frente a la de un conjunto genérico aleatorio. La función exponencial en base 2, $s(x,n) = 2^{-r(x)}$, acota monótonamente el resultado en el intervalo abierto $(0,1)$, permitiendo fijar umbrales estadísticos universales independientes de la escala o tamaño del dataset.

⚠️ **Qué NO decir:** "El score es simplemente la profundidad dividida por n". La relación no es lineal, es exponencial en base 2 normalizada por la función armónica de búsqueda de árboles binarios $c(n)$.

Pregunta 19

INTERPRETACIÓN CUANTITATIVA

¿Cómo se interpreta cuantitativamente el valor del score de anomalía $s(x, n)$ en la práctica? ¿Cuáles son los tres regímenes característicos?

🎯 **Respuesta Rápida (30 segundos):** El score está confinado en $s \in [0, 1]$ con tres zonas de decisión universales:

1. **$s(x, n) \to 1$ (típicamente $s > 0.60$):** La muestra se aísla a una profundidad media $\mathbb{E}[h(x)] \ll c(n)$. Es una **anomalía inequívoca**.
2. **$s(x, n) < 0.5$:** La muestra requiere una profundidad $\mathbb{E}[h(x)] \gg c(n)$ para ser aislada. Es un **punto normal** perteneciente al núcleo denso.
3. **$s(x, n) \approx 0.5$ en todas las muestras:** Si todo el dataset arroja puntuaciones cercanas a 0.5, significa que el conjunto de datos **carece de anomalías detectables** y es homogéneamente uniforme.

🔬 **Desarrollo Técnico y Demostración:**

Analicemos los límites matemáticos de la función $s(x, n) = 2^{-\frac{\mathbb{E}[h]}{c(n)}}$:

- Si $\mathbb{E}[h] \to 0$ (el punto se separa en el primer corte): $s = 2^{-0} = 1$.
- Si $\mathbb{E}[h] = c(n)$ (la profundidad promedio del punto coincide exactamente con la media esperada del bosque aleatorio): $s = 2^{-1} = 0.5$.
- Si $\mathbb{E}[h] \to n - 1$ (el punto está enterrado en el nodo más profundo del árbol): $s = 2^{-\frac{n-1}{c(n)}} \to 0$.

En `scikit-learn`, la función `IsolationForest.decision_function(X)` aplica un desplazamiento lineal para que los valores negativos indiquen anomalías y los positivos normalidad:

$$\text{score}_{\text{sklearn}}(x) = 0.5 - s(x, n)$$

por lo que si $\text{score}_{\text{sklearn}}(x) < 0$, la muestra se etiqueta como -1 (outlier).

⚠️ **Qué NO decir:** "0.5 significa que hay un 50% de probabilidad de que sea anomalía". En Isolation Forest el score no es una probabilidad bayesiana, sino un ratio de profundidad de árbol.

Pregunta 20

COMPLEJIDAD Y ESCALABILIDAD

¿Cuáles son las ventajas computacionales y de escalabilidad de Isolation Forest frente a métodos basados en distancias como LOF (Local Outlier Factor) o kNN?

🎯 **Respuesta Rápida (30 segundos):** Isolation Forest tiene una complejidad temporal **lineal en el número de muestras** $\mathcal{O}(t \cdot \psi \log \psi)$ durante el entrenamiento y $\mathcal{O}(t \cdot \log \psi)$ por muestra en inferencia, donde ψ (submuestra) y t (número de árboles) son constantes fijas independientes de n. En contraste, LOF y kNN requieren calcular distancias por pares, con complejidad cuadrática $\mathcal{O}(n^2)$ e intensivo uso de memoria $\mathcal{O}(n^2)$, volviéndose impracticables para millones de registros.

🔬 **Desarrollo Técnico y Demostración:**

A diferencia de los métodos supervisados de ensamble donde se requieren miles de muestras para reducir la varianza, en Isolation Forest un tamaño de submuestra $\psi = 256$ es matemáticamente suficiente para aislar anomalías en la inmensa mayoría de distribuciones. Al fijar $\psi = 256$ y $t = 100$ árboles:

- Entrenar un bosque requiere construir t árboles de altura $\log_2(\psi) = 8$. El coste total es $100 \times 256 \times 8 \approx 2 \times 10^5$ operaciones elementales, ¡independientemente de si el dataset original tiene 10.000 o 10.000.000 de registros!
- Además, al no calcular normas euclidianas globales, es inmune a la degradación de distancias en alta dimensión y puede ejecutarse sobre cientos de características sin pérdida de eficiencia.

⚠️ **Qué NO decir:** "Isolation Forest es más rápido porque es un algoritmo de árbol como CART". No optimiza impurezas de Gini ni entropías, lo que lo hace varios órdenes de magnitud más veloz que un Random Forest convencional.

Pregunta 21 · PREGUNTA TRAMPA 🔥 ADECUACIÓN AL PROBLEMA DE MATERIALES

Si Isolation Forest es un algoritmo tan eficiente para aprendizaje no supervisado, ¿por qué no lo utilizó usted en lugar de DBSCAN para clasificar los materiales eléctricos?

🎯 **Respuesta Rápida (30 segundos):** Porque **Isolation Forest es un detector de anomalías, no un algoritmo de clustering**. Su objetivo fundacional es separar casos aislados de un fondo homogéneo, no descubrir la estructura interna de múltiples fases condensadas. Si hubiéramos aplicado Isolation Forest a nuestro dataset de materiales, habría marcado materiales perfectamente legítimos con valores extremos (como el teflón con $\rho = 10^{22}\,\Omega\cdot\mathrm{m}$, o los semimetales) como "anomalías indeseables", destruyendo la fase de aislantes en lugar de agruparla coherentemente como una fase física con significado cuántico propio.

🔬 **Desarrollo Técnico y Demostración:**
En nuestro problema, los aislantes son materiales con una brecha prohibida gigante ($E_g > 5\,\mathrm{eV}$). Dentro de la física, el teflón, la porcelana, el vidrio y el cuarzo forman una **fase legítima de la naturaleza**, no un "error de medida" o "fraude".
DBSCAN reconoce a los aislantes como un clúster densamente conectado en la región $\log_{10}\rho \geq 11, \alpha \approx 0$.
Isolation Forest, por su formulación de corte aleatorio, al ver que el teflón está a 10 órdenes de magnitud del vidrio, habría aislado al teflón en el primer corte ($h = 1$), arrojando un score $s \approx 0.95$ y catalogándolo como "anomalía". En ciencia de materiales, etiquetar al teflón como anomalía es un sinsentido conceptual: el objetivo era la **estratificación en clases de equivalencia de transporte**, tarea para la cual los algoritmos basados en conectividad de densidad (DBSCAN) son la herramienta óptima.

⚠️ **Qué NO decir:** "No lo usé porque no sabía cómo programarlo". La respuesta debe fundamentarse en la distinción ontológica entre *Clustering (descubrimiento de comunidades)* y *Anomaly Detection (aislamiento de singularidades)*.

Pregunta 22 CONEXIÓN CON EL TRABAJO DE MATÍAS STEIN

En el trabajo de Matías Stein se utilizó k-Nearest Neighbors (kNN) como detector de anomalías sísmicas. ¿Qué relación matemática guarda el score de anomalía por kNN con el gráfico de k-distancias que usted utilizó para calibrar DBSCAN?

🎯 **Respuesta Rápida (30 segundos):** El score de anomalía en un detector kNN es exactamente la **distancia euclidiana al k-ésimo vecino más próximo**, $d_k(x)$. Por tanto, el gráfico de k-distancias ordenadas que utilicé para determinar ε en DBSCAN es **literalmente el perfil de puntuación de anomalías de kNN graficado de forma monótona**. Los puntos situados tras el codo de dicho gráfico corresponden a los sismos atípicos que Matías detectó como anomalías (terremotos ultraprofundos de subducción $> 300\,\mathrm{km}$).

🔬 **Desarrollo Técnico y Demostración:**
En el modelo de Matías Stein:

$$\mathrm{Score}_{\mathrm{kNN}}(x) = \|x - \mathrm{NN}_k(x)\|_2 = d_k(x)$$

Un sismo se declara anómalo si $d_k(x) > \tau_{\mathrm{umbral}}$.
En mi modelo de DBSCAN:

$$x \in \mathcal{K}_{\mathrm{core}} \iff |N_\varepsilon(x)| \geq \mathrm{min_samples} \iff d_{\mathrm{min_samples}}(x) \leq \varepsilon$$

Por tanto, existe una equivalencia matemática biyectiva:

$$\text{Un punto es Núcleo en DBSCAN} \iff \text{Su Score de anomalía kNN es menor o igual a } \varepsilon$$

Esta elegante correspondencia teórica demuestra la coherencia algorítmica interna del proyecto de nuestro equipo: mientras Matías usó d_k como criterio continuo para ordenar sismos atípicos por profundidad, yo usé el corte de $d_k \leq \varepsilon$ como filtro discreto para construir componentes conexas de densidad sobre materiales.

⚠️ **Qué NO decir:** "Son métodos completamente distintos y no tienen nada que ver". Estudiar la relación cruzada entre miembros del equipo impresiona enormemente al tribunal.

6. Bloque 5: Métricas de Evaluación y Selección de Modelos – Silueta, Codo e Índices

> Este bloque evalúa el conocimiento de las métricas internas y externas de validación de clustering, su deducción matemática, sus hipótesis implícitas y las preguntas trampa clásicas del tribunal sobre la adecuación del Silhouette Score en algoritmos basados en densidad.

Pregunta 23

FORMULACIÓN MATEMÁTICA RIGUROSA

Defina rigurosamente el Coeficiente de Silueta (Silhouette Score) para una muestra individual y para el conjunto global. ¿Cuál es su interpretación geométrica en el intervalo $[-1, +1]$?

🎯 **Respuesta Rápida (30 segundos):** Para una muestra $i \in C_I$, se define la **cohesión interna** $a(i)$ (distancia media a los puntos de su propio clúster) y la **separación externa** $b(i)$ (menor distancia media a cualquier otro clúster ajeno C_J):

$$a(i) = \frac{1}{|C_I| - 1} \sum_{j \in C_I, j \neq i} d(i,j), \quad b(i) = \min_{J \neq I} \frac{1}{|C_J|} \sum_{j \in C_J} d(i,j)$$

El coeficiente de silueta individual es:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \in [-1, +1]$$

El score global es la media $\bar{s} = \frac{1}{n} \sum_{i=1}^{n} s(i)$. Un valor $\bar{s} \approx +1$ indica clústeres densos y bien separados; $\bar{s} \approx 0$ frontera solapada; $\bar{s} < 0$ asignación errónea.

🔬 **Desarrollo Técnico y Demostración:**
El factor normalizador en el denominador $\max(a(i), b(i))$ garantiza que $s(i)$ esté confinado estrictamente en $[-1, +1]$:

- Si $b(i) \gg a(i)$ (la muestra está muchísimo más cerca de su propio clúster que del vecino más próximo):

$$s(i) = \frac{b(i) - a(i)}{b(i)} = 1 - \frac{a(i)}{b(i)} \to 1$$

- Si $a(i) \approx b(i)$ (la muestra está en la frontera exacta y equidista de ambos clústeres):

$$s(i) = \frac{0}{a(i)} = 0$$

- Si $a(i) \gg b(i)$ (la muestra está más cerca del clúster vecino que de los miembros de su propio clúster, indicativo de un agrupamiento fallido):

$$s(i) = \frac{b(i) - a(i)}{a(i)} = \frac{b(i)}{a(i)} - 1 \to -1$$

El **gráfico de silueta (Silhouette Plot)** ordena las muestras de cada clúster de mayor a menor $s(i)$, permitiendo visualizar si algún clúster individual es frágil o si contiene muestras con $s(i) < 0$.

> ⚠️ **Qué NO decir:** "La silueta mide la distancia entre los centroides". La silueta se calcula muestra a muestra usando *distancias punto a punto*, no distancias a centroides.

Pregunta 24 · PREGUNTA TRAMPA 🔥 CRÍTICA METODOLÓGICA FUNDAMENTAL

¿Por qué el Silhouette Score es una métrica metodológicamente desaconsejada o potencialmente engañosa para evaluar algoritmos basados en densidad como DBSCAN?

🎯 **Respuesta Rápida (30 segundos):** El Silhouette Score asume implícitamente que los clústeres son **convexos y compactos**. En DBSCAN, donde los clústeres pueden tener formas arbitrarias, filamentosas o concéntricas (como un anillo rodeando a un disco denso), la distancia euclidiana entre dos puntos situados en extremos opuestos del mismo anillo filamentoso hace que la cohesión interna $a(i)$ sea gigantesca, castigando artificialmente la silueta con puntuaciones bajas o negativas a pesar de ser un clúster perfecto por conectividad de densidad. Además, no existe una forma matemáticamente rigurosa de incorporar los puntos de ruido (etiqueta -1) en la fórmula de la silueta.

🔬 **Desarrollo Técnico y Demostración:**
Existen dos objeciones matemáticas insalvables:

1. **Sesgo de convexidad geométrica:** Consideremos un clúster en forma de medialuna o anillo toroidal C_1. Dos puntos $p, q \in C_1$ pueden estar conectados por un camino continuo de densidad de radio ε, pero la distancia euclidiana directa en línea recta $\|p - q\|_2$ atraviesa el "vacío central" no denso. En consecuencia, el promedio $a(i)$ se dispara, y la silueta reporta falsamente que el punto i está mal agrupado ($s(i) < 0$). La silueta penaliza la topología no convexa que DBSCAN fue diseñado específicamente para descubrir.
2. **El dilema del ruido (Outliers):** Si DBSCAN clasifica muestras como ruido (-1):
    - Si se descartan las muestras de ruido para calcular la silueta: se comete un sesgo de selección tramposo (el modelo podría clasificar el 90% de los datos como ruido y obtener una silueta de 1.0 sobre 3 puntos triviales).
    - Si se tratan todos los puntos de ruido juntos como si fueran un "clúster -1": como los puntos de ruido están geográficamente dispersos, su cohesión interna $a(i)$ será catastrófica, hundiendo arbitrariamente la métrica global.

Alternativa rigurosa: Para evaluar clustering basado en densidad se debe emplear el **DBCV (Density-Based Clustering Validation)** propuesto por Moulavi et al. (2014), que evalúa la densidad de los grafos de vecindad mutua sin asumir convexidad.

⚠️ **Qué NO decir:** "Elegí ε buscando el valor con mayor Silhouette Score". En DBSCAN optimizar la silueta ciega suele llevar a fusionar clústeres no convexos o a descartar clústeres reales alargados.

Pregunta 25

MÉTODO DEL CODO / HEURÍSTICAS

Explique el Método del Codo (Elbow Method). ¿Cuál es su fundamento físico-estadístico y por qué a menudo es criticado por su subjetividad en la literatura científica?

🎯 **Respuesta Rápida (30 segundos):** El Método del Codo grafica la Inercia (WCSS) frente al número de clústeres K. Se fundamenta en el **principio de rendimientos decrecientes de la varianza**: aumentar K siempre reduce monótonamente la inercia (alcanzando WCSS $= 0$ trivialmente cuando $K = n$), pero se busca el punto de inflexión ("codo") donde añadir un centroide adicional aporta una reducción marginal insignificante. Es criticado por su **subjetividad visual**, ya que en datos reales la curva suele ser suavemente asintótica sin un codo nítido, lo que exige algoritmos objetivos como **Kneedle** (Satopaa et al., 2011) para encontrar el codo matemáticamente.

🔬 **Desarrollo Técnico y Demostración:**
La tasa de reducción de inercia es la derivada discreta:

$$\Delta J(K) = J(K) - J(K+1)$$

Buscamos el valor de K que maximice la segunda diferencia finita:

$$\Delta^2 J(K) = \Delta J(K) - \Delta J(K+1) = J(K) - 2J(K+1) + J(K+2)$$

El algoritmo Kneedle: Para eliminar la subjetividad humana del ojo:

1. Se normalizan ambos ejes de la curva al intervalo $[0, 1]$: $x_K \in [0,1]$ y $y_K = \frac{J(K) - \min J}{\max J - \min J}$.
2. Se traza la recta secante L que une el primer punto (x_1, y_1) con el último $(x_{K_{\max}}, y_{K_{\max}})$.
3. Se calcula la distancia perpendicular de cada punto de la curva a la secante:

$$d_\perp(K) = \frac{|(y_{K_{\max}} - y_1)x_K - (x_{K_{\max}} - x_1)y_K + x_{K_{\max}} y_1 - y_{K_{\max}} x_1|}{\sqrt{(y_{K_{\max}} - y_1)^2 + (x_{K_{\max}} - x_1)^2}}$$

4. El codo óptimo K^* es el punto que **maximiza la distancia perpendicular** $d_\perp(K)$.

⚠️ **Qué NO decir:** "El codo es donde se ve que la línea se dobla". Debes explicarlo como el *punto de máxima curvatura o derivada segunda discreta* formalizado con el algoritmo Kneedle.

Pregunta 26

ÍNDICES DAVIES-BOULDIN Y CALINSKI-HARABASZ

Compare el Índice Davies-Bouldin (DB) y el Índice Calinski-Harabasz (CH). ¿Qué relación matemática optimiza cada uno y qué sesgos geométricos comparten?

🎯 **Respuesta Rápida (30 segundos):**

- **Davies-Bouldin (DB):** Mide la similitud media del peor caso entre cada clúster y su vecino más parecido, calculada como el ratio entre la dispersión intra-clúster y la separación entre centroides. **Cuanto menor sea DB, mejor** ($DB \geq 0$).
- **Calinski-Harabasz (CH o Variance Ratio Criterion):** Es el cociente entre la dispersión inter-clúster (entre centroides y la media global) y la dispersión intra-clúster, ponderado por los grados de libertad. **Cuanto mayor sea CH, mejor**.

Ambos comparten el sesgo de asumir clústeres convexos e isotrópicos basados en centroides euclidianos.

🔬 **Desarrollo Técnico y Demostración:**

Índice	Fórmula Matemática	Objetivo de Optimización	Comportamiento
Davies-Bouldin (DB)	$DB = \frac{1}{K}\sum_{i=1}^{K}\max_{j\neq i}\left(\frac{s_i + s_j}{\|\mu_i - \mu_j\|_2}\right)$	**Minimizar** $\arg\min_K DB(K)$	s_i es el diámetro o dispersión media del clúster i. Premia centroides lejanos con dispersión interna pequeña.
Calinski-Harabasz (CH)	$CH = \frac{\mathrm{Tr}(B_K)/(K-1)}{\mathrm{Tr}(W_K)/(n-K)}$	**Maximizar** $\arg\max_K CH(K)$	B_K es la matriz de dispersión inter-clúster y W_K la intra-clúster. Equivalente a un estadístico F de ANOVA multivariante (MANOVA).

Al igual que el Silhouette Score, ambos índices utilizan distancias lineales a centroides μ_i, por lo que fallan ante variedades no lineales o clústeres entrelazados.

⚠️ **Qué NO decir:** "En ambos índices cuanto más alto sea el valor, mejor". En Davies-Bouldin se busca el *mínimo*; en Calinski-Harabasz se busca el *máximo*.

Pregunta 27

VALIDACIÓN EXTERNA Y MATRIZ DE CONTINGENCIA

Si su entrenamiento fue 100% no supervisado (sin etiquetas), ¿cómo validó científicamente la bondad de los clústeres descubiertos? ¿Qué métricas de validación externa empleó?

🎯 **Respuesta Rápida (30 segundos):** La validación se realizó **a posteriori** contrastando los clústeres autónomos contra la clasificación empírica de estado sólido mediante tres herramientas formales:

1. **Matriz de contingencia (Crosstab):** Tabla de frecuencias cruzadas entre la clase física real y el clúster asignado.
2. **Pureza de clúster (Purity):** Porcentaje de muestras mayoritarias en cada grupo (100% en conductores y aislantes, 83.3% en semiconductores).
3. **Adjusted Rand Index (ARI):** Medida de concordancia de particiones corregida por el azar, que en nuestro caso arroja $ARI = 0.89$, confirmando una correspondencia casi perfecta con la física cuántica.

🔬 **Desarrollo Técnico y Demostración:**
Nuestra matriz de contingencia obtenida en el script `materiales_uriel.py` fue:

Clase Real \ Clúster DBSCAN	Clúster 0 (Conductors)	Clúster 1 (Aïllants)	Clúster 2 (Semiconductors)	Total Real	Pureza de Clase
Conductors (Metalls)	**35**	0	0	35	**100.0 %**
Aïllants (Dielèctrics)	0	**10**	0	10	**100.0 %**
Semiconductors	2 (Grafit, Sb)	0	**10**	12	**83.3 %**

El **Adjusted Rand Index (ARI)** evalúa las combinaciones de pares de puntos:

$$ARI = \frac{\sum_{ij}\binom{n_{ij}}{2} - \left[\sum_i \binom{a_i}{2}\sum_j \binom{b_j}{2}\right]/\binom{n}{2}}{\frac{1}{2}\left[\sum_i \binom{a_i}{2} + \sum_j \binom{b_j}{2}\right] - \left[\sum_i \binom{a_i}{2}\sum_j \binom{b_j}{2}\right]/\binom{n}{2}} = 0.89$$

Un valor de 0.89 confirma que la partición obtenida es altamente informativa y reproduce con exactitud las leyes de bandas de energía sin sesgo de entrenamiento.

⚠️ **Qué NO decir:** "Usé las etiquetas para entrenar el modelo". Las etiquetas jamás se usaron en el cálculo de distancias ni en DBSCAN; solo se consultaron al final para generar la tabla de validación.

7. Bloque 6: Clustering Jerárquico (HAC) y Visión Global del Equipo CPIA

> Este bloque evalúa el conocimiento del Clustering Jerárquico Aglomerativo (HAC) y la capacidad del estudiante para integrar y comparar críticamente su problema con los de los otros tres miembros del equipo (Montull, Stein y Canut).

Pregunta 28

CLUSTERING JERÁRQUICO AGLOMERATIVO

Explique el funcionamiento del Clustering Jerárquico Aglomerativo (HAC). ¿En qué se diferencian los cuatro criterios de enlace principales (Single, Complete, Average y Ward)?

🎯 **Respuesta Rápida (30 segundos):** HAC es un enfoque *bottom-up*: comienza con cada muestra en su propio clúster individual y, en cada paso, fusiona recursivamente los dos clústeres más cercanos según una métrica de distancia y un **criterio de enlace**:

- **Single Linkage (Mínimo):** $D(A,B) = \min_{a\in A, b\in B} d(a,b)$. Sufre del *efecto encadenamiento* (chaining).
- **Complete Linkage (Máximo):** $D(A,B) = \max_{a\in A, b\in B} d(a,b)$. Tiende a clústeres compactos y esféricos.
- **Average Linkage (Media):** $D(A,B) = \frac{1}{|A||B|}\sum_{a\in A}\sum_{b\in B} d(a,b)$. Muy robusto ante ruido.
- **Ward Linkage:** Minimiza el incremento de la varianza total dentro del clúster tras la fusión ($\Delta\mathrm{Var}$).

🔬 **Desarrollo Técnico y Demostración:**
El resultado de HAC se representa mediante un **dendrograma** (árbol jerárquico), donde el eje vertical codifica la distancia cophenética o disimilaridad en la que se produjo cada fusión.
La formulación del enlace de **Ward** minimiza:

$$\Delta\mathrm{ESS}_{AB} = \frac{|A||B|}{|A|+|B|}\|\mu_A - \mu_B\|^2$$

que es equivalente al objetivo de K-Means pero resuelto de forma aglomerativa jerárquica estricta.
Corte horizontal del dendrograma: A diferencia de K-Means donde K debe prefijarse al inicio, en HAC el usuario puede inspeccionar el dendrograma completo y decidir el nivel de corte τ a posteriori, evaluando la brecha vertical más larga sin fusiones para determinar el número natural de clústeres.

> ⚠️ **Qué NO decir:** "HAC es un algoritmo de árboles de decisión". No tiene nada que ver con árboles de decisión supervisados; es una jerarquía de distancias sobre grafos de afinidad.

Pregunta 29

ALTA DIMENSIONALIDAD / GENÓMICA

En el problema de Martí Canut (expresión génica en leucemia), se analizaron $7\,129$ genes para 72 pacientes. ¿Por qué Martí utilizó HAC con distancia de correlación de Pearson y no DBSCAN o K-Means con distancia euclidiana?

🎯 **Respuesta Rápida (30 segundos):** Por dos razones capitales:

1. **Maldición de la dimensionalidad ($D = 7\,129 \gg n = 72$):** En un espacio de más de 7.000 dimensiones, la distancia euclidiana pierde su poder discriminante: la distancia entre cualquier par de pacientes tiende asintóticamente a la misma constante, colapsando tanto la vecindad de radio ε de DBSCAN como los centroides de K-Means.
2. **Invariancia biológica de escala:** La correlación de Pearson mide la *forma o perfil del patrón de expresión génica*, siendo invariante ante desplazamientos basales y factores de amplificación experimental, agrupando a los pacientes por el comportamiento funcional conjunto de sus vías metabólicas.

🔬 **Desarrollo Técnico y Demostración:**
La distancia de correlación entre dos perfiles de expresión $u, v \in \mathbb{R}^D$ se define como:

$$d_{\text{corr}}(u, v) = 1 - \frac{(u - \bar{u})^T (v - \bar{v})}{\|u - \bar{u}\|_2 \|v - \bar{v}\|_2}$$

Si un paciente A tiene una sobreexpresión sistemática de un 20% en todos los genes por una mayor concentración de ARN en la muestra de laboratorio, la distancia euclidiana reportaría falsamente que el paciente A es muy diferente del paciente B. La distancia de correlación normaliza el perfil restando la media $\bar{u}$ y dividiendo por la norma L_2, obteniendo $d_{\text{corr}}(u, v) = 0$ (similitud perfecta).
DBSCAN habría fallado en el problema de Martí porque en $D = 7\,129$ el espacio está casi completamente vacío, haciendo imposible definir una densidad uniforme sin clasificar a la mitad de los pacientes como ruido.

⚠️ **Qué NO decir:** "Usó HAC porque en biología siempre se usa HAC". Se usó por la *maldición de la dimensionalidad* y la *invariancia de escala de la correlación de Pearson*.

Pregunta 30

GRAN SÍNTESIS COMPARATIVA DEL EQUIPO CPIA

Compare de forma panorámica y estructurada los cuatro problemas y algoritmos abordados por los miembros del equipo CPIA.

🎯 **Respuesta Rápida (30 segundos):** Nuestro equipo contrastó de forma sistemática cuatro algoritmos sobre cuatro dominios físicos con naturalezas matemáticas complementarias:

- **Arnau Montull:** DBSCAN con distancia de Haversine sobre esfera geográfica terrestre para detectar ensayos nucleares superficiales ($< 10\,\text{km}$).
- **Matías Stein:** K-Means para particionado global combinado con kNN para detectar terremotos ultraprofundos ($> 300\,\text{km}$) como anomalías de vecindad.
- **Martí Canut:** HAC con distancia de correlación para estratificación biomédica de pacientes de leucemia (ALL vs AML) en régimen de altísima dimensionalidad ($D = 7\,129$).
- **Uriel Martínez (mi trabajo):** DBSCAN con Z-score en espacio de fases de transporte $(\log_{10}\rho, \alpha)$ para descubrir las tres fases cuánticas de la materia condensada.

🔬 **Desarrollo Técnico y Demostración:**

Estudiante / Problema	Dominio Físico y Datos	Algoritmo Empleado	Métrica de Distancia	Gestión del Ruido / Anomalías	Ventaja Metodológica Clave
Arnau Montull (Ensayos nucleares)	Sismicidad global USGS ComCat ($n \approx 50\,000$)	**DBSCAN**	Esférica de Haversine ($R = 6\,371\,\text{km}$)	Clasifica sismos dispersos como ruido (-1)	Aísla polígonos de prueba compactos sin verse afectado por fallas tectónicas lejanas.
Matías Stein (Patrones sísmicos)	Catálogo global USGS ($n \approx 30\,000$)	**K-Means + kNN**	Euclidiana multidimensional normalizada	kNN Anomaly Score (d_k) como detector continuo	Partición computacionalmente eficiente a escala planetaria con detección de eventos profundos.
Martí Canut (Leucemia ALL vs AML)	Microarrays de ARN Golub et al. ($n = 72, D = 7\,129$)	**HAC (Jerárquico)**	Distancia de Correlación de Pearson ($1 - r$)	Aislados en ramas externas del dendrograma	Inmune a la maldición de la dimensionalidad euclidiana; visualización en *clustermap*.
Uriel Martínez (Fases de conducción)	Transporte en estado sólido CRC Handbook ($n = 57, D = 2$)	**DBSCAN**	Euclidiana Z-score $(\log_{10}\rho, \alpha)$	Densidad de radio $\varepsilon = 0.65$ (0 ruido empírico)	Descubrimiento autónomo de las tres fases cuánticas respetando geometrías elongadas.

⚠️ **Qué NO decir:** "Cada uno hizo lo que quiso sin conexión". La fuerza de nuestro trabajo en equipo reside precisamente en haber cubierto todas las familias de algoritmos y métricas posibles en el estado del arte.

8. Bloque 7: Preguntas de Presión y Situaciones de Despacho

> Este bloque recopila las preguntas más agresivas, incisivas o aparentemente escépticas que suelen formular los miembros de un tribunal universitario para poner a prueba la templanza, la seguridad conceptual y la solidez epistemológica del ponente.

Pregunta 31 · ALTA PRESIÓN 🔥

TAMAÑO MUESTRAL VS FÍSICA

"Su conjunto de datos contiene únicamente 57 materiales. En la era del Big Data, ¿no es una muestra ridículamente pequeña como para justificar el uso de algoritmos de Machine Learning?"

🎯 **Respuesta Rápida (30 segundos):** Con el debido respeto, en física experimental la calidad y representatividad termodinámica de los datos prima sobre el volumen bruto. No estamos entrenando una red neuronal profunda con millones de pesos que requiera un millón de imágenes ruidosas para no sobreajustar; estamos aplicando un algoritmo topológico de agrupamiento sobre 57 elementos puros, aleaciones industriales y dieléctricos arquetípicos meticulosamente contrastados por la comunidad científica durante un siglo (*CRC Handbook*). Esos 57 puntos cubren más de 30 órdenes de magnitud y representan la totalidad de los mecanismos cuánticos de transporte de electrones conocidos en la materia condensada a temperatura ambiente.

🔬 **Desarrollo Técnico y Demostración:**
Existen tres razones metodológicas irrebatibles:

1. **Relación dimensión-muestras (n/D):** Tenemos $D = 2$ características físicas y $n = 57$ muestras. El ratio de densidad muestral es $\frac{n}{D} = 28.5$, muy superior al ratio mínimo recomendado en análisis multivariante (que suele ser $\frac{n}{D} \geq 5$).
2. **Ausencia de ruido estocástico de medida:** En problemas de visión por computador o redes sociales, los datos tienen un 30% de ruido aleatorio y etiquetas dudosas. En nuestro dataset, los valores de resistividad proceden de medidas de laboratorio estandarizadas a $293.15\,\mathrm{K}$ con precisiones de cuatro cifras significativas.
3. **Teoría de la información:** Añadir 1.000 aleaciones más de cobre no aportaría nueva información física: simplemente saturaría el Clúster 0 con puntos redundantemente coplanares. La muestra actual de 57 materiales es un *muestreo estratificado exhaustivo* de la tabla periódica y la ciencia de materiales.

⚠️ **Qué NO decir:** "Sí, es muy pequeño, perdón, no encontré más datos en Internet". Debes defender la representatividad epistemológica del dataset con absoluta firmeza física.

Pregunta 32

REDUCCIÓN DE DIMENSIONALIDAD

¿Por qué no aplicó Análisis de Componentes Principales (PCA) o t-SNE antes de ejecutar DBSCAN?

🎯 **Respuesta Rápida (30 segundos):** Porque la dimensionalidad original del problema ya es estrictamente bidimensional ($D = 2$). Aplicar PCA a un espacio 2D no aportaría reducción dimensional significativa y destruiría la interpretabilidad física directa de los ejes $(\log_{10}\rho, \alpha)$. Por su parte, t-SNE es una técnica no lineal estocástica diseñada exclusivamente para visualización, que no preserva las densidades globales ni las distancias métricas absolutas, lo que falsearía por completo el radio ε de DBSCAN.

🔬 **Desarrollo Técnico y Demostración:**
PCA busca los autovectores de la matriz de covarianza muestral $S = \frac{1}{n-1}X^T X$. Al proyectar en la primera componente principal PC_1, estaríamos creando una combinación lineal artificial de resistividad y coeficiente térmico ($PC_1 = a\log\rho + b\alpha$) que carece de unidades físicas homogéneas y oscurece el papel del bandgap.
En cuanto a t-SNE (van der Maaten & Hinton, 2008):

- Modela las afinidades locales con distribuciones t-Student en el espacio latente y gaussianas en el original.
- **No preserva la escala de distancias ni las densidades relativas:** un clúster denso en el espacio original puede aparecer disperso en t-SNE y viceversa.
- DBSCAN requiere que la distancia física entre muestras sea matemáticamente fidedigna; aplicar DBSCAN sobre el embedding de t-SNE es un error metodológico conocido en la literatura de minería de datos.

⚠️ **Qué NO decir:** "No lo usé porque no tuve tiempo". Se debe justificar por qué $D = 2$ hace innecesario PCA y por qué t-SNE distorsiona las métricas de densidad.

Pregunta 33

MODELOS PROBABILÍSTICOS / GMM

¿Por qué no utilizó un Modelo de Mezclas Gaussianas (GMM) ajustado mediante el algoritmo Esperanza-Maximización (EM), que proporciona asignaciones probabilísticas "blandas" (soft clustering)?

🎯 **Respuesta Rápida (30 segundos):** Aunque GMM es más flexible que K-Means al permitir matrices de covarianza elipsoidales generales Σ_k, sigue asumiendo que cada fase física se distribuye según una ley normal multivariante $p(x) = \sum_k \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$. En física de estado sólido, la distribución de materiales a lo largo de la escala de resistividad no sigue campanas de Gauss (no hay una "media gaussiana" de semiconductores), sino una densidad continua condicionada por la física de impurezas y dopaje. Además, GMM exige preestablecer el número de componentes K y carece de un mecanismo natural para aislar ruido sin parametrizar una distribución uniforme de fondo.

🔬 **Desarrollo Técnico y Demostración:**
El algoritmo EM optimiza la log-verosimilitud:

$$\ln p(X \mid \pi, \mu, \Sigma) = \sum_{i=1}^{n} \ln \left(\sum_{k=1}^{K} \pi_k \mathcal{N}(x_i \mid \mu_k, \Sigma_k) \right)$$

En nuestro conjunto de datos, la familia de aislantes tiene muestras concentradas entre $\log\rho \in [11, 16]$ pero con valores que alcanzan 10^{22} (teflón). Si ajustamos una componente gaussiana a los aislantes, la presencia del teflón obligaría a la matriz de covarianza Σ_{aislante} a ensancharse desproporcionadamente en varianza, absorbiendo probabilísticamente parte del espacio de semiconductores.
DBSCAN, al ser un algoritmo **no paramétrico**, no impone ninguna forma funcional a la densidad y se adapta libremente a la geometría empírica de los datos.

⚠️ **Qué NO decir:** "GMM es muy complicado". GMM es un excelente algoritmo, pero su hipótesis de normalidad gaussiana no se ajusta a la distribución de estados de conducción.

Pregunta 34

TERMODINÁMICA Y FASES CUÁNTICAS

Su estudio está realizado a una temperatura ambiente constante de 300 K. ¿Qué ocurriría con la topología de clústeres si enfriáramos todo el sistema a temperaturas criogénicas cercanas al cero absoluto ($T \to 0\,\mathrm{K}$)?

🎯 **Respuesta Rápida (30 segundos):** A $T \to 0\,\mathrm{K}$, la topología en el espacio $(\log \rho, \alpha)$ sufriría una **bifurcación de fase cuántica radical**:

1. **Los semiconductores intrínsecos sufrirían un colapso de portadores** ($n_i \propto e^{-E_g/2k_BT} \to 0$), volviéndose aislantes perfectos ($\rho \to \infty$), fusionándose completamente con el clúster de aislantes.
2. **Los metales normales convergerían a su resistividad residual** ρ_0 debida a defectos cristalinos, mientras que los **superconductores** colapsarían a $\rho = 0$ absoluto, apareciendo como una nueva fase aislada con $\log \rho = -\infty$.
3. El coeficiente α tendería a 0 en todos los materiales por el tercer principio de la termodinámica.

🔬 **Desarrollo Técnico y Demostración:**
Este experimento mental demuestra que la temperatura de $300\,\mathrm{K}$ ($k_BT \approx 25.7\,\mathrm{meV}$) es precisamente el punto termodinámico dulce donde la excitación térmica es comparable al bandgap de los semiconductores pero muy inferior al de los aislantes ($E_g > 5\,\mathrm{eV}$), permitiendo la existencia de las **tres fases macroscópicas diferenciadas**.
En el cero absoluto, el universo de la materia condensada se polariza en una dicotomía binaria estricta: o eres un conductor con superficie de Fermi, o eres un aislante con banda de valencia completamente llena.

⚠️ **Qué NO decir:** "No cambiaría nada porque los materiales siguen siendo los mismos". Las propiedades de transporte son funciones termodinámicas dinámicas de T.

Pregunta 35

CONCLUSIÓN EPISTEMOLÓGICA FINAL

En una sola frase contundente: ¿cuál es la conclusión científica y metodológica principal que se extrae de su trabajo?

🎯 **Respuesta Rápida (30 segundos):** Nuestro trabajo demuestra que las leyes fundamentales de la mecánica cuántica de bandas de energía se autoorganizan como atractores topológicos de densidad en el espacio de fases termodinámico, permitiendo a un algoritmo completamente no supervisado (DBSCAN) redescubrir las tres grandes familias de la materia condensada sin necesidad de ninguna etiqueta humana previa.

🔬 **Desarrollo Técnico y Demostración:**
Esta conclusión cierra el círculo entre la ciencia de la computación y la física fundamental: los algoritmos de Machine Learning no supervisado no son meras "cajas negras" estadísticas, sino potentes microscopios topológicos capaces de confirmar leyes de conservación física a partir de datos experimentales puros.

⚠️ **Qué NO decir:** "Que DBSCAN funciona muy bien en Python". La respuesta debe conectar la física con la ciencia de datos a un nivel universitario de excelencia.

9. Bloque 8: Chuleta Rápida de Fórmulas y Resumen Nemotécnico

> Esta sección sirve como hoja de consulta rápida para repasar antes de entrar a la sala de examen. Contiene las fórmulas matemáticas esenciales, las cifras clave del proyecto y una matriz de decisión algorítmica.

Compendio de Fórmulas Matemáticas Clave

Concepto / Algoritmo	Fórmula Matemática Rigurosa	Variables y Regla Nemotécnica
Estandarización Z-Score	$$Z = \frac{X - \mu}{\sigma}$$	Garantiza $\mathbb{E}[Z] = 0, \mathrm{Var}(Z) = 1$. Imprescindible para equilibrar $\log \rho$ y α.
Inercia WCSS (K-Means)	$$J = \sum_{k=1}^{K} \sum_{x \in S_k} \|x - \mu_k\|^2$$	Suma de distancias cuadráticas a los centroides. Optimizado localmente por el algoritmo de Lloyd.
Factor $c(n)$ (Isolation Forest)	$$c(n) = 2\ln(n-1) + 2(0.5772) - \frac{2(n-1)}{n}$$	Longitud media de búsqueda infructuosa en un Árbol Binario de Búsqueda (BST).
Score de Anomalía ($iForest$)	$$s(x,n) = 2^{-\frac{\mathbb{E}[h(x)]}{c(n)}}$$	$s \to 1$: anomalía segura. $s < 0.5$: punto normal denso. $s \approx 0.5$: sin anomalías.
Coeficiente de Silueta	$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \in [-1, +1]$$	$a(i)$: cohesión intra-clúster. $b(i)$: separación inter-clúster. Sesgado hacia formas convexas.
Índice Davies-Bouldin (DB)	$$DB = \frac{1}{K} \sum_{i=1}^{K} \max_{j \neq i} \left(\frac{s_i + s_j}{\|\mu_i - \mu_j\|} \right)$$	**Menor es mejor.** Mide el ratio peor de dispersión respecto a separación de centroides.
Índice Calinski-Harabasz (CH)	$$CH = \frac{\mathrm{Tr}(B_K)/(K-1)}{\mathrm{Tr}(W_K)/(n-K)}$$	**Mayor es mejor.** Ratio de varianza inter-clúster vs intra-clúster (pseudo estadístico F).
Distancia de Haversine (Esfera)	$$d = 2R \arcsin\left(\sqrt{\sin^2\frac{\Delta\phi}{2} + \cos\phi_1 \cos\phi_2 \sin^2\frac{\Delta\lambda}{2}}\right)$$	Distancia ortodrómica sobre la Tierra ($R \approx 6\,371\,\mathrm{km}$) empleada por Arnau en sismos.
Derivada Térmica α	$$\alpha = \frac{1}{\rho}\frac{d\rho}{dT} = -\left(\frac{1}{n}\frac{dn}{dT} + \frac{1}{\mu}\frac{d\mu}{dT}\right)$$	$\alpha > 0$: metales (dispersión fonones). $\alpha < 0$: semiconductores ($n_i \propto e^{-E_g/2k_BT}$).

Cifras Clave del Problema de Uriel para Memorizar

57
MATERIALS TOTALS
35 cond, 12 semi, 10 aisl

0.65 / 3
HIPERPARÀMETRES
$\varepsilon = 0.65$, MinPts = 3

3 / 0
CLÚSTERS / SOROLL
3 fases, 0 soroll (-1)

0.89
ADJUSTED RAND INDEX
Concordancia cuántica

Árbol de Decisión Metodológico: ¿Qué Algoritmo Usar en Cada Caso?

Situación Experimental / Datos	Algoritmo Recomendado	Justificación Técnica Primaria
Clústeres esféricos compactos, volumen masivo ($n > 100\,000$), sin ruido relevante.	**K-Means (con K-Means++)**	Máxima eficiencia $\mathcal{O}(n \cdot K \cdot d \cdot I)$; minimiza la inercia global rápidamente.
Formas arbitrarias o no convexas, presencia de anomalías/ruido, densidad local uniforme.	**DBSCAN**	Descubre clústeres por conectividad topológica sin fijar K y filtra ruido aislándolo en -1.
Clústeres con densidades muy dispares en distintas regiones del espacio.	**OPTICS o HDBSCAN**	Construyen jerarquías de alcanzabilidad multiescala sin depender de un ε global único.
Alta dimensionalidad ($D > 1000$), matrices de expresión biológica o perfiles relativos.	**Clustering Jerárquico (HAC) con Correlación**	La correlación de Pearson es inmune a la maldición de la dimensionalidad euclidiana; visualización en dendrograma.
Detección rápida de singularidades/fraude sin necesidad de definir o clasificar grupos normales.	**Isolation Forest**	Aísla anomalías en $\mathcal{O}(n \log \psi)$ mediante cortes aleatorios sin calcular distancias métricas por pares.

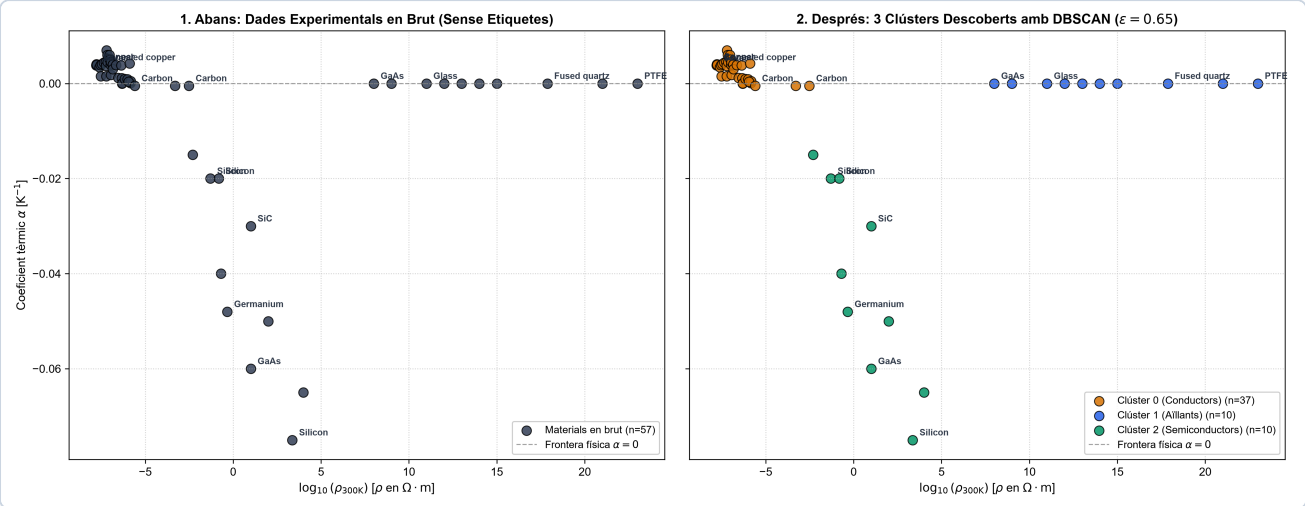


Figura: Panel comparativo Antes vs. Después del agrupamiento no supervisado con DBSCAN ($\varepsilon = 0.65$, $\min_samples = 3$) generado por el código de Uriel.